arXiv:2202.06042v1[cs.RO]5 Sep 2022

Learning-based Traversability Costmap for Autonomous Off-road Navigation

朱秋敏[1]、孙震[1]、夏松鹏程[1]、刘国庆[1]、马克辉[1]、裴凌[1]✉、龚正[2]✉、金成[3]

1 上海交通大学 上海市导航与位置服务重点实验室，中国上海，ling.pei@sjtu.edu.cn 2 中国信息通信研究院，中国北京，gongzheng1@caict.ac.cn 3 智能地球重点实验室，中国北京，jinchengno1@163.com

Abstract. 越野地形的可通行性估计是自主导航的重要程序。然而，为机器人和表面之间的复杂交互创建可靠的标签仍然是基于学习的成本图生成中的一个具有挑战性的问题。为了解决这个问题，我们提出了一种通过利用环境的视觉和几何信息来预测可遍历性成本图的方法。为了量化粗糙度和凹凸度等表面特性，我们引入了一种利用本体感受信息进行风险感知标记的新方法，用于网络训练。我们在复杂越野场景的成本图预测和导航任务中验证了我们的方法。我们的结果表明，我们的成本图预测方法在平均精度和 MSE 方面表现出色。导航结果表明，使用我们学习的成本图可以实现更安全、更平稳的驾驶，在两种场景下的最高成功率、最低归一化轨迹长度、最低时间成本和最高平均稳定性方面优于以前的方法。

Keywords: 自主导航、可穿越性、越野环境、无人驾驶地面车辆、惯性测量单元 (IMU)

1 Introduction

越野环境中的自主导航是无人驾驶地面车辆的一个关键问题。机器人可在荒野、森林、矿山和其他复杂地形中执行农业、采矿、行星探索、监视等任务。为了确保安全驾驶，分析这些地形的可通行性并构建导航成本图至关重要。

各种工作都集中在这个问题上，并为研究的进展做出了贡献。最初，可通行性估计被视为区分可通行和不可通行地形的二元分类问题。

✉Corresponding author

目前，它可以被视为与遍历难度级别相关的多类分类[1, 2]或分配连续可遍历性值的回归[3]。尽管在评估可通行性方面付出了巨大的努力，但研究界仍然面临两个挑战。

挑战之一是地形特征的表示。几何属性统计是一种流行的方法，构建高度网格图来计算台阶高度、粗糙度和坡度作为可通行性得分[4, 5]。基于外观的方法将问题重定向到图像处理和分类。地形根据图像的纹理和颜色进行分类，最近语义分割已成为可通行性估计的有用工具[6,7]。虽然几何和外观信息可以分别评估可通行性，但也存在几何特性或外观相同但可通行性不同的情况，例如干泥和湿泥，或低草和高草。我们考虑环境的几何和视觉特征来综合评估可穿越性。虽然这些信息可以代表不同的地形，但地面对车辆的实际影响（决定其可通过性）仍然未知。

因此，另一个挑战涉及可遍历性成本标签的定义。尽管各种工作提出了基于学习的成本图方法，但它们在预测成本时忽略了机器人与不同地形交互的细微差别。有些简单地将地面分为可穿越和不可穿越，无论车辆能否到达[8]，而另一些则将滑移表示为速度误差[9]。为了捕捉车辆所经历的粗糙度和颠簸度，惯性测量单元 (IMU) 等本体感受传感器可用于感测这些特征。 IMU 很容易在地面车辆上构建并捕获状态 [10]。这些信号将车辆的振动、运动和感觉变化反映为可通行性成本。我们考虑到IMU数据的特性和机器人风险，处理IMU在z轴上的线性加速度以生成连续的可遍历性值作为学习目标。

简而言之，我们提出了一种基于学习的方法来预测可遍历性成本图，该成本图呈现了地形对机器人导航的风险感知影响。包括语义和几何特征的外感受信息以及作为机器人速度的内感受信息是学习连续成本的输入，该连续成本由处理后的 IMU 数据监督。我们结合了一个卷积神经网络（CNN）主干来从外感受信息中提取特征，一个神经网络来处理内感受信息，以及一个长短期记忆（LSTM）来处理串联特征作为我们的学习架构。

本研究的主要贡献如下：

- 我们提出了一个基于学习的框架，该框架通过语义和几何信息以及线性和角速度的融合来预测连续可遍历性成本图，并使用 LSTM 来处理这些特征的序列。

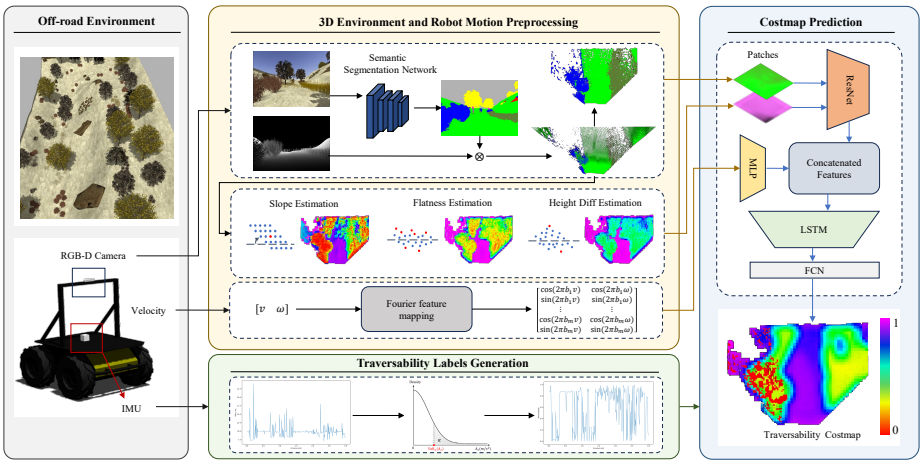

图 1：可遍历性成本图预测系统概述。我们的方法包括三个模块：1）可遍历性标签生成；2）3D环境和机器人运动预处理；3）成本图预测。我们使用 IMU 数据来计算风险感知的可遍历性标签。 3D 环境信息和速度经过预处理作为网络的输入。网络生成连续的可通行性成本图，用于越野地形中的导航。

- 为了反映在不同地形上驾驶的反应和风险，我们提出了一种新颖的可穿越性成本标签，该标签源自用于训练网络的 IMU 数据。 • 我们在两种越野场景中的成本图预测和导航任务上验证了我们的方法，在准确性、MSE、成功率、时间成本和驾驶稳定性方面表现出色。

2 Methods

2.1 Overview

我们提出了一个基于学习的框架来评估地形的可穿越性并获得越野环境中导航的成本图。它将 RGB-D 点云和机器人速度作为神经网络的输入，并输出以机器人为中心的可遍历性成本图。该框架的概述如图1所示。路径规划算法可以使用网络预测的成本图来实现自主导航。

该框架分为三个主要模块：1）可遍历性标签生成；2）3D环境和机器人运动预处理；3）成本图预测。标签生成步骤根据本体感觉计算可遍历性成本。预处理模块从 RGB-D 图像和点云中提取语义和几何数据，并表示机器人速度作为输入

网络的。利用输入和标签，训练神经网络来预测可遍历性成本。

2.2 Traversability Labels Generation

为了学习连续且标准化的可遍历性成本，我们使用 z 轴的线性加速度来描述机器人与地面之间的相互作用[17-19]。 z轴线加速度，一般理解为作用在机器人z轴上的力，反映了地形的粗糙度和凹凸程度。如之前的工作 [20,21] 所示，IMU 线性加速度测量在静止条件下遵循正态分布或高斯分布。根据z轴线加速度的物理特性，其分布的均值近似为重力加速度的值。我们采用风险价值（VaR）作为机器人风险评估[22]，来量化可通性成本。由于两侧偏离均值相等的值可以被认为具有相同的成本，因此分布 $X \sim N\left(\mu, \sigma^2\right)$ 可以通过 $\left|\frac{X-\mu}{\sigma}\right|$ 转换为半正态分布，α 级别的 $\mathrm{VaR}_\alpha(A_z)$ 就是 $(1-\alpha)$ 分位数，如图 2 所示：

$$\mathrm{VaR}_\alpha(A_z) := \min\{a_z \mid \mathbb{P}[A_z > a_z] \leq \alpha\} \tag{1}$$

我们将每个处理后的IMU z轴线性加速度值作为$\mathrm{VaR}_\alpha(A_z)$，并计算其风险级别 $\alpha \in$[0,1]作为可遍历成本标签，其中1表示最低成本，0表示最高成本。稳定运动期间记录的数据用于导出分布。

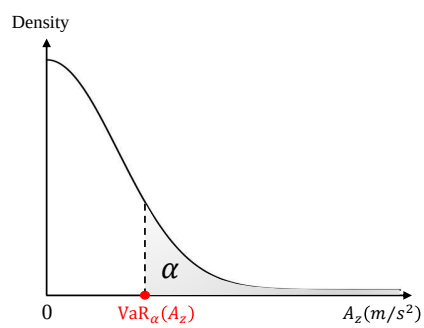

图 2：这项工作将 IMU 数据定义为风险价值 (VaR)，将可遍历性标签定义为风险级别 α。

2.3 3D Environment and Robot Motion Preprocessing

为了获取学习网络的输入，我们将环境的地形特征表示为视觉和几何信息，并参数化

机器人速度到高维。我们使用 Fast-SCNN [23] 来预测来自 RGB-D 相机的 RGB 图像的语义分割，并根据语义和深度图像生成彩色点云。从点云构建分辨率为 0 .1 米的局部网格图，每个网格单元包含 RGB 和几何值，无论车辆上方 2 米处没有接触的点。

为了计算包括坡度、平坦度和高度差在内的几何估计，我们首先构建局部点云的八叉树，以加快每个位置点的检索。每个网格单元中的斜率s由车辆坐标系的z轴与以网格单元为中心的宽度为0.5米的正方形区域的表面法线之间的角度来表示：

$$s = \frac{180 \arccos\left(\mathbf{n} \cdot \mathbf{e_z}\right)}{\pi} \tag{2}$$

其中$\mathbf{n}$是用PCA[11]计算的单位法线向量，$\mathbf{e_z}$是向量$[0, 0, 1]^\top$。坡度值的范围是从 0 到 90 度。平坦度 f 通过任意网格单元中点的垂直高度计算：

$$f = \sqrt{\frac{\sum_{j=1}^{N}\left[\mathbf{n} \cdot \left(\mathbf{p_j} - \bar{\mathbf{p}}\right)\right]^2}{N+1}} \tag{3}$$

其中 $\bar{\mathbf{p}}$ 是网格单元的 3D 质心，$\mathbf{p_j} = [x, y, z]^\top$ 是网格单元中点的位置，N 是这些点的数量。高度差 h 计算为点垂直高度之间的最大偏差：

$$h = \max\left[\mathbf{n} \cdot \left(\mathbf{p_i} - \bar{\mathbf{p}}\right)\right] - \min\left[\mathbf{n} \cdot \left(\mathbf{p_j} - \bar{\mathbf{p}}\right)\right], i, j \in [1, N] \tag{4}$$

当高速行驶或急转弯时，车辆会感受到由崎岖地形引起的明显振动。我们考虑速度的影响并将其处理为网络的输入。为了匹配局部网格图的维度，我们使用傅立叶特征[19]将速度参数化为更高维度的向量$\lambda(v)$：

$$\lambda(v) = \begin{bmatrix} \cos\left(2\pi b_1 v\right) & \cos\left(2\pi b_1 \omega\right) \\ \sin\left(2\pi b_1 v\right) & \sin\left(2\pi b_1 \omega\right) \\ \vdots & \vdots \\ \cos\left(2\pi b_m v\right) & \cos\left(2\pi b_m \omega\right) \\ \sin\left(2\pi b_m v\right) & \sin\left(2\pi b_m \omega\right) \end{bmatrix} \tag{5}$$

其中v是x轴和y轴线速度的范数，ω是z轴角速度，$b_i \sim \mathcal{N}\left(0, \sigma^2\right)$从高斯分布中采样，$m$对应于局部地图块的比例。

2.4 Costmap Prediction

我们的代价图预测的流程类似于[19]。我们首先从机器人轨迹中提取局部地图补丁，然后预测这些的可遍历性成本

通过训练 CNN-LSTM 网络进行补丁，最后生成用于使用训练后的网络进行导航的代价图。

我们收集所有环境数据来构建全局地图，然后使用每 0.1 秒采样的一组机器人里程计信息在全局地图中定位并提取 1×1 米的补丁。还在这些位置记录线速度和角速度。我们使用每个位置的五个连续 IMU 线性加速度数据帧作为可遍历性成本的真实标签来计算平均风险级别。

我们训练一个网络来预测从 0 到 1 的连续值作为可遍历性成本，输入语义和几何地图块以及参数化速度。我们将 ResNet18 [24] 和 MLP 提取的这些特征连接起来，然后将它们通过 LSTM [25] 来处理数据序列，因为点云补丁是沿着全局地图的驱动轨迹采样的。我们使用与[19]相同的损失和优化器。

为了在导航过程中生成实时成本图，我们采用从当前 RGB 图像和深度图像生成的 10×10 米点云局部地图。 1×1 米补丁是从本地地图中每 0.2 米进行下采样的。通过这些补丁和速度，网络可以预测可遍历性成本，并且每个 0.1×0.1 米单元的最终值是覆盖该单元的所有补丁的可遍历性成本的平均值。成本图通过检查没有点的单元并将其从输出中删除来维护本地地图输入的形状。而网络只学习车辆可以穿越的环境信息，而忽略了无法到达的障碍物数据。我们记录了机器人在数据集收集期间无法行驶的语义类别，并将值 0 分配给包含这些类别的单元格。

3 Experiment and Results

3.1 Simulation Setup

我们使用 Gazebo 模拟 [26] 中的自然环境来训练和测试我们的框架。 HUSKY 机器人配备了 RGB-D 相机和 IMU。 Gazebo 插件用于获取车辆的地面实况里程计。实验采用两种场景，如图 3 所示： i) 崎岖的山坡，其中包含陡峭的斜坡，有高草、灌木丛、岩石和树木； ii) 茂密的森林，由高高的草丛、石头、灌木丛、树木和倒下的树干组成。为了增强场景的真实感，我们调整了高草的物理属性，使车辆可以通过但有阻力。我们还通过在不同的地方添加草地、岩石和灌木丛来修改环境，使导航更具挑战性。通过机器人操作系统（ROS），记录数据并控制车辆。算法和模拟由配备 Intel i5-12490F CPU、32GB RAM 和 Nvidia RTX 3070 GPU 的台式计算机处理。

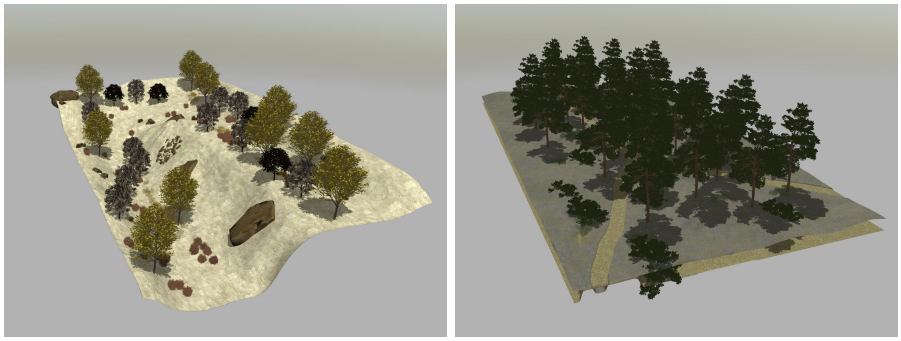

(a) hill (b) forest

图 3：用于实验的两个 Gazebo 模拟场景。 (a) 是陡峭的山坡，(b) 是茂密的森林。

3.2 Training Data

我们通过遵循不同的网络训练路径来收集模拟环境中的数据。我们使用数据集中的 RGB 和深度图像来获取密集的彩色点云，并使用 IMU 来获取地面实况可遍历性成本。包括位置、方向和速度在内的里程计数据由插件提供。在山坡场景中，由于其复杂性和粗糙度，低成本帧与高成本帧的比例为 2:1，而在森林场景中，由于平坦度，低成本帧与高成本帧的比例为 5:1。总共，我们为实验生成了 4K 训练帧、0.5K 验证帧和 0.5K 测试帧。

3.3 Costmap Evaluation

我们将性能与两个基于外观和几何的基线进行比较，以评估我们方法的质量。TNS [11] 使用一种非学习方法，根据地形类别和几何可穿越性（包括坡度和台阶高度）计算可穿越性分数。 HDIF [19] 将粗糙度描述为 IMU z 轴线性加速度的 1-30 Hz 频带功率，并训练网络来学习可遍历性成本。该网络是根据我们的数据集进行训练的。图 4 显示了这三种方法在同一位置预测的代价图。尽管这些方法输出 0 到 1 之间的连续值，但我们简化了比较以避免任何偏差。我们使用地面实况语义环境，通过将点云的标签转换为 0 或 1 来填充可穿越性网格地图。可穿越区域（如地面、高草和小径）设置为 1，其他区域（如树干、灌木丛和岩石）设置为 0。

车辆在现实和语义环境中沿着路径行驶。全局成本图是由基线和我们的方法使用收集的传感器数据生成的，并使用四种不同的指标进行评估，类似于[11]。指标描述如下：

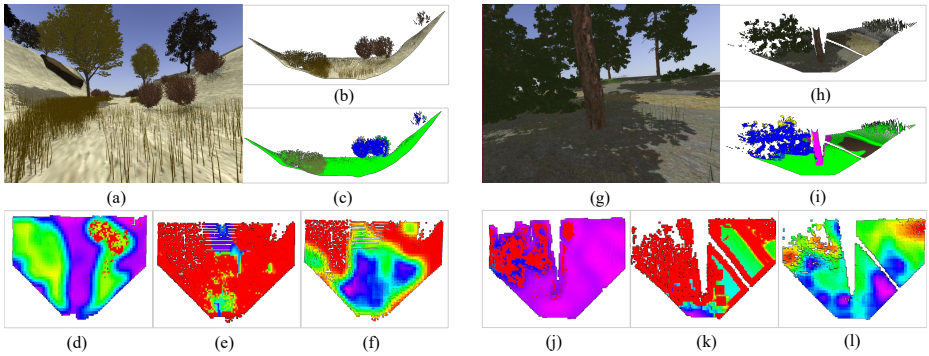

图 4：Costmap 预测比较。 (a)和(g)是机器人的前视图。 (b) 和 (h) 显示 RGB-D 点云。 (c) 和 (i) 显示语义点云。 (d)和(j)是我们的方法预测的成本图，(e)和(k)是TNS，(f)和(l)是HDIF。彩虹色可视化可遍历性成本，其中红色为 0，紫色为 1。

Trav. Accuracy: 可遍历区域的准确性。
All Accuracy: 地图所有网格的精度。
ROC (Receiver Operation Curve): 我们将超过0.5的成本设置为1，其余设置为0作为二元分类，并使用ROC通过真阳性率和假阳性率来表示性能。

MSE (Mean Squared Error): 我们计算连续预测和真实标签之间的平均距离，以估计预测的质量。

表 1：成本图比较结果

Scene	Method	Trav. Acc ↑	aAcc ↑	AUC ↑	MSE ↓
hill	TNS [11]	86.34	86.12	0.894	**0.117**
	HDIF [19]	14.80	55.95	0.695	0.662
	ours	**92.39**	**91.52**	**0.897**	0.149
forest	TNS [11]	40.73	42.07	**0.920**	0.405
	HDIF [19]	2.56	5.00	0.795	0.463
	ours	**99.07**	**97.48**	0.914	**0.0581**

表1显示了两种场景下costmap预测性能的比较。我们的方法在准确性和 MSE 方面具有更好的性能。图 5 表明我们的方法在 AUC 上的表现与 TNS 类似，均优于 HDIF。 TNS提前将语义类别分为可遍历和不可遍历的地形，因此它比我们的有一点优势。结果

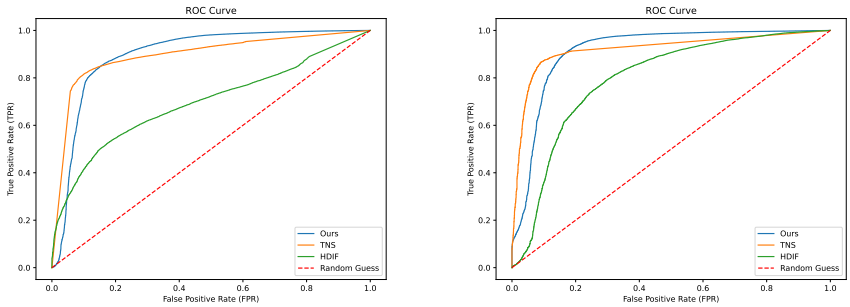

(a) hill (b) forest

图 5：ROC 图。我们根据两条基线和我们的方法绘制 ROC。 (a) 是山地场景的结果，(b) 是森林场景的结果。

成本图比较验证了我们对可遍历性成本的定义是合理的，并且我们的成本图预测是准确的。

3.4 Navigation Evaluation

我们验证越野环境中自主导航的成本图，并将性能与两个基线进行比较。由当前帧的RGB图像、深度图像和里程数据生成实时成本图。我们将代价图的输出点云与无碰撞路径规划算法相结合来进行局部路径规划[27]。

我们在每个场景中设计了 8 个试验，并使用以下指标 [15] 来评估导航的性能：

Success Rate ($R_{success}$): 机器人实现目标的比例。

Normalized Trajectory Length ($\bar{L}$): 所有成功试验的起点和目标之间的欧几里得距离标准化的轨迹长度。

Relative Time Cost (t_{rel}): 其他方法同样成功试验的时间成本与我们的比率。

Mean Stability ($\bar{S}$): 由 IMU 数据计算的可遍历性成本。我们计算 IMU z 轴线性加速度所有帧的平均遍历成本作为机器人在试验中的稳定性。

表2显示了两种场景下导航性能的比较。我们的方法在所有四个指标方面都优于其他方法。 HDIF 在森林场景中采用较短的轨迹，因为它直接朝目标行进，不考虑障碍物，并且其成功评估的轨迹比我们的要少。我们的方法较高的成功率表明，即使在不同和复杂的情况下它也是有效的，而其他方法则失败了。我们的方法较短的归一化轨迹长度表明，通过最大限度地减少不必要的运动并同时避免碰撞，该方法更加高效和精确。时间成本更少，条件稳定性更高

表 2：导航比较结果

Scene	Method	$R_{success}$ (%) ↑	$\bar{L}$ (→ 1)	t_{rel} ↓	$\bar{S}$ ↑
hill	TNS [11]	47.46	1.505	1.648	0.727
	HDIF [19]	29.28	2.647	3.658	0.712
	ours	**100**	**1.103**	**1.000**	**0.799**
forest	TNS [11]	40.48	1.407	1.890	0.758
	HDIF [19]	69.67	**1.090**	1.047	0.799
	ours	**96.82**	1.098	**1.000**	**0.882**

相同的预设速度表明我们的方法确保了更快但更安全和更稳定的导航。导航实验的轨迹如图6所示。

3.5 Further Analysis

我们使用角速度作为输入，并在网络中使用 LSTM。为了验证它们是否可以提高我们网络的性能，我们进行了一项消融研究。我们使用相同的数据集来训练三个网络：我们的网络、没有角速度 ω 的网络和没有 LSTM 的网络。我们比较验证集和测试集中三个学习得最好的模型。表3显示角速度和LSTM对于网络的损失都有改善。

表 3：网络损耗比较

Method	Val. Loss ($\times 10^{-2}$)	Test Loss ($\times 10^{-2}$)
Ours	**5.59**	**6.25**
Ours w/o ω	6.03	7.42
Ours w/o LSTM	6.27	6.56

4 Conclusions

我们提出了一种成本图预测系统，该系统使用学习方法来识别机器人与不同地形之间的交互，以便在越野环境中进行自主导航。考虑到 IMU 数据和机器人风险，我们引入了一种新颖的可遍历性成本标签。我们的方法将表面的语义和几何信息以及机器人的速度作为输入，然后输出连续的可遍历性成本图。与之前的工作相比，我们证明了我们的成本图可确保复杂越野场景的安全稳定导航。未来，将进行硬件实验以在现实世界中的机器人平台上验证该系统，并考虑对腿式机器人等其他车辆的适应。

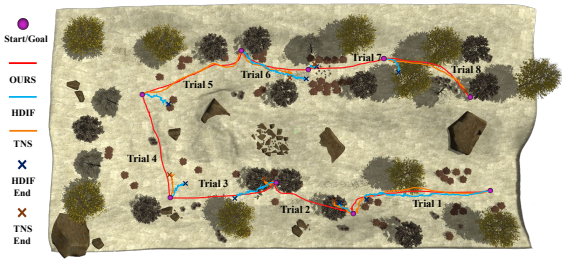

(a) hill

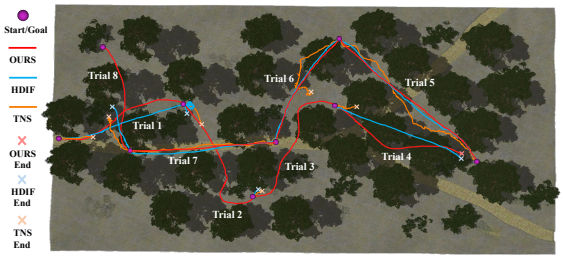

(b) forest

图 6：导航实验。紫色点是试验的起点和目标。 (a) 是山丘场景的结果，(b) 是森林。红色轨迹是我们的轨迹，橙色轨迹是 TNS 轨迹，蓝色轨迹是 HDIF 轨迹。

Acknowledgement

该工作得到了国家自然科学基金委（NSFC）62273229号和智慧城市北斗时空数字基地建设及应用产业化（HCXBCY-2023-020）的部分支持。

References

1. Zürn J、Burgard W、Valada A。来自无监督声学特征学习的自监督视觉地形分类。 IEEE 机器人学报，2020，37(2)：466-481。 2. Vulpi F、Milella A、Marani R 等人。用于自主机器人深度地形分类的循环神经网络和卷积神经网络。土地力学杂志，2021，96：119-131。 3. Maturana D、Chou P W、Uenoyama M 等。用于自主越野导航的实时语义映射。现场和服务机器人：第 11 届国际会议的结果。施普林格国际出版，2018：335-350。 4. 孟晓，曹Z，梁S，等。基于高程格网图的可通行性分析地形描述方法国际先进机器人系统杂志，2018，15：1-12。 5. Fankhauser P、Bloesch M、Hutter M。具有不确定定位的移动机器人的概率地形测绘。 IEEE 机器人与自动化快报，2018，3(4)：3019-3026。

6.Hosseinpoor S、Torresen J、Mantelli M 等人。移动机器人语义地形分割的可穿越性分析。 2021年IEEE第17届自动化科学与工程国际会议（CASE）。 IEEE，2021：1407-1413。 7. Dabbiru L、Sharma S、Goodin C 等人。使用语义分割的越野环境中的可通行性映射。自主系统：2021 年车辆和基础设施的传感器、处理和安全。SPIE, 2021, 11748: 78-83。 8. Seo J，Sim S，Shim I。仅通过自我监督学习越野地形穿越能力。 IEEE 机器人与自动化快报，2023 年。 9. Frey J、Mattamala M、Chebrolu N 等人。野外视觉导航的快速可遍历性估计。 arXiv 预印本 arXiv:2305.08510, 2023. 10. Wu Q, Xu X, Chen X, et al. 360-VIO：使用 360° 相机的稳健视觉惯性里程计。 IEEE Transactions on Industrial Electronics, 2024, 71(9): 11136-11145。 11.guan, z.he,r.song,d.manocha 和 l.zhang,TNS：自动挖掘机的地形可通行性地图和导航系统。机器人学论文集：科学与系统，2022 年。 12. Leung T H Y、Ignatyev D、Zolotas A。越野环境中的混合地形可穿越性分析。 2022 年第八届自动化、机器人与应用国际会议（ICARA）。 IEEE，2022：50-56。 13. Fan D D、Agha-Mohammadi A A、Theodorou E A。学习风险意识成本图以在具有挑战性的环境中实现可遍历性。 IEEE 机器人和自动化快报，2021，7(1)：279-286。 14.蔡X，埃弗雷特M，芬克J，等。通过学习的速度分布图进行风险感知越野导航。 2022 年 IEEE/RSJ 智能机器人与系统国际会议 (IROS)。 IEEE，2022：2931-2937。 15. Sathyamoorthy A J、Weerakoon K、Guan T 等人。 Terrapn：使用在线自我监督学习的非结构化地形导航。 2022 年 IEEE/RSJ 智能机器人与系统国际会议 (IROS)。 IEEE，2022：7197-7204。 16.Waibel G G、Löw T、Nass M 等。道路有多崎岖？用于局部和全局路径规划的地形可穿越性估计。 IEEE 智能交通系统学报，2022 年，23(9)：16462-16473。 17. Seo J、Kim T、Kwak K 等人。 Scate：非结构化环境中自监督可遍历性估计的可扩展框架。 IEEE 机器人与自动化快报，2023，8(2)：888-895。 18. Yao X，Zhang J，Oh J.Rca：通过自我监督学习实现舒适感知视觉导航。 2022 年 IEEE/RSJ 智能机器人与系统国际会议 (IROS)。 IEEE，2022：7847-7852。 19. Castro MG，Triest S，Wang W，等。感觉如何？用于越野车辆可通行性的自监督成本图学习。 2023 年 IEEE 机器人与自动化国际会议 (ICRA)。 IEEE，2023：931-938。 20. Aranburu A. IMU 数据处理，使用智能耳机识别日常生活活动。加州大学圣克鲁斯分校，2018 年。21. Nirmal K、Sreejith A G、Mathew J 等人。基于 IMU 的姿态传感器的噪声建模和分析：通过滤波和传感器融合提高性能。望远镜和仪器的光学和机械技术的进步 II。国际光学工程学会，2016，9912：2138-2147。 22. Majumdar A，Pavone M。机器人应该如何评估风险？走向机器人风险公理化理论。机器人研究：第 18 届国际研讨会 ISRR。施普林格国际出版，2020：75-84。 23. Poudel R P K，Liwicki S，Cipolla R。Fast-scnn：快速语义分割网络。 arXiv 预印本 arXiv:1902.04502, 2019。

24. 何凯，张旭，任胜，等。用于图像识别的深度残差学习。 IEEE 计算机视觉和模式识别会议 (CVPR) 会议论文集，2016 年：770-778。 25. Graves A，Graves A。长短期记忆。使用循环神经网络进行监督序列标记，2012：37-45。 26. Sánchez M、莫拉莱斯 J、Martı́nez J L 等。通过凉亭模拟自动注释自然环境中地面移动机器人的数据集。传感器, 2022, 22(15): 5599. 27. 张杰, 胡 C, Chadha RG, 等。 Falco：基于可能性的快速防撞，并扩展到人工引导导航。现场机器人学报, 2020, 37(8): 1300-1313。