5202 ceD 13]OR.sc[1v15642.2152:viXra

具有深度强化学习的混合运动规划用于移动机器人导航

Yury Kolomeytsev 莫斯科国立罗蒙诺索夫大学计算数学与控制论系 yury.kolomeytsev@gmail.com

Dmitry Golembiovsky 莫斯科国立罗蒙诺索夫大学计算数学与控制论系

抽象的

在复杂、动态环境中运行的自主移动机器人面临着双重挑战，即在具有静态障碍物的大规模、结构多样的空间中导航，同时与各种移动主体安全地交互。传统的基于图的规划器擅长远程寻路，但缺乏反应性，而深度强化学习（DRL）方法表现出强大的碰撞避免能力，但由于缺乏全局背景，往往无法达到遥远的目标。我们提出 *Hybrid Motion Planning with Deep Reinforcement Learning* (HMP-DRL)，这是一个弥补这一差距的混合框架。我们的方法利用基于图的全局规划器来生成一条路径，该路径通过状态空间和奖励函数中编码的一系列检查点集成到本地 DRL 策略中。为了确保社会合规性，本地规划者采用实体感知奖励结构，根据周围代理的语义类型动态调整安全边际和惩罚。我们通过在从真实世界地图数据派生的真实模拟环境中进行广泛测试来验证所提出的方法。综合实验表明，在机器人导航的关键指标（成功率、碰撞率和到达目标的时间）方面，HMP-DRL 始终优于其他方法，包括最先进的方法。总的来说，这些发现证实，将长期路径引导与语义感知的本地控制相结合，可以显着提高复杂的以人为中心的环境中自主导航的安全性和可靠性。

Keywords 机器人 · 强化学习 · 运动规划 · 路径规划 · 防撞 · 深度学习 · 机器人导航

1 简介

移动机器人正在迅速从受控工业环境过渡到复杂的、以人为中心的环境。旨在帮助人类的机器人越来越多地部署在各个领域，包括制造和工业自动化、农业、太空探索、医疗保健、家庭援助、物流和交付以及设施和公共空间服务[1-3]。自主移动机器人结合了移动平台、传感器和机载智能，可以实时适应动态环境，而不是依赖于自动导引车 (AGV) 等固定基础设施。这些系统的核心功能是自主导航，它允许机器人独立操作、感知环境并安全行动以实现指定目标，而无需操作员监督或控制。

自主机器人的典型应用包括仓库和工厂的物料搬运；医院后勤（例如，运输实验室样本、血液成分和药物）；服务机器人在

商业建筑和酒店的室内送货和访客引导；自主清洁；保安巡逻、检查；杂货、膳食和包裹的最后一英里城市配送[3-5]。
此类部署的核心挑战是双重的：穿越大规模、结构复杂的环境（全局规划），同时与不同的动态代理安全交互（局部规划和避免碰撞）。考虑在城市环境中运行的人行道送货机器人 [6]：它必须行驶长达几公里，穿越人行道和人行横道等不同的表面，同时考虑建筑物、公交车站、花坛和路缘石等静态障碍物。传统的基于搜索的规划器（例如，A*、Dijkstra）擅长使用静态地图在这些长距离上找到最佳路径，但很难对未映射的移动实体做出流畅的反应。

相反，深度强化学习（DRL）方法在局部防撞和人群导航方面表现出了卓越的性能[7-9]。然而，纯粹的 DRL 方法通常缺乏全局背景。当应用于具有复杂几何形状的大型环境时，它们通常无法达到遥远的目标，由于缺乏全局指导而陷入局部极小值。

此外，安全导航需要的不仅仅是将障碍物视为通用几何形状。机器人必须以符合社会规范的方式进行导航，并考虑到周围环境实体的语义多样性。儿童、骑自行车的人、成人和混凝土墙都会施加不同的安全约束和运动模式。以与静态障碍物相同的安全裕度对待易受伤害的行人不足以实现符合社会要求的导航。

为了应对这些挑战，我们引入了 *Hybrid Motion Planning with Deep Reinforcement Learning* (HMP-DRL)，这是一种新颖的混合方法，它弥合了全局路径规划和具有实体感知碰撞避免的局部运动规划之间的差距。我们的方法利用全局路径规划器在复杂的静态环境中提供长期指导（处理路缘石、墙壁和限制区域），而本地 DRL 策略则处理与动态代理和静态实体的即时交互。这种分解使机器人能够在不迷路的情况下导航数公里，同时展示复杂的、实体感知的防撞功能，以确保安全导航。

我们的主要贡献如下：

- 我们提出了一种混合运动规划方法，它将基于图的全局搜索与基于深度强化学习的局部规划相结合。这种混合结构使机器人能够利用地图信息到达远处的目标，同时保持动态避障所需的反应性。
- 我们设计了一个奖励函数，鼓励机器人遵循全局路径并最大限度地减少旅行时间。该功能使用语义意识，根据机器人遇到的代理或障碍物的类型对机器人进行不同的惩罚。具体来说，所需的安全距离和碰撞惩罚会根据实体类型动态调整，从而实现更安全、更符合社会规范的行为。
- 我们引入了一个训练和测试环境，旨在模拟具有各种静态和动态障碍的真实户外环境。我们的实验结果表明，这种新方法始终优于标准导航技术，包括最先进的方法。

2 相关工作

机器人导航研究已经从传统的基于规则的方法和经典规划算法发展到基于学习的方法，最近的工作重点是人群导航和结合全局和局部规划的混合架构。

社会力模型 (SFM) [10] 和最优相互碰撞避免 (ORCA) [11] 等经典方法使用手工制定的交互规则来避免碰撞。 SFM 应用吸引力和排斥力，但容易出现局部极小值； ORCA 在相互假设下使用速度约束，期望所有智能体平等合作以避免碰撞——这种假设在行人不可预测的现实环境中很少遇到。这两种方法都会产生短视或不自然的行为，并且很难在不同的社会环境中推广。

基于学习的方法作为手工制定规则的替代方案而受到广泛关注。模仿学习方法从期望行为的演示中得出导航策略。例如，[12]将行为克隆与生成对抗性模仿学习（GAIL）相结合，开发出一种直接对原始深度图像进行操作的策略，绕过了显式的行人跟踪。 [13] 应用最大熵逆 RL 将人类导航建模为捕获离散决策（例如，向左或向右通过）和连续轨迹方差的混合分布。然而，这些方法在很大程度上取决于演示的质量和规模，收集这些方法可能需要消耗大量资源，并且可能会限制对新场景的推广。

深度强化学习（DRL）提供了一种替代方法，将导航视为顺序决策问题。 CADRL [7] 通过训练一个价值网络来制定分散式多智能体碰撞避免，该价值网络根据机器人及其邻居的联合状态估计到达目标的时间，实现比 ORCA 更快的导航，同时保持实时可实现性。 SA-CADRL [14] 通过规范诱导奖励来扩展这一想法，这些奖励可以惩罚违反社会惯例的行为（例如，在错误的一方传递），以及具有权重共享和最大池化的对称网络架构来处理可变数量的代理，以牺牲一些效率来换取符合社会规范的行为。为了更好地扩展到密集人群，LSTM-RL [15] 使用循环网络对任意数量的相邻代理进行编码，从而显着降低拥挤场景中的失败率。 SARL [8] 通过基于注意力的价值网络进一步改进人群建模，该网络共同推理人与机器人和人与人的交互，增强对人群动态的预期。最近，[16]提出了一个时空价值网络和一个危险感知奖励结构，它明确地推理行人速度和危险区域，以提高安全性和舒适度。最近，EB-CADRL [9]将实体类型感知引入状态表示和奖励函数中，为各种代理类型提供了差异化的安全边际。该方法证明了密集人群中易受攻击的代理具有卓越的安全性，并通过并行经验收集实现了显着的训练加速。

纯 DRL 方法的一个显着限制是它们主要关注局部碰撞避免，并且通常在小型有界环境中进行训练和评估。当应用于大规模地图或远程导航任务时，这些方法无法达到遥远的目标，常常由于缺乏全局路径引导而陷入困境或表现出次优行为。此外，他们忽略了静态环境结构，例如建筑物、墙壁和地形边界。为了弥补这一差距，最近的研究探索了将经典路径规划与基于学习的局部控制相结合的混合方法。
基于 DRL 的混合方法将全球规划者与学习到的本地政策相结合。 SARL* [17] 通过使用 Dijkstra 算法进行动态局部目标设置和基于地图的安全行动空间来扩展 SARL；然而，它在每个时间步都会重建路径（计算效率低下），并且依赖于基于规则的动作过滤而不是学习的避障。 G2RL [18] 将静态 A* 路径作为引导通道纳入 DRL 状态空间，但当障碍物阻挡路径时，固定的全局路径就会出现问题，并且粗离散化（200 × 200 网格上的 4 向动作）限制了现实世界的适用性。同样，[19] 将 A* 与 DQN 代理集成用于自动驾驶，展示了更快的收敛速度，但缺乏行人意识并使用离散动作，导致控制不稳定。 GDAE [20] 将基于边界的航路点选择与 TD3 结合起来用于未知环境，但不利用全局路径并且缺乏动态障碍物处理。 VDPF-TD3[21]使用TD3来优化修改后的势场力之间的平衡，有效地逃避局部最优，但依赖于几何障碍物表示并且缺乏现实世界的验证。

经典的混合规划器将全局路径规划与反应性局部控制相结合。钟等人。 [22] 提出了具有风险意识成本的 Safe A* 与自适应窗口方法相结合，而 IAB-A* [23] 则引入了与 DWA 集成的 B 样条平滑的双向搜索。这两种方法都实现了计算效率，但严重依赖于手动调整的参数，并且不区分障碍物类型。 RC-Map 方法 [24] 使用矩形分解进行快速拓扑规划（网格方法为 10 毫秒 vs 740 毫秒），但会产生次优路径并且难以应对非正交环境。
基于采样的混合提高了路径搜索效率。 RRTstar-RL [25] 用学习的概率分布取代了均匀的 RRT* 采样，实现了 28% 的短路径和 2 倍的加速，但需要大量的训练数据，并且缺乏动态避障机制。

我们的 HMP-DRL 方法通过以下方式解决了这些限制：(i) 计算每集的单个全局路径，并在奖励和网络输入中使用其检查点以低成本提供路径指导；(ii) 通过奖励直接通过细粒度的离散动作空间学习避免碰撞，该空间仍可实现平滑运动；(iii) 对状态和奖励中的实体类型进行编码，以实现具有依赖于类型的安全裕度的社会兼容导航。

3 问题表述

我们解决了机器人在充满各种实体（包括动态代理和静态障碍物）的动态环境中实现目标的自主导航问题。这个问题可以表述为马尔可夫决策过程（MDP）。机器人必须以符合社会规范的方式导航，在达到目标的同时避免碰撞。我们根据可观察和不可观察的组件来定义每个代理（机器人或环境实体）的状态：

- Observable states: position $\mathbf{p} = [p_x, p_y]$, velocity $\mathbf{v} = [v_x, v_y]$, and radius r.
- Unobservable states: goal position $\mathbf{g} = [g_x, g_y]$, preferred speed v_{pref}, and heading angle θ.

在环境中行动时，机器人知道其可观察和不可观察状态，以及所有实体的可观察状态。我们使用[7]和[15]中描述的以机器人为中心的参数化，其中机器人位于原点，x轴与机器人的目标方向对齐。将 e_i 表示为实体 i 的一种类型。机器人的状态和第 i 个实体在 t 时刻的可观察状态可以表示为：

$$\begin{aligned} \mathbf{s}_t^r &= [d_g, v_x, v_y, r, v_{\text{pref}}, \theta], \\ \mathbf{s}_t^{io} &= [p_x^i, p_y^i, v_x^i, v_y^i, r^i, d^i, r^i + r, e_i], \end{aligned} \tag{1}$$

其中$d_g = \|\mathbf{p}_t - \mathbf{g}\|_2$是从机器人到目标的距离，$d^i = \|\mathbf{p}_t - \mathbf{p}_t^i\|_2$是从机器人到第$i$实体的距离。

机器人可以在每个时间步获取自己的状态和其他智能体的可观察状态。 t 时刻的联合状态定义为：

$$\mathbf{s}_t^j = [\mathbf{s}_t^r, \mathbf{s}_t^{1o}, \mathbf{s}_t^{2o}, \ldots, \mathbf{s}_t^{no}]. \tag{2}$$

机器人的速度 $\mathbf{v}_t$ 由导航策略中的动作命令 $\mathbf{a}_t$ 确定，即 $\mathbf{v}_t = \mathbf{a}_t = \pi(\mathbf{s}_t^j)$。

奖励函数 $R(\mathbf{s}_t^j, \mathbf{a}_t)$ 定义为从当前状态 $\mathbf{s}_t^j$ 和操作 $\mathbf{a}_t$ 到标量值的映射，该标量值表示在状态 $\mathbf{s}_t^j$ 下采取操作 $\mathbf{a}_t$ 的直接好处。正式：

$$R(\mathbf{s}_t^j, \mathbf{a}_t) = r_t, \tag{3}$$

其中 r_t 是在时间步 t 收到的奖励。

我们的目标是找到最大化预期奖励的最优策略 $\pi^*(\mathbf{s}_t^j)$。

最优值函数由[26]给出：

$$V^*(\mathbf{s}_t^j) = \sum_{\tilde{t}=t}^{T} \gamma^{\tilde{t} \cdot v_{\text{pref}}} R_{\tilde{t}}(\mathbf{s}_{\tilde{t}}^j, \pi^*(\mathbf{s}_{\tilde{t}}^j)), \tag{4}$$

其中 $\gamma \in (0, 1)$ 是　折扣因子和 T 是情节的时间步长　　e 结束。

使用值迭代，得出最优策略为：

$$\begin{aligned} \pi^*\left(\mathbf{s}_t^j\right) = \arg\max_{\mathbf{a}_t \in \mathbf{A}} \Bigg[& R\left(\mathbf{s}_t^j, \mathbf{a}_t\right) + \gamma^{\Delta t \cdot v_{\text{pref}}} \cdot \\ & \int_{\mathbf{s}_{t+\Delta t}^j} P\left(\mathbf{s}_{t+\Delta t}^j \mid \mathbf{s}_t^j, \mathbf{a}_t\right) V^*\left(\mathbf{s}_{t+\Delta t}^j\right) d\mathbf{s}_{t+\Delta t}^j \Bigg], \end{aligned} \tag{5}$$

其中Δt是时间步持续时间，$R(\mathbf{s}_t^j, \mathbf{a}_t)$是奖励函数，$\mathbf{A}$是动作空间，$P(\mathbf{s}_{t+\Delta t}^j \mid \mathbf{s}_t^j, \mathbf{a}_t)$是转移概率。

4 提议的方法

在本节中，我们将介绍我们的新方法，称为深度强化学习混合运动规划（HMP-DRL）。 HMP-DRL 将基于图形的全局路径规划器与本地深度强化学习策略相结合，实现在具有静态和动态障碍的复杂环境中进行远程导航，同时保持实体感知碰撞避免，从而与动态代理进行安全、符合社交要求的交互。

4.1 全局规划

全局路径规划确定已知或部分已知环境中从起始位置到目标的最佳无碰撞路径。核心思想是构建可导航空间的图形表示，然后应用搜索算法来找到通过该图形的最佳路径。全局规划器考虑地图和已知的静态障碍物。地图上不存在的动态代理和静态障碍物在全局规划时是未知的，但在导航过程中由机器人的传感器检测到，并由本地规划器实时处理。

图构造方法。全球规划的一个基本方面是构建一个捕获自由空间连通性的图表。可以使用不同的方法来构建此类图，每种方法都有独特的优点：

- *Occupancy Grids.* 环境被离散化为规则的单元格网格，其中每个单元格根据障碍物的存在被标记为已占用或空闲。节点放置在空闲单元的中心，边缘连接相邻节点，从而实现基于网格的寻路算法。这种方法简单明了，广泛应用于 2D 环境，并与占用地图等传感器数据无缝集成。
- *Navigation Meshes.* 可用空间可以使用单元分解方法划分为一组连接的多边形，最常见的是三角形或四边形[27]。与均匀网格不同，基于网格的表示（例如不规则三角形网格（ITM）和变化尺寸 ITM（VITM））可以更好地符合障碍物边界。特别是，VITM 能够在狭窄通道中进行局部细化，同时在开放区域中保持较粗糙的单元，从而在几何保真度和计算复杂性之间提供平衡[28]。四边形（QUAD）表示虽然在近似不规则或倾斜障碍物边界方面不太灵活，但提供了具有可预测的邻居关系的简单且结构化的拓扑。当应用膨胀层来考虑机器人尺寸时，四边形网格通常不如固定尺寸的三角形网格敏感，但除非使用精细分辨率，否则它们可能无法在狭窄或杂乱的环境中保持连接性。相比之下，不同尺寸的三角形网格在通货膨胀下表现出更大的鲁棒性，特别是在通道狭窄、在线地图更新或具有不同尺寸的多个机器人的环境中，使它们更适合此类场景[29]。
- *Voronoi Diagrams.* 给定一个带有多边形障碍物边界的矢量化地图，可以构建自由空间的广义维诺图（GVD）[30, 31]。 GVD 边缘由与两个或多个障碍物等距的点组成，形成可导航空间的稀疏骨架。 Voronoi 顶点（边相交的地方）充当节点，边本身充当规划图中的路径。基于 Voronoi 的图计算的路径可局部最大化与障碍物的间隙，从而提高杂乱或狭窄环境中的安全性，尽管与最短路径方法相比通常会增加路径长度。 • *Visibility Graphs.* 在具有多边形障碍物的环境中，节点可以表示起点、目标和障碍物顶点，边连接相互可见的对[32, 33]。这会产生欧几里得距离的最短路径，但可能会产生过于靠近障碍角的轨迹。

Algorithm 1 A* Algorithm

Require: occupancy map, start node s, goal node g, neighbor function $\mathcal{N}(\cdot)$, edge cost $c(\cdot,\cdot)$, heuristic $h(\cdot)$
Ensure: shortest path from s to g, if it exists

```
openSet ← {s}, closedSet ← ∅
cameFrom ← empty map
gScore(s) ← 0, fScore(s) ← h(s)
while openSet is not empty do
    n ← arg min_{x∈openSet} fScore(x)
    if n = g then
        return RECONSTRUCTPATH(cameFrom, n)
    end if
    remove n from openSet; add n to closedSet
    for each neighbor m ∈ N(n) do
        if m in closedSet or grid cell m is occupied then
            continue
        end if
        tentative ← gScore(n) + c(n, m)
        if m not in openSet then
            add m to openSet
        else if tentative ≥ gScore(m) then
            continue
        end if
        cameFrom(m) ← n
        gScore(m) ← tentative
        fScore(m) ← gScore(m) + h(m)
    end for
end while
return failure
function RECONSTRUCTPATH(cameFrom, n)
    path ← [n]
    while cameFrom contains n do
        n ← cameFrom(n)
        prepend n to path
    end while
    return path
end function
```

所有四种图构建方法都适用于我们的 HMP-DRL 框架；选择取决于可用的地图表示和所需的路径特征。当地图源自 SLAM 或语义分割管道时，占用网格通常是首选，因为它们简单且与传感器数据直接兼容。导航网格为具有复杂障碍物形状的大型开放区域提供了有效的表示，实现了穿过凸区域的平滑路径，同时自然地处理不同的地形成本。当具有多边形边界的矢量图可用并且与障碍物的最大间隙优先于路径长度时，基于 Voronoi 的图是有利的。可见性图产生最短的欧几里德路径，但可能需要额外的安全裕度，因为轨迹可以靠近障碍物角落。

搜索算法。我们采用 A* 算法 [34] 作为全局规划器来计算构造图上起点和目标之间的最短无碰撞路径。 A* 将从一开始的精确路径成本与对目标的启发式估计相结合，并且在给定可接受且一致的启发式（例如欧几里德距离）的情况下，它既完整又最优，通常比 Dijkstra 算法扩展的节点少得多 [35]。相反，广度优先搜索（BFS）[36]仅在未加权图上是最佳的

并探索许多不相关的状态；Dijkstra 算法[35]在非负成本下是最优的，但缺乏启发式指导，使其效率较低；像 D* [37] 这样的增量规划器在成本变化时可以有效地更新路径，但会增加不必要的实现复杂性和静态全局场景中不需要的计算开销 [38]。

A*算法的操作可以描述如下。维护一个开放列表，按优先级 $f(n) = g(n) + h(n)$ 排序，其中 g 是从起始点到节点 n 的路径成本，h 启发式估计从 n 到目标的成本。在每一步中，具有最小 f的节点被扩展，邻居被放松，并且重复该过程直到选择目标；然后使用反向指针重建最佳路径。在网格上，我们使用占用检查来避免静态障碍物，并使用距离启发式来保持最优性。在我们的实现中，我们使用 8 个连接的网格，其中每个单元的邻居集 $\mathcal{N}(n)$ 包括所有 8 个相邻单元（4 个正交邻居和 4 个对角邻居），从而实现对角移动路径。为了完整起见，我们提供了算法 1 中 A* 过程的详细伪代码。

实验设置。在我们的实验中，机器人在城市街道环境中的户外运行（例如送货机器人、安全巡逻机器人和清洁机器人）。我们使用占用网格方法：地图覆盖 200 m x 200 m 的面积，并离散化为 10 cm x 10 cm 的单元。占用网格由街道语义层组成：建筑物、草坪、空地、运动场和其他不可通行或限制区域等区域被标记为占用（禁止移动），而可通行路段和人行道被标记为自由空间。

我们实验中使用 A* 算法构建的路径示例如图 1 所示。

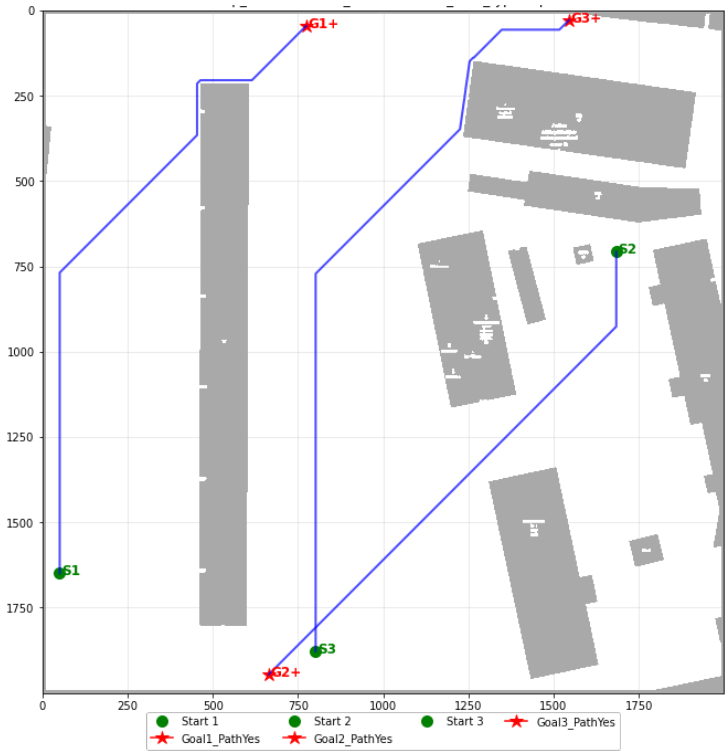

图 1：在我们的实验中，A* 算法针对不同的起始和目标对构建全局路径的三个示例。被占用的牢房被标记为灰色，在这一集中代表了城市中各种大小和形状的住宅和非住宅建筑。

4.2 地方规划

我们的本地规划基于 [9] 中描述的 EB-CADRL 方法，但进行了增强，将全局路径纳入模型和奖励函数中。局部规划者考虑静态和动态障碍，并旨在遵循全局路径。

为了将全球规划与本地决策联系起来，我们在全球路径上放置了一组检查点。检查点彼此之间的距离为 D。第一个检查点位于全局路径上，距起点的距离为 D。检查点可以有不同的形状和大小。在我们的实验中，我们使用具有固定半径的圆形点。这些检查点对本地规划者是可见的，并且包含在奖励函数和神经网络 V 中，鼓励沿着全局路径取得进展。

图 2 描绘了 HMP-DRL 模拟期间模拟器的快照。在其中，我们可以看到检查点（绿色虚线圆圈）如何沿着全局路径定位。

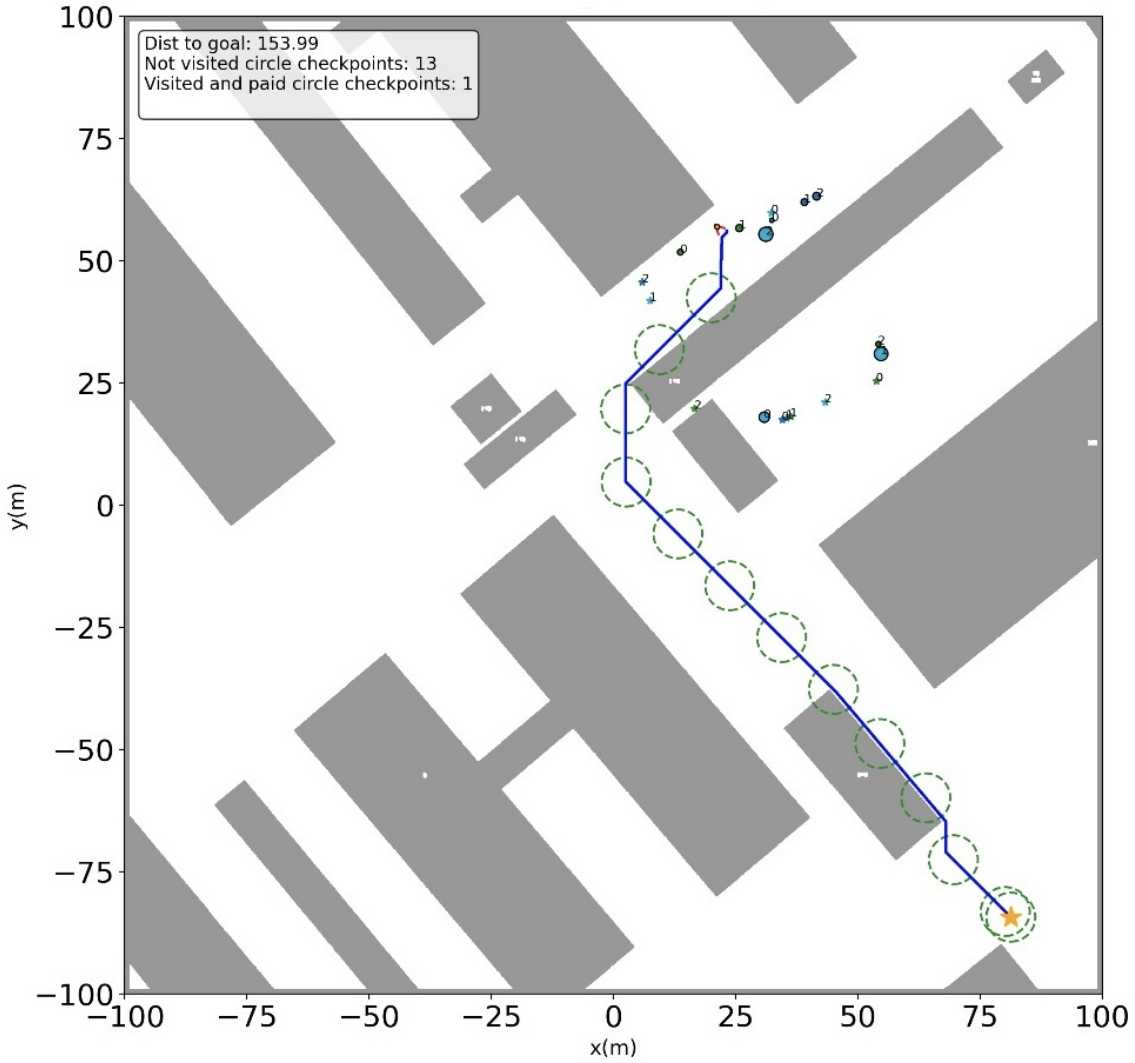

图 2：HMP-DRL 方法模拟过程中的模拟器快照。蓝色折线是全局路径。绿色圆圈是检查点。灰色物体是城市中的住宅和非住宅建筑。剩下的物体是机器人和它周围的动态代理。

4.3 奖励功能

我们的奖励函数 $R(t)$ 包含三个附加组件：针对情节结束事件（达到目标、碰撞或超时）的最终奖励 $R_{\text{terminal}}(t)$，针对全局路径进展的检查点奖励 $R_{\text{checkpoint}}(t)$，以及针对邻近违规的不适惩罚 $R_{\text{discomfort}}(t)$。

在定义这些组件之前，我们建立用于测量机器人实体距离的符号。考虑一个具有 N 实体类型 $\mathcal{E} = \{e_1, \ldots, e_N\}$ 的环境。令 $d(e_i, t)$ 表示机器人与任何 e_i 类型实体在区间 $[t - \Delta t, t]$ 上的最小距离。我们定义：

$$i^*(t) = \arg \min_{i \in \{1,\ldots,N\}} d(e_i, t), \tag{6}$$

其中$i^*(t)$是最接近机器人的实体类型的索引。为简洁起见，我们写为 i^* 而不是 $i^*(t)$。到任何实体的最小距离是$d_{\text{min}}(t) = d(e_{i^*}, t)$，$e_{i^*} \in \mathcal{E}$是相应的实体类型。当 $d_{\text{min}}(t) \leq 0$ 时发生冲突。

当机器人位于 A* 路径上先前未访问过的检查点内时，机器人会收到检查点奖励 $R_{\text{checkpoint}}(t)$。检查点可能有不同的形状和大小。例如，我们可以使用圆形检查点，当机器人到检查点中心的欧几里德距离小于或等于检查点半径时，机器人就会收到奖励。每个检查点最多支付一次（无重复支付）。

函数$R_{\text{time}}(t)$代表时间奖励：

$$R_{\text{time}}(t) = \begin{cases} 1 & \text{if } t < t_{\text{pref}} \\ \frac{t_{\text{max}} - t}{t_{\text{max}} - t_{\text{pref}}} & \text{if } t_{\text{pref}} \leq t \leq t_{\text{max}} \\ 0 & \text{otherwise} \end{cases} \tag{7}$$

其中 t_{pref} 是达到目标的首选持续时间，t_{max} 是达到目标的最大允许时间。

令 d_{max} 为到目标的最大距离，即机器人在时间 $t = 0$ 时的起始位置与目标位置之间的欧几里德距离。令$d_g(t)$ 为t 时刻到目标的距离。那么邻近奖励可以表示为：

$$R_{\text{prox}}(t) = 1 - \frac{d_g(t)}{d_{\text{max}}}. \tag{8}$$

将 $R_{\text{coll}}(e_i)$ 定义为与涉及 e_i 类型实体的碰撞相关的惩罚，将 R_{success} 定义为达到目标的奖励。

令 $d_{\text{disc}}(e_i)$ 为 e_i 类型实体的不适距离，$p_{\text{disc}}(e_i)$ 为 e_i、$i = 1, \ldots, N$ 类型实体的不适惩罚因子。

我们的奖励函数定义为三个组成部分的总和：

$$R(t) = R_{\text{terminal}}(t) + R_{\text{checkpoint}}(t) + R_{\text{discomfort}}(t). \tag{9}$$

终端奖励处理互斥的结束事件，并结合超时和碰撞情况的邻近奖励：

$$R_{\text{terminal}}(t) = \begin{cases} R_{\text{prox}}(t) & \text{if } t \geq t_{\text{max}} \text{ and } \|\mathbf{p}_t - \mathbf{g}\|_2 > r \\ R_{\text{coll}}(e_{i^*}) + R_{\text{prox}}(t) & \text{else if } d_{\text{min}}(t) \leq 0 \\ R_{\text{success}} + R_{\text{time}}(t) & \text{else if } \|\mathbf{p}_t - \mathbf{g}\|_2 \leq r \\ 0 & \text{otherwise} \end{cases} \tag{10}$$

其中 r 是机器人的半径。接近奖励 $R_{\text{prox}}(t)$ 被添加到超时和碰撞情况中，以提供与机器人实现目标的进度成比例的学习信号，即使情节不成功结束也是如此。

检查站奖励鼓励沿着全球路径取得进展：

$$R_{\text{checkpoint}}(t) = \begin{cases} R_{\text{cp}} & \text{if } \mathbf{p}_t \in \mathcal{C}_k \text{ and } k \text{ is unvisited} \\ 0 & \text{otherwise} \end{cases} \tag{11}$$

其中$\mathcal{C}_k$表示检查点k (的区域，例如具有公差宽度)的圆形、矩形或线段，R_{cp}是检查点奖励值。每个检查点最多产生一次奖励。
不适奖励会惩罚与实体的接近度：

$$R_{\text{discomfort}}(t) = \begin{cases} (d(e_{i^*}, t) - d_{\text{disc}}(e_{i^*})) \cdot p_{\text{disc}}(e_{i^*}) \cdot \Delta t & \text{if } d(e_{i^*}, t) < d_{\text{disc}}(e_{i^*}) \text{ and } d_{\text{min}}(t) > 0 \\ 0 & \text{otherwise} \end{cases} \tag{12}$$

4.4 模型

我们的模型建立在[9]中描述的架构之上，将其扩展以合并来自全局路径的信息。基本架构使用注意力机制来处理不同数量的动态代理，而我们的扩展集成了 A* 路径中的检查点功能以提供全局指导。我们首先描述检查点特征提取和扩展自状态表示，然后介绍神经网络架构。

检查点特征提取。为了合并全局路径信息，我们从 A* 路径上即将到来的 K 检查点中提取特征。在每个时间步，我们必须确定使用哪些检查点作为输入特征。令 m 表示最近访问的检查点的索引（最初为 $m = -1$）。我们考虑两种选择起始检查点索引 s 的策略。 *Sequential selection*：最简单的方法将 $s = m +$ 设置为 1，始终选择紧随最后访问的检查点之后的 K 检查点。这确保了沿着路径的严格进展并提供一致的、确定性的特征。 *Nearest-first selection*：这种自适应方法在所有未访问的索引为 $i > m$ 的检查点中进行搜索，并选择最接近机器人当前位置的一个作为起点：$s = \arg\min_{i>m} \|c_i - \mathbf{p}\|_2$。当机器人偏离计划路径时，该策略可以提供更好的本地指导，因为它专注于最直接相关的检查点，而不是路径上可能遥遥领先的检查点。
顺序策略提供了简单性和稳定性，而最近优先策略以适度的计算成本提高了适应性。在这两种情况下，约束 $s > m$ 都会阻止机器人接收已访问过的检查点的特征，从而确保沿着全局路径前进。

令 $\mathcal{C} = \{c_s, c_{s+1}, \ldots, c_{s+K-1}\}$ 表示 K 所选检查点位置的集合。对于每个检查点 $c_k = (c_x^k, c_y^k)$，我们计算以机器人为中心的坐标系中的特征向量。
定义以机器人为中心的坐标系，使得 x 轴从机器人的当前位置指向目标。令 $\phi = \text{atan2}(g_y - p_y, g_x - p_x)$ 为旋转角度，其中 (p_x, p_y) 为机器人位置，(g_x, g_y) 为目标位置。对于每个检查点 c_k，我们计算：

$$\begin{aligned} \delta_x^k &= c_x^k - p_x, \quad \delta_y^k = c_y^k - p_y, \\ \tilde{\delta}_x^k &= \delta_x^k \cos\phi + \delta_y^k \sin\phi, \\ \tilde{\delta}_y^k &= \delta_y^k \cos\phi - \delta_x^k \sin\phi, \\ d^k &= \sqrt{(\delta_x^k)^2 + (\delta_y^k)^2}, \end{aligned} \tag{13}$$

其中 $(\tilde{\delta}_x^k, \tilde{\delta}_y^k)$ 是以机器人为中心的框架中的旋转偏移量，d^k 是到检查点 k 的欧几里得距离。

这 定义每个检查点的检查点特征向量 作为：

$$\mathbf{f}^k = [d^k, \tilde{\delta}_x^k, \tilde{\delta}_y^k, r_{\text{cp}}], \tag{14}$$

其中 r_{cp} 是检查点半径。完整的检查点特征表示是所有 K 检查点特征的串联：

$$\mathbf{f}_{\text{cp}} = [\mathbf{f}^1, \mathbf{f}^2, \ldots, \mathbf{f}^K]. \tag{15}$$

扩展的自状态。在基本 EB-CADRL 模型中，机器人在旋转坐标系中的自状态表示为 $\mathbf{s}^r = [d_g, v_{\text{pref}}, \theta, r, v_x, v_y]$，其中 d_g 是到目标的距离，v_{pref} 是首选速度，θ 是航向角，r 是机器人半径，(v_x, v_y) 是以机器人为中心的坐标系中的速度。
在我们的 HMP-DRL 模型中，我们通过合并检查点功能来扩展自状态：

$$\tilde{\mathbf{s}}^r = [d_g, v_{\text{pref}}, \theta, r, v_x, v_y, \mathbf{f}_{\text{cp}}], \tag{16}$$

导致维度 $6 + 4K$ 的扩展自状态。这种扩展的自我状态为模型提供了有关全局路径的明确信息，使其能够做出平衡局部碰撞避免与实现遥远目标的进展的决策。

实体状态嵌入。我们使用多层感知器（MLP）将扩展机器人状态 $\tilde{\mathbf{s}}^r$ 以及每个实体 i 的可观察状态嵌入到固定长度向量 g_i 中：

$$g_i = \phi_g(\tilde{\mathbf{s}}^r, \mathbf{s}^{io}; W_g), \tag{17}$$

其中 $\phi_g(\cdot)$ 是具有修正线性单元 (ReLU) 激活的嵌入函数，W_g 是嵌入权重。为了考虑不同类型的实体（例如成人、儿童、自行车），我们使用 one-hot 编码来表示每种代理类型。这些编码特征与代理的主要特征连接并传递到模型中。

然后将嵌入向量 g_i 输入到另一个 MLP 中，以获得机器人和实体 i 之间的成对交互特征：

$$h_i = \psi_h(g_i; W_h), \tag{18}$$

其中$\psi_h(\cdot)$是具有ReLU非线性的全连接层，W_h是网络权重。

社会关注汇集。为了处理不同数量的实体，我们使用社交注意力池模块[8]，该模块以数据驱动的方式学习每个邻居的相对重要性以及人群的集体影响。让 n 表示环境中的实体数量。交互嵌入 g_i 转换为注意力分数 α_i，如下所示：

$$g_m = \frac{1}{n}\sum_{k=1}^{n} g_k, \qquad \alpha_i = \psi_\alpha(g_i, g_m; W_\alpha), \tag{19}$$

其中g_m是通过平均池化所有个体获得的固定长度嵌入向量，$\psi_\alpha(\cdot)$是具有ReLU激活的MLP，W_α是权重。
给定成对交互向量 h_i 和每个邻居 i 的相应注意力分数 α_i，人群的最终表示是所有对的加权线性组合：

$$c = \sum_{i=1}^{n} \text{softmax}(\alpha_i) h_i, \tag{20}$$

其中 $\text{softmax}(\alpha_i) = \frac{e^{\alpha_i}}{\sum_{j=1}^{n} e^{\alpha_j}}$.

价值网络。使用人群 c 的紧凑表示和扩展的自我状态 $\tilde{\mathbf{s}}^r$，我们构建了一个规划模块，用于估计合作规划的状态值 v：

$$v = f_v(\tilde{\mathbf{s}}^r, c; W_v), \tag{21}$$

其中 $f_v(\cdot)$ 是具有 ReLU 激活的 MLP，W_v 是权重。我们将此价值网络表示为 V。
在我们的模型中，检查点特征被合并到扩展的自状态 $\tilde{\mathbf{s}}^r$ 中，然后在整个网络管道中使用它，从初始的成对嵌入 ϕ_g 到最终的值估计 f_v。这使得网络能够从第一层学习联合考虑动态避障和全局路径跟踪的表示。在训练过程中，网络学习在遵循全局路径（由检查点奖励引导）和避免动态障碍（由碰撞和不适惩罚引导）之间取得平衡。

4.5 算法HMP-DRL

HMP-DRL算法通过并行深度V学习将全局路径规划与局部强化学习相结合。训练过程并行运行多个episode，收集经验，并使用带有经验回放的时差学习和固定目标网络$\hat{V}$来更新价值网络 V。主训练循环如算法 2 所示，情节执行如算法 3 所示。

算法 2 采用并行深度 V 学习的 HMP-DRL 训练

1: 通过演示 D 运行模仿学习，用 D 更新价值网络 $V$2: 初始化：目标价值网络$\hat{V} \leftarrow V$，体验回放记忆 $E \leftarrow D$，并行进程数 $N$3: while Episode $<$ M do 4: 初始化大小为 N 的多处理池 5: 对于 k = Episode，episode + N并行执行： 6: 执行 Episode k 使用算法 3 7: end for 8: 从 E 中采样随机小批量元组 9: 通过梯度下降更新值网络 $V$10: if Episode mod UpdateInterval = 0 then 11: 更新目标值网络$\hat{V} \leftarrow V$12: end if 13: 更新 $episode \leftarrow episode + N$14: end while 15: 返回 V

算法 3 HMP-DRL 片段执行

1: 初始化环境，随机开始 $\mathbf{p}0$ 和目标 $\mathbf{g}$ 2: 计算全局路径 $\mathcal{P} \leftarrow$ A*(OccupancyMap, $\mathbf{p}0, \mathbf{g}$) 3: 沿 $\mathcal{P}$ 每隔 D 放置检查点 $\{c_1, \ldots, c_L\}$ 4: 初始化：访问集 $\mathcal{V} \leftarrow \emptyset$、缓冲区 $S \leftarrow \emptyset$、$t \leftarrow 0$ 5:重复 6: 设置上次访问的检查点索引: $m \leftarrow \max\{i : c_i \in \mathcal{V}\}$ 7: 选择 K 检查点: $\mathcal{C}_K \leftarrow \{c_{m+1}, \ldots, c_{\min(m+K,L)}\}$ 8: 使用 (13) – (15) 计算检查点特征 $\mathbf{f}_{\text{cp}}$ 9: 构造扩展状态 $\tilde{\mathbf{s}}_t^r \leftarrow [d_g, v_{\text{pref}}, \theta, r, v_x, v_y, \mathbf{f}_{\text{cp}}]$ 10: 形成联合状态 $\tilde{\mathbf{s}}_t^j \leftarrow [\tilde{\mathbf{s}}_t^r, \mathbf{s}_t^1, \ldots, \mathbf{s}_t^{no}]$ 11: $\mathbf{a}_t \leftarrow \begin{cases} \text{RandomAction()} & \epsilon \\ \arg\max_{\mathbf{a} \in \mathbf{A}} R(\tilde{\mathbf{s}}_t^j, \mathbf{a}) + \gamma^{\Delta t \cdot v_{\text{pref}}} V(\tilde{\mathbf{s}}_{t+\Delta t}^j), & 1-\epsilon \end{cases}$ 12: 执行 $\mathbf{a}_t$，观察 r_t 和下一个状态 13: 如果机器人进入未访问的检查点 c_i 则 14: $\mathcal{V} \leftarrow \mathcal{V} \cup \{c_i\}$，添加$R_{\text{cp}}$ 到 r_t 15: 结束 if 16: 将 ($\tilde{\mathbf{s}}_t^j, \mathbf{a}_t, r_t, \tilde{\mathbf{s}}_{t+\Delta t}^j$) 存储在 S 17: $t \leftarrow t + \Delta t$ 18: 直到终端状态或 $t \geq t_{\max}$ 19: 对于 S 中的每个 ($\tilde{\mathbf{s}}_t^j, \mathbf{a}_t, r_t, \tilde{\mathbf{s}}_{t+\Delta t}^j$) 执行 20: $\text{value}_t \leftarrow r_t + \gamma^{\Delta t \cdot v_{\text{pref}}} \hat{V}(\tilde{\mathbf{s}}_{t+\Delta t}^j)$ 21: 将 ($\tilde{\mathbf{s}}_t^j$, value_t) 存储在经验记忆 E 中22：结束

At the beginning of each episode, we compute the global path $\mathcal{P}$ from the robot's start position to its goal using A* on the occupancy grid. We then place checkpoints $\{c_1, \ldots, c_L\}$ along $\mathcal{P}$ at intervals of distance D.

在每个时间步，我们选择 K 即将到来的检查点，使用（13）将它们转换为以机器人为中心的框架，并将结果特征 $\mathbf{f}_{\text{cp}}$ 与基本自我状态连接起来形成 $\tilde{\mathbf{s}}^r$ （如（16）中定义的）。然后，扩展的关节状态 $\tilde{\mathbf{s}}_t^j = [\tilde{\mathbf{s}}_t^r, \mathbf{s}_t^{1o}, \ldots, \mathbf{s}_t^{no}]$ 用于动作选择和价值估计。
全局路径每集计算一次，避免了每一步重新规划的计算开销。由于每一集都有一个独特的起始目标对，因此机器人学会在环境中遵循不同的路径。检查点功能为本地规划者提供全局背景，实现长距离导航，同时基于注意力的价值网络处理动态避障。

4.6 实施细节

我们假设非完整机器人运动学并使用独轮车模型。动作空间由 81 个离散动作组成：一个停止动作（零速度）加上 5 个速度的组合，在范围 $(0, v_{\text{pref}}]$ 内呈指数分布，以及 16 个方向，在 $[0, 2\pi)$ 内均匀分布。
对于全局路径表示，我们使用 $K = 2$ 个检查点，半径 $r_{\text{cp}} = 5$ m，检查点间距离 $D = 15$。请注意，K 表示在每个时间步馈送到模型的检查点数量，而不是沿路径的检查点总数，这取决于路径长度和距离 D。这会导致 $4K = 8$ 个检查点特征附加到基本自状态，从而产生 $6 + 8 = 14$ 的扩展自状态维度。

神经网络架构由四个多层感知器（MLP）组成。 MLP 的结构由元组 $(d_{\text{in}}, d_1, \ldots, d_{\text{out}})$ 表示，它分别指定输入层、隐藏层和输出层中的神经元数量。这些 MLP 组件的维度为 ϕ_g: (25, 300, 200)、ψ_h: (200, 200, 100)、ψ_α: (400, 200, 200, 1) 和 f_v: (114, 350, 250, 200, 1)。输入维度 25 到 ϕ_g 表示由扩展机器人状态 (14)、代理可观察状态 (7) 和实体类型 one-hot 编码 (4) 组成的关节状态。 f_v 的 114 个输入维度将扩展的自我状态 (14) 与所有代理的注意力加权特征表示 (100) 结合起来。

我们在所有 MLP 中的每个隐藏线性层之后和 ReLU 激活之前应用批量归一化 [39]。该技术标准化了每一层的输入，从而稳定了训练并允许使用更高的学习率。此外，它还可以加速收敛并提供温和的正则化效果，有助于减轻过度拟合。在我们的实验中，事实证明，批量归一化对于基于值的强化学习设置（其中目标值是非平稳的）的稳定性特别有益。

我们在深度学习框架 PyTorch [40] 中实现了该策略，并使用随机梯度下降以 100 的批量大小（每个情节）对其进行训练。对于模仿学习，我们使用 ORCA 收集了 3000 集演示，并以 0.01 的学习率对策略进行了 200 轮训练。对于强化学习，学习率为 0.001，折扣因子 γ 为 0.99。 ϵ 贪婪策略的探索率在前 25000 个回合中从 0.5 线性衰减到 0.05，并在其余回合中保持在 0.05。

在我们的实验中，所有输入特征（机器人状态、实体状态和实体类型）都是直接从模拟器获得的。在真正的机器人上，这些将由标准定位和感知系统提供[41]，其实现超出了本工作的范围。

5 实验

5.1 城市情节生成

我们根据地图中的真实城市几何形状，通过栅格化欧洲大城市的 OpenStreetMap (OSM) 数据，在模拟器中生成机器人导航事件的大型数据集 [42]。数据准备管道生成地图快照，在语义上将每个快照分割为土地利用和基础设施类别，将语义折叠成用于全局规划的二进制占用地图，最后选择保证之间存在路径的起始目标对。这些地图随后被用作静态层，而动态代理在 “ 隐形机器人 ” 假设下使用 ORCA [11] 进行训练和评估期间建模。

来自 OSM 的地图快照。我们定义了一个以城市中心为中心的矩形区域，并在 29 公里 × 38 公里区域内使用密集的视点网格对其进行统一离散化。对于每个视点，我们通过拼接来自自托管 OSM 切片服务器的 256 像素地图切片来生成高缩放方形栅格快照（缩放 20）。快照在渲染时没有叠加文本标签，以确保稳定的调色板，并保存为方形图像（每边 2000 像素）。此步骤遵循标准的 Web 墨卡托投影切片程序：将地理坐标转换为目标缩放级别的切片坐标，检索覆盖所需区域的相邻切片，并将生成的马赛克裁剪为所需的大小。
通过将像素颜色与固定调色板匹配，将每个快照转换为语义栅格。我们使用最近的颜色规则（RGB 中的曼哈顿距离，阈值较小）将每个图像像素分配给以下类别之一：

1. 住宅区 2. 绿地 3. 工业区 4. 学校/大学/医院 5. 土地 6. 停车场 7. 棕地 8. 公园/绿地 9. 森林/公园 10. 道路 11. 商业区 12. 草地/草地 13. 运动场 14. 水域 15. 建筑

二进制占用图。接下来，语义栅格被折叠成二进制占用图，为全局规划器编码静态可遍历性。具体来说，与自然障碍或无法通行的基础设施（建筑物、水、运动场和草地/草地）相对应的类别被标记为占用，而所有其他类别（有人行道的住宅区、有人行道的土壤、工业区、学校/大学/医院、分配地、停车场、棕地、公园/绿地、森林/公园、道路和商业区）被标记为空闲。

在图中。在图3a和3b中，我们可以看到上述步骤的示例：从OSM城市地图生成占用地图，放置起点和终点，并构建全局路径。

(a) OSM map snapshot. (b) Binary occupancy map and global path.

图 3：地图处理示例：(a) OSM 地图快照，从中形成占用地图； (b) 相应的二进制占用图以及使用 A* 构建的全局路径。

起始目标抽样。在每个二元地图上，我们选择一到三个起始目标对。机器人的足迹被建模为 20 × 20 像素的正方形；有效的起始位置和目标位置是整个足迹完全位于自由空间内的位置。此外，我们要求目标距离起点足够远，以产生重要的情节：我们选择欧几里德距离至少为地图较大维度 0.75 的目标。为了确保全球层面的动态可行性，我们将障碍物膨胀了足迹厚度的一半，并在膨胀的网格上执行 8 连接的 A* 搜索（如第 4 节所述）。仅当存在无碰撞 A* 路径时才接受对；接受的路径与起点和目标一起保存。

结果数据集。由于我们的目标是训练机器人在足够复杂的环境中驾驶，因此我们通过引入最小静态占用率来丢弃没有或很少有静态障碍物的地图：障碍物百分比低于阈值（5%）的地图将被跳过和使用。没有有效的起始目标对满足路径存在约束的地图也将被删除。

在过滤和删除无法实现的情况后，我们获得了 30,948 个不同的地图。在每张地图上采样 1-3 个起始目标对，并保证从开始到结束的路径，会产生 77,663 个独特的导航片段。这些情节在我们的模拟器中充当静态占用地图。我们将它们随机分为训练集、验证集和测试集：对于我们的主要实验，我们使用 60,000 个集进行训练，500 个集用于验证，1,000 个集用于测试。剩余的剧集保留用于根据需要进行额外的实验。

5.2 奖励设置

在本小节中，我们定义实验的奖励函数。机器人在具有四种实体类型的环境中导航：成人、自行车、儿童和静态障碍物。每个动态实体类型有 4 个实例，因此每个场景有 12 个动态代理。静态障碍物由占用图定义，并因区域而异。

$$R_{\text{checkpoint}}(t) = \begin{cases} 0.3, & \text{if } \|\mathbf{p}_t - \mathbf{c}_k\|_2 < r_{\text{checkpoint}} \text{ and } k \text{ is unvisited checkpoint} \\ 0, & \text{otherwise} \end{cases} \tag{22}$$

$$R_{\text{success}} = 3 \tag{23}$$

我们将实体类型表示如下：成人 (A)、自行车 (B)、儿童 (C) 和障碍物 (O)。碰撞处罚定义为：

$$R_{\text{coll}}(e) = \begin{cases} -1.0, & \text{if } e = O \\ -1.5, & \text{if } e = A \\ -2.0, & \text{if } e = B \\ -2.5, & \text{if } e = C \end{cases} \tag{24}$$

我们根据不可预测性和潜在危害来调整碰撞处罚。静态障碍物受到的惩罚最低（-1.0），因为它们的位置是固定的。成年人由于其可预测的运动模式而受到中等惩罚（-1.5）。考虑到骑自行车者的速度和跌倒风险，他们应该受到更高的处罚（-2.0）。与儿童发生碰撞将受到最高处罚 (-2.5)，因为儿童难以预测且极易受到伤害。

令 $d_{\text{disc}}(e)$ 为实体 e 的不适距离（以米为单位）：

$$d_{\text{disc}}(e) = \begin{cases} 0.1, & \text{if } e = A \\ 0.2, & \text{if } e = B \\ 0.2, & \text{if } e = C \end{cases} \tag{25}$$

令 $p_{\text{disc}}(e)$ 为实体 e 的不适惩罚因子：

$$p_{\text{disc}}(e) = \begin{cases} 0.0, & \text{if } e = O \\ 0.5, & \text{if } e = A \\ 1.0, & \text{if } e = B \\ 1.0, & \text{if } e = C \end{cases} \tag{26}$$

我们省略 $d_{\text{disc}}(O)$ 因为静态障碍物不会感到不适。然而，如果机器人需要与静态障碍物保持距离，则可以定义 $d_{\text{disc}}(O)$ 并将 $p_{\text{disc}}(O) >$ 设置为 0。

5.3 模拟设置

我们使用专为城市环境中运行的户外移动机器人设计的模拟器进行实验，例如人行道送货机器人、自动清洁工和安全巡逻机器人。模拟器根据第 5.1 节中描述的地图对现实的行人交通和城市几何形状进行建模。
我们比较了三种导航方法：SARL [8]、EB-CADRL [9] 和我们的 HMP-DRL。

模拟主体（成人、儿童、骑自行车的人）由最佳相互碰撞避免（ORCA）控制[11]。为了引入多样性，每个代理的大小和速度都是根据其类型特定的均匀分布得出的。这些分布被设计为重叠，例如，某些儿童可能比某些成人更快，因此无法仅根据代理的大小和速度来确定代理的类型。

动态代理生成。在我们的模拟器中，我们在一个情节（“ 动态生成 ”）期间使用新的动态代理来维持机器人周围的流量。在我们的设置中，每 80 个模拟步骤启用并执行动态生成（$\Delta t = 0.25$ 秒，这相当于 20 秒）。在每次生成事件中，我们添加 4 个成人、4 个骑自行车的人和 4 个儿童，并为他们分配 80 步的生命周期。年龄超过寿命的特工将被从现场移除。新代理从宽度为 40 m 的正方形区域中采样，相对于机器人进行定位和定向：我们计算从机器人到其目标的单位方向向量，并将正方形中心沿该方向放置在机器人前方正方形宽度的一半处。方形偏航与机器人到目标的相同方向对齐。生成的代理的起始位置和目标位置在此定向正方形（正方形交叉）的相对边缘上进行采样，并进行拒绝采样以避免与机器人、其他代理和静态障碍物立即发生碰撞。

所有评估都使用 “ 隐形机器人 ” 设置，其中其他代理不会感知机器人或对机器人做出反应。这测试了机器人在最坏情况下的避碰能力，这也是现实的，因为小型机器人经常被人们忽视。

使用模仿学习对模型进行 3000 集训练，然后使用 “ 并行深度 V 学习的 HMP-DRL 训练 ” 算法进行 60000 集训练。2. 在训练期间，我们在 500 集验证集上每 1024 集验证模型。为了进行最终比较，我们使用加权得分指标根据每种方法的验证性能选择性能最佳的模型，并在 1,000 集测试集上对其进行评估。

5.4 结果

图 4 显示了训练和验证曲线。

所有方法在 60,000 个 RL 训练集内收敛（在模仿学习热启动之后）。

在训练和验证过程中，HMP-DRL 始终实现更高的成功率和加权分数，同时保持比 SARL 和 EB-CADRL 更低的冲突率。
为了以反映不同碰撞严重程度的方式比较安全性，我们使用加权分数 (WS) 指标：

$$WS = SR - CR(A) - 4.0 \cdot CR(C) - 2.0 \cdot CR(B) - 0.5 \cdot CR(O). \tag{27}$$

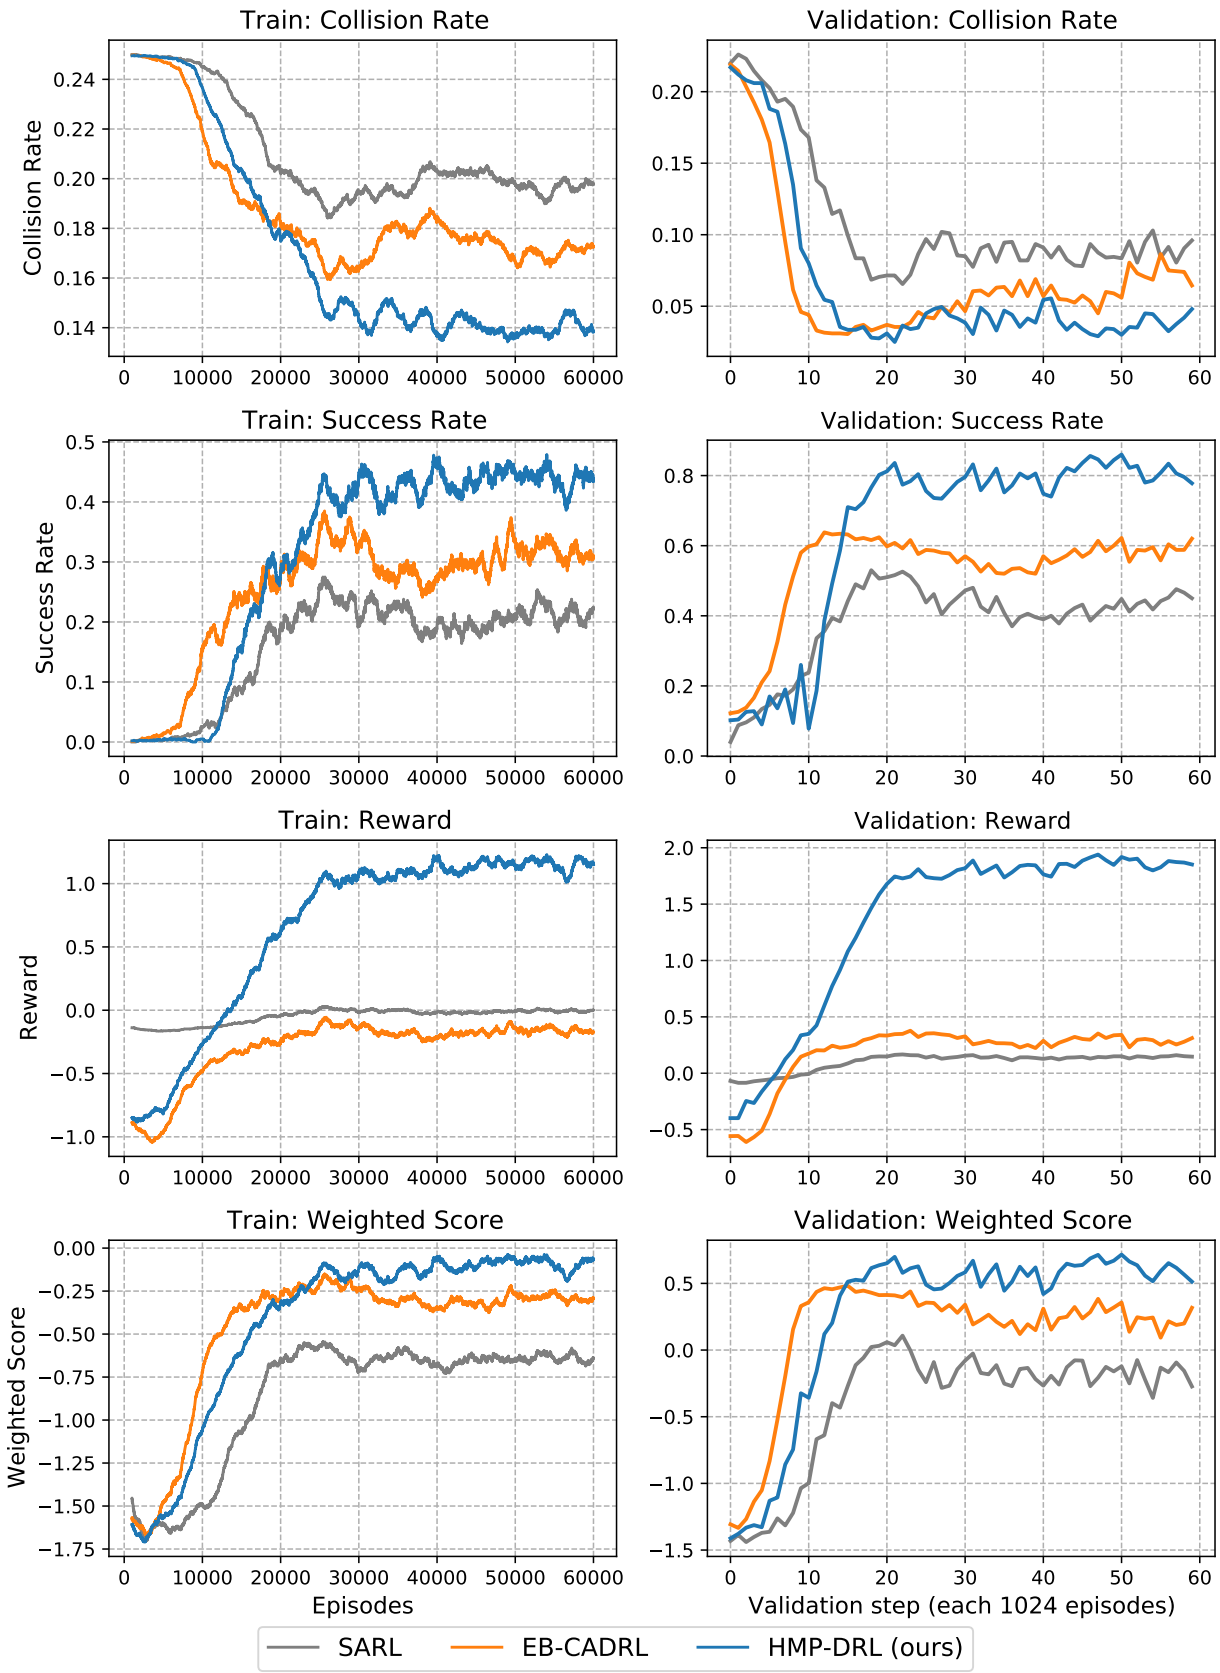

图 4：训练和验证数据的碰撞率、成功率、奖励、加权得分指标。每 1024 集执行一次验证步骤。

表 1：12 种代理的测试数据指标。

Method	SARL	EB-CADRL	HMP-DRL
SR	0.524	0.649	**0.836**
CR	0.289	0.128	**0.123**
CR(A)	0.05	**0.019**	**0.019**
CR(B)	0.155	0.047	**0.044**
CR(C)	0.022	0.015	**0.004**
CR(O)	0.062	**0.047**	0.056
Time	78.36	93.42	**72.03**
DD(A)	0.154	0.147	**0.166**
DD(B)	0.144	0.181	**0.183**
DD(C)	0.153	0.184	**0.209**
WS	0.045	0.4525	**0.685**

表 2：3 名代理人（1 名成人、1 辆自行车、1 名儿童）的测试数据指标。

Method	SARL	EB-CADRL	HMP-DRL
SR	0.719	0.712	**0.936**
CR	0.054	0.034	**0.017**
CR(A)	0.009	0.003	**0.001**
CR(B)	0.018	0.015	**0.007**
CR(C)	0.004	**0.0**	**0.0**
CR(O)	0.023	0.016	**0.009**
Time	89.72	98.89	**72.84**
DD(A)	0.15	0.166	**0.182**
DD(B)	0.151	**0.169**	0.15
DD(C)	0.157	**0.249**	0.208
WS	0.6465	0.671	**0.9165**

这里，SR是成功率，$CR(\cdot)$是与成人(A)、儿童(C)、自行车(B)和静态障碍物(O)的碰撞率。选择系数来更严厉地惩罚与更脆弱实体的碰撞，并且可以进行调整以匹配特定于应用程序的安全优先级。

由于每种方法使用不同的奖励定义，因此不同方法之间的情节回报不能直接比较，并且仅用于监控方法内的学习进度。
表 1 总结了 1,000 集测试集的评估。我们报告：*SR* (成功率)；*CR* (总体碰撞率); *CR(A), CR(B), CR(C), CR(O)* (与成人、自行车、儿童和静态障碍物的碰撞率)；*Time* (达到目标的平均时间)；*DD(A), DD(B), DD(C)* (表示成人、自行车和儿童在“危险”交互期间机器人与代理的距离，其中危险定义为距离 $<$ 30 cm)。
HMP-DRL 的成功率 (0.836) 明显高于 EB-CADRL (0.649) 和 SARL (0.524)，同时还降低了总体碰撞率（0.123 vs. 0.128 和 0.289）。最大的安全增益是在与儿童发生碰撞时：HMP-DRL 的 $CR(C)$ 下降至 0.004（而 EB-CADRL 为 0.015，SARL 为 0.022），这大大提高了加权分数（0.685 对比 0.452 5 和 0.045）。 HMP-DRL 平均达到目标的速度也更快（72.03 秒对比 93.42 秒和 78.36 秒）。

表 2 报告了具有 3 个动态代理（1 名成人、1 名自行车、1 名儿童）的更简单场景的结果，这减少了周围密集交通的影响。在此设置中，HMP-DRL 进一步提高了性能，实现了 $SR = 0.936$ 和 $CR = 0.017$，与易受攻击的代理的碰撞几乎为零（$CR(A) = 0.001$、$CR(C) = 0.0$）。因此，它获得了最高的加权分数（0.9165）和最短的平均到达目标时间（72.84 秒）。

总体而言，HMP-DRL 在主要指标上表现最佳：它实现了最高的成功率（SR）和加权得分（WS）以及最低的碰撞率（CR），同时在密切交互过程中保持了相当的安全裕度。

5.5 消融实验

表 3：消融研究：检查点奖励塑造 (R_{cp}) 对 HMP-DRL 的影响。

Method	With checkpoint reward ($R_{\text{cp}} = 0.3$)	Without checkpoint reward ($R_{\text{cp}} = 0.0$)
SR	**0.836**	0.615
CR	**0.123**	0.13
CR(A)	0.019	**0.018**
CR(B)	**0.044**	0.054
CR(C)	**0.004**	0.008
CR(O)	0.056	**0.05**
Time	**72.03**	79.59
DD(A)	**0.166**	0.153
DD(B)	**0.183**	0.182
DD(C)	**0.209**	0.2
WS	**0.685**	0.432

我们取消了基于检查点的奖励塑造项（第 4.3 节，方程（11）），它通过检查点沿着全局 A* 路径提供中间进度反馈。我们使用相同的架构、数据集和超参数从头开始训练两个 HMP-DRL 策略；唯一的区别是检查点奖励大小 R_{cp}。在第一个变体中，我们使用默认设置 $R_{\text{cp}} = 0.3$，而在第二个变体中，我们通过设置 $R_{\text{cp}} = 0.0$ 来禁用检查点整形。这两种策略都在表 1 中相同的 1,000 集测试集上进行评估，并且我们报告了相同的指标。

结果总结在表 3 中。启用检查点奖励显着提高了导航性能：成功率从 0.615 增加到 0.836，加权分数从 0.432 增加到 0.685。该策略平均达到目标的速度也更快（72.03 秒 vs. 79.59 秒），这表明进展更有效，停滞轨迹更少。安全性的提高主要针对最具挑战性的动态实体：与自行车的碰撞减少（0.054 → 0.044），与儿童的碰撞减少一半（0.008 → 0.004）。我们还观察到更大的平均危险距离 $DD(\cdot)$，这表明检查点形状的政策在密切互动期间保持了稍大的安全边际。虽然 $CR(A)$ 和 $CR(O)$ 仅略有变化（并且方向相反），但检查点整形的总体效果在关键指标上具有强烈的积极作用。

这些发现支持我们的设计选择：稀疏的检查点反馈使本地政策与全球计划保持一致，从而改善所有主要指标。

6 结论

在这项工作中，我们提出了 *Hybrid Motion Planning with Deep Reinforcement Learning* (HMP-DRL)，这是一种混合导航方法，它将基于图的全局规划器与本地 DRL 策略结合起来。全局级别计算全局路径并将其转换为一系列间隔距离的检查点。本地级别扩展了一个具有检查点功能的基于注意力的实体感知价值网络，并通过奖励塑造对其进行训练，以鼓励沿路线取得进展，同时对不同实体实施与类型相关的安全裕度和碰撞惩罚。

在源自 OpenStreetMap 的大型城市模拟器（具有 ORCA 控制的密集交通）中进行的实验表明，HMP-DRL 提高了可靠性和安全性。在主要测试集上，它实现了 0.836 的成功率（相对于 EB-CADRL 的 0.649 和 SARL 的 0.524），总体碰撞率较低，为 0.123，遍历时间更快（平均 72.03 秒）。最大的增益是针对最脆弱的实体类型：与儿童的碰撞下降至 0.004，产生最佳加权安全得分 (0.685)。消融研究进一步证实了路线引导的作用：禁用检查点奖励会将成功率从 0.836 降低到 0.615，加权分数从 0.685 降低到 0.432。

未来的研究方向包括将动态占用地图与在线图形重新规划相结合、添加额外的实体类型（例如汽车和摩托车）、复杂场景的训练策略（例如动态车辆的道路交叉口）以及真实世界的测试。

参考

[1] Roland Siegwart、Illah R. Nourbakhsh 和 Davide Scaramuzza。 *Introduction to Autonomous Mobile Robots*。麻省理工学院出版社，第 2 版，2011 年。ISBN 0262015358。[2] Giuseppe Fragapane、René de Koster、Fabio Sgarbossa 和 Jan Ola Strandhagen。内部物流自主移动机器人的规划和控制：文献综述和研究议程。 *European Journal of Operational Research*，294(2)：405 – 426，2021。ISSN 0377-2217。 doi：https://doi.org/10.1016/j.ejor.2021.01.019。网址 https://www.sciencedirect.com/science/article/pii/S0377221721000217。 [3] 乔治·A·贝基。
Autonomous Robots: From Biological Inspiration to Implementation and Control。麻省理工学院出版社，2005 年。ISBN 0262025787。[4] Daniel S Drew。用于搜索和救援应用的多代理系统。
Current Robotics Reports，2：189 – 200，2021。doi：10.1007/s43154-021-00048-3。 [5] Thibault Kruse、Amit Kumar Pandey、Rachid Alami 和 Alexandra Kirsch。人类感知机器人导航：一项调查。
Robotics and Autonomous Systems，61(12)：1726 – 1743，2013。ISSN 0921-8890。 [6] 史蒂文·R·格尔克、克里斯托弗·D·菲尔、布伦丹·J·鲁索和爱德华·J·斯马格利克。观察人行道自主送货机器人与行人和骑自行车者的互动。 *Transportation Research Interdisciplinary Perspectives*，18:100789，2023。ISSN 2590-1982。 [7] 陈宇凡、刘淼、Michael Everett、Jonathan P. How。通过深度强化学习来避免分散的非通信多智能体碰撞。在 *2017 IEEE International Conference on Robotics and Automation (ICRA)* 中，第 285 – 292 页，2017 年。 [8] Changan Chen、Yuejian Liu、Sven Kreiss 和 Alexandre Alahi。人群与机器人交互：具有基于注意力的深度强化学习的人群感知机器人导航。载于
2019 International Conference on Robotics and Automation (ICRA)，第 6015 – 6022 页，2019 年。 [9] Yury Kolomeytsev 和 Dmitry Golembiovsky。使用深度强化学习实现基于实体的防撞机器人导航，2025 年。URL https://arxiv.org/abs/2408.14183。 [10] 德克·赫尔宾和彼得·莫纳尔。行人动力学的社会力模型。 *Phys. Rev. E*，51：4282 – 4286，1995 年 5 月。doi：10.1103/PhysRevE.51.4282。 [11] Jur van den Berg、Stephen J. Guy、Ming Lin 和 Dinesh Manocha。相互的 n 体碰撞避免。 Cédric Pradalier、Roland Siegwart 和 Gerhard Hirzinger，编辑，*Robotics Research*，第 3-19 页，柏林，海德堡，2011 年。施普林格柏林海德堡。 ISBN 978-3-642-19457-3。 [12] 泰雷，张经纬，刘明，Wolfram Burgard。通过生成对抗性模仿学习通过原始深度输入实现社交合规导航，2018 年 5 月。 [13] Henrik Kretzschmar、Markus Spies、Christoph Sprunk 和 Wolfram Burgard。通过逆强化学习实现符合社交要求的移动机器人导航。 *The International Journal of Robotics Research*, 35, 01 2016.doi:10.1177/0278364915619772。 [14] 陈宇凡、Michael Everett、Miao Liu 和 Jonathan P. How。具有深度强化学习的社会意识运动规划。载于 *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*，第 1343 – 1350 页，2017 年。 [15] Michael Everett、Yu Fan Chen 和 Jonathan P. How。通过深度强化学习在动态决策代理之间进行运动规划。 In
2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)，第 3052 – 3059 页，2018 年。 [16] Bingxin Xu 等人。通过深度强化学习实现群体感知、社交合规的机器人导航。
International Journal of Social Robotics，16(1)：197 – 209，2024。ISSN 1875-4805。

[17] 李克宇，徐阳欣，王建坤，Max Q.-H。孟。 Sarl：基于深度强化学习的人类感知导航，用于室内环境中的移动机器人。在 *2019 IEEE International Conference on Robotics and Biomimetics (ROBIO)* 中，第 688 – 694 页，2019 年。doi:10.1109/ROBIO49542.2019.8961764。 [18]王斌宇，刘哲，李清彪，Amanda Prorok。通过全局引导强化学习在动态环境中进行移动机器人路径规划。 *IEEE Robotics and Automation Letters*，5(4)：6932 – 6939，2020。doi：10.1109/LRA.2020.3026638。 [19] Ekim Yurtsever、Linda Capito、Keith Redmill 和 Umit Ozguner。将深度强化学习与基于模型的路径规划器集成以实现自动驾驶。在 *2020 IEEE Intelligent Vehicles Symposium (IV)* 中，第 1311 – 1316 页。 IEEE，2020。[20] Reinis Cimurs、Il Hong Suh 和 Jin Han Lee。通过深度强化学习实现目标驱动的自主探索。 *IEEE Robotics and Automation Letters*，7(2)：730 – 737，2022。doi：10.1109/LRA.2021.3133591。 [21] 毕云飞，方曦.集成深度强化学习和可变方向势场的混合路径规划框架。 *Mathematics*，13(14)，2025。ISSN 2227-7390。 doi：10.3390/math13142312。网址 https://www.mdpi.com/2227-7390/13/14/2312。 [22] 钟旭，田建，胡红，等。大规模动态环境下移动机器人基于safe a*算法和自适应窗口方法的混合路径规划*Journal of Intelligent & Robotic Systems*，99:65 – 77，2020。doi:10.1007/s10846-019-01112-z。 [23] 孙勇，袁强，高强，等。基于改进的a*算法的多环境可用路径规划。 *International Journal of Computational Intelligence Systems*，17:172，2024。doi:10.1007/s44196-024-00571-z。 [24] Youngmi Baek 和 Jung Kyu Park。使用混合地图的移动机器人导航快速路径生成算法 *Applied Sciences*，15(5)，2025。ISSN 2076-3417。 doi：10.3390/app15052414。网址 https://www.mdpi.com/2076-3417/15/5/2414。 [25] Hoang-Long Pham、Nhu-Nghia Bui 和 Thai-Viet Dang。基于rrt-star算法和强化学习方法的轮式移动机器人混合路径规划*Journal of Robotics and Control (JRC)*, 6(4):2045 – 2051, 2025.doi:10.18196/jrc.v6i4.27678。 [26] 理查德·S·萨顿和安德鲁·G·巴托。 *Reinforcement Learning: An Introduction*。布拉德福德书籍，美国马萨诸塞州剑桥，2018 年。ISBN 0262039249。[27] Jean-Claude Latombe。 *Robot Motion Planning*。 Kluwer 学术出版社，美国马萨诸塞州诺威尔，1991 年。ISBN 978-0-7923-9129-6。 [28] 马塞洛·卡尔曼。三角测量中的路径规划。 *Proceedings of the IJCAI Workshop on Reasoning, Representation, and Learning in Computer Games*，第 49-54 页，2005 年。 [29] Ahmadreza Meysami、Jean-Christophe Cuillière、Vincent François 和 Sousso Kelouwani。研究三角形和四边形网格表示对各种室内环境的 AGV 路径规划的影响：有或没有充气。 *Robotics*，11(2):50，2022。doi:10.3390/robotics11020050。 [30] H. Choset 和 J. Burdick。基于传感器的规划。我。广义 voronoi 图。在 *Proceedings of 1995 IEEE International Conference on Robotics and Automation*，第 2 卷，第 1649 – 1655 页，第 2 卷，1995 年。doi:10.1109/ROBOT.1995.525511。 [31] 弗朗茨·奥伦哈默。沃罗诺伊图——对基本几何数据结构的调查。 *ACM Comput. Surv.*，23(3):345 – 405，1991 年 9 月。ISSN 0360-0300。号码：10.1145/116873.116880。网址 https://doi.org/10.1145/116873.116880。 [32] 托马斯·洛萨诺-佩雷斯和迈克尔·A·韦斯利。一种规划多面体障碍物之间无碰撞路径的算法。 *Commun. ACM*，22(10)：560 – 570，1979 年 10 月。ISSN 0001-0782。号码：10.1145/359156.359164。网址 https://doi.org/10.1145/359156.359164。 [33] 欧俊林，洪成贤，宋歌，王毅。基于自适应可见图初始化和边缘计算的移动机器人混合路径规划。 *Engineering Applications of Artificial Intelligence*，126：107110，2023。ISSN 0952-1976。 doi：https://doi.org/10.1016/j.engappai.2023.107110。网址 https://www.sciencedirect.com/science/article/pii/S0952197623012940。

[34] 彼得·哈特、尼尔斯·尼尔森和伯特伦·拉斐尔。启发式确定最小成本路径的正式基础。 *IEEE Transactions on Systems Science and Cybernetics*，4(2)：100 – 107，1968。doi：10.1109/tssc.1968.300136。 [35] 埃兹格·W·迪杰斯特拉。关于与图表相关的两个问题的说明。 *Numerische mathematik*，1(1)：269 – 271，1959。 [36]托马斯·H·科门、查尔斯·E·莱瑟森、罗纳德·L·里维斯特和克利福德·斯坦。 *Introduction toAlgorithms, Third Edition*。麻省理工学院出版社，第 3 版，2009 年。ISBN 0262033844。 [37] 安东尼（托尼）斯坦茨。用于实时规划最佳遍历的 d* 算法。技术报告 CMU-RI-TR-94-37，匹兹堡，宾夕法尼亚州，1994 年 10 月。 [38] Steven M. Lavalle。 *Planning Algorithms*。剑桥大学出版社，2006。ISBN 0521862051。[39] Sergey Ioffe 和 Christian Szegedy。批量归一化：通过减少内部协变量偏移来加速深度网络训练。载于 Francis Bach 和 David Blei，编辑，*Proceedings of the 32nd International Conference on Machine Learning*，*Proceedings of Machine Learning Research* 第 37 卷，第 448-456 页，法国里尔，2015 年 7 月 7-09 日。PMLR。网址 https://proceedings.mlr。按/v37/ioffe15.html。 [40] 亚当·帕斯克等人。 Pytorch：命令式高性能深度学习库。 *Proceedings of the 33rd International Conference on Neural Information Processing Systems*，美国纽约州雷德胡克，2019 年。Curran Associates Inc. [41] Bruno Siciliano 和 Oussama Khatib。 *Springer Handbook of Robotics*。施普林格手册。施普林格，2016。ISBN 978-3-319-32550-7。 doi：10.1007/978-3-319-32552-1。 [42] OpenStreetMap 贡献者。从 https://planet.osm.org 检索的行星转储。 https://www. openstreetmap.org，2017。