vehicles

MDPI

Review

移动机器人路径规划深度强化学习算法综述

Ramanjeet Singh [1]、Jing Ren [2] 和 Xianke Lin [1,*]

1 安大略理工大学机械工程系，奥沙瓦，ON L1G 0C5，加拿大；ramanjeet.singh@ontariotechu.net [2] 安大略理工大学电气、计算机和软件工程系，奥沙瓦，ON L1G 0C5，加拿大；jing.ren@ontariotechu.ca * 通讯：xianke.lin@ontariotechu.ca

摘要：路径规划是自主移动机器人最基本的需求。传统上，路径规划问题是使用解析方法来解决的，但这些方法需要在环境中完美定位，需要完整的地图来规划路径，并且不能处理复杂的环境和紧急情况。最近，深度神经网络已被应用于解决这个复杂的问题。本文讨论了使用神经网络的路径规划方法，包括深度强化学习及其不同类型，例如无模型和基于模型、基于 Q 值函数、基于策略和基于行动者评论家的方法。此外，专门的部分深入研究了机器人与行人交互的细微差别和方法，探索人行道、道路交叉口和室内空间等不同环境中的这些动态，强调了机器人导航中社会责任的重要性。最后，讨论了这些方法面临的共同挑战以及用于优化解决方案的应用解决方案，例如奖励塑造、迁移学习、并行模拟等。

关键词：模仿学习；深度强化学习；全局和局部路径规划；行人互动；人行道导航和道路交叉口；动态环境

check for updates

引文：辛格，R.；任，J。 Lin, X。移动机器人路径规划深度强化学习算法综述。 *Vehicles* 2023, *5*, 1423 – 1451. https://doi.org/10.3390/ vehicles5040078

学术主编：黄超

收稿日期: 2023年9月5日 修回日期: 2023年10月11日 接受日期: 2023年10月13日 发布日期: 2023年10月17日

Copyright: © 2023 by the authors. Licensee MDPI, Basel, Switzerland. This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

一、简介

随着机械臂在制造和装配行业的成功集成[1]，移动机器人领域正在进行大量研究，特别是自主移动机器人。自主移动机器人广泛应用于清洁、送货[2]、商场协助[3]、巡逻[4]、自动驾驶汽车、老年家庭帮助机器人[5]、测量、搜索和救援[6,7]、自动化生产、采矿、家庭服务、农业等领域[8]。为了执行其预期任务，这些机器人应该能够沿着无碰撞的路径到达目标。此类机器人需要首先使用有关环境的可用信息规划一条全局路径，然后规划一条到全局路径上检查点的本地路径[9]，使用来自 RGB 相机、RGBD 相机或 LiDAR 等传感器的输入避免与静态和动态障碍物发生碰撞。

传统上，路径规划问题是使用解析方法来解决的，但这些方法需要在环境中完美定位，需要完整的地图来规划路径，并且不能处理复杂的环境和紧急情况[10,11]。随着深度神经网络的普及和计算硬件能力的增强，用于移动机器人路径规划的深度学习、模仿学习和深度强化学习等策略得到了普及。模仿学习使用深度神经网络来学习周围环境数据与专家驾驶员所采取的行动之间的关系[12]。深度强化学习（DRL）利用强化学习的决策能力和神经网络的特征识别能力，并将其应用于路径规划问题[13]。 DRL算法已被广泛应用

用于视频预测、目标定位、文本生成、机器人、机器翻译、控制优化、自动驾驶、文本游戏和许多其他领域[14]。图 1 显示了主要路径规划方法的简明概述。

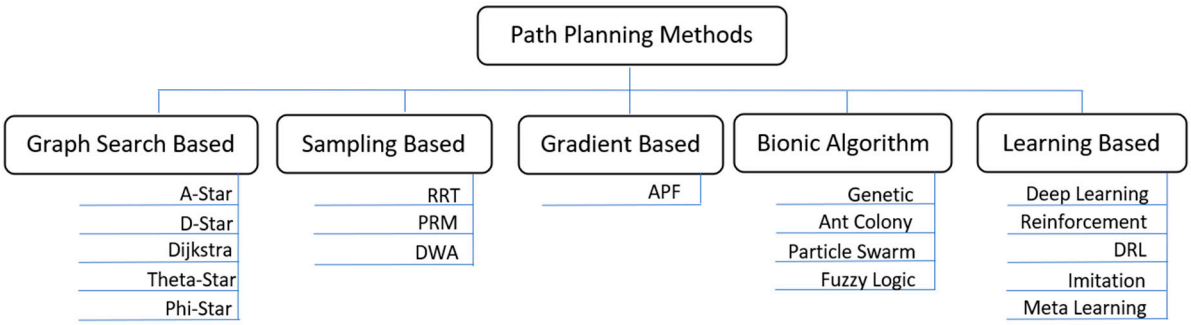

图 1. 路径规划方法概述。

在下一节中，将讨论用于环境和障碍物检测的流行输入传感器及其对学习策略的影响。第 3 节讨论深度神经网络在路径规划中的使用，包括强化学习方法。第 4 节讨论了在需要以符合社会规范的方式行事的环境中部署移动机器人的方法。在第 5 节中，讨论了常见问题及其解决方案，以及有助于解决方案的可用流行资源，然后是结论。

2. 障碍物检测及其在路径规划中的作用

机器人有效导航其环境的能力取决于其感官输入的质量和准确性。对于移动机器人来说，了解周围环境至关重要，这主要是通过摄像头、激光雷达、IMU 和 GPS 等传感器来实现的。通过理解和识别障碍物，机器人可以生成有效且安全的路径，避免潜在的碰撞并确保成功导航。障碍物检测方法的选择和质量直接影响机器人的导航能力。本节深入研究两种主要传感方式：视觉传感器和激光雷达，强调它们对路径规划的影响。

2.1. Vision Sensor

RGB 和 RGB-D 相机等视觉传感器从环境中捕获视觉数据[15]。传统的 RGB 相机缺乏深度数据，给障碍物的直接距离计算带来了挑战。深度学习方法，特别是 CNN，已被用来从此类图像中获取空间信息。通过将 DRL 框架与 CNN 集成，机器人可以使用原始图像数据做出端到端的规划决策。然而，存在一个警告：由于虚拟和真实环境之间的视觉差异，在模拟中训练的模型通常会在现实环境中表现出性能下降[16]。

另一方面，深度相机提供每个像素的深度数据，使机器人能够更明确地了解障碍物距离。此类信息对于路径规划非常宝贵，因为它提供了关键的距离指标，可以增强导航算法并提高移动过程中的安全性。然而，深度相机会引入噪声，这可能会导致机器人行为不确定[17]。尽管如此，丰富的数据（包括轮廓和姿态变化）提供了深度和细节，可以极大地帮助障碍感知路径规划[18]。

2.2. LiDAR

LiDAR发射脉冲调制光并检测反射光以计算不同方向上障碍物的距离[15]。移动机器人利用 2D 和 3D LiDAR 来绘制周围环境的地图。大多数激光雷达为机器人提供完整的 360 度感知，与视野有限的相机不同。尽管激光雷达的数据准确且覆盖广阔的视野，但读数稀疏，而且问题

随着距离的增加而增加。 LiDAR数据可以以数组的形式发送到网络，更容易处理。与视觉导航任务相比，本地激光雷达信息可以移植到更复杂的环境中，无需重新训练网络参数，具有更广泛的应用和更好的泛化性能。但是，虽然点云数据被用作物体表面的空间坐标信息，但没有关于物体所属类别的信息。这导致自动识别和特征提取的困难[15]。 LiDAR 的主要缺点是其成本，但可以使用多个固态 LiDAR [19]，因为它们的视场较窄，从而更便宜。在 [17] 中，使用来自 Intel Realsense D435 和 Hokuyo UST-20LX LiDAR 的融合传感器输入来获得两全其美的效果。从地面开始，根据机器人的高度（z 轴）对 3D 点云进行过滤，并使用 ROS 节点将其转换为 2D 激光扫描，并与 LiDAR 数据相结合。但如果障碍物像落地扇或某些家具，由于 z 轴限制，激光可能只能看到两极。

3. 路径规划方法

3.1. Deep Learning

深度学习是一种机器学习技术，使用具有至少一个隐藏层的人工神经网络[20]。深度神经网络可以通过使用训练数据更新网络的权重和偏差来学习模式识别、函数逼近和分类[21]。它在图像分析[22]、人脸识别[23]、语音识别[24]、渐进诊断[25]、自然语言处理[26]和模式识别[27]等领域取得了显着的成功。深度学习的用途如此广泛，以至于它被用来以不同的方式解决路径规划问题。任何使用图像作为输入的算法都使用CNN，神经网络用于模仿学习以及在强化学习中当状态动作空间复杂且无法存储在表中时求解*Q*-值方程。

在[28]中，GoogLeNet在CIFAR10数据集上进行训练，将障碍物分类为静态（家具）或动态（宠物），并采取相应的行动来避开障碍物。光线追踪用于避开静态障碍物，等待规则用于避开动态障碍物，而RRT用于全局路径规划。在[29]中，作者使用 CNN 来查找无人机赛车场中的检查点，其中无人机使用单目摄像头自主导航赛道。在[5]中，作者将 Elman 型 RNN 与多级感知器在机器人导航问题中进行了比较。该模型以7维激光数据和目标相对位置作为输入，输出车轮运动指令。使用十七个迷宫环境来训练和测试网络。总体而言，RNN 在新环境中的表现优于 MLP。在[30]中，道路图像是从安装在汽车上左、中、右的三个摄像头收集的，用于 CNN 训练。然后通过CNN直接从原始图像中提取综合特征。最后根据分类结果导出机器人的运动方向。该模型也在土壤路径上进行了训练和测试，经过 1000 次迭代后，准确率达到 98%。在[29]中，作者使用单次检测器（CNN）来检测无人机赛车赛道中的方形检查站大门。他们训练了一个 ARDnet，使用 Caffe 库提取检查点的中心点并执行制导算法，使无人机遵循该中心点。制导算法生成前进、左/右和航向速度命令，这些命令被发送到飞行控制计算机（FCC）。无人机能够通过 25 个检查点中的 10 个，并且需要针对不同环境进行参数调整。

3.2. Imitation Learning

模仿学习方法直接向专家学习策略，专家的演示以神经网络标记数据的形式提供。模仿学习的主要方法可以分为行为克隆（BC）和逆强化学习（IRL）[31]。行为克隆以有监督的方式解决这个问题

直接学习从相机或激光雷达记录的输入状态到相应动作的映射。它很简单，并且可以很好地处理大量训练数据，但由于时间相关性的无知而遭受复合误差的困扰。因此，它往往会过度拟合，并且很难推广到与训练数据集相差很大的未见过的场景，并可能导致图 2 中所示的问题。逆强化学习旨在提取最佳专家演示下的奖励或成本函数。它通过考虑底层 MDP 并从整个轨迹而不是单个帧进行学习来进行模仿 [32]。

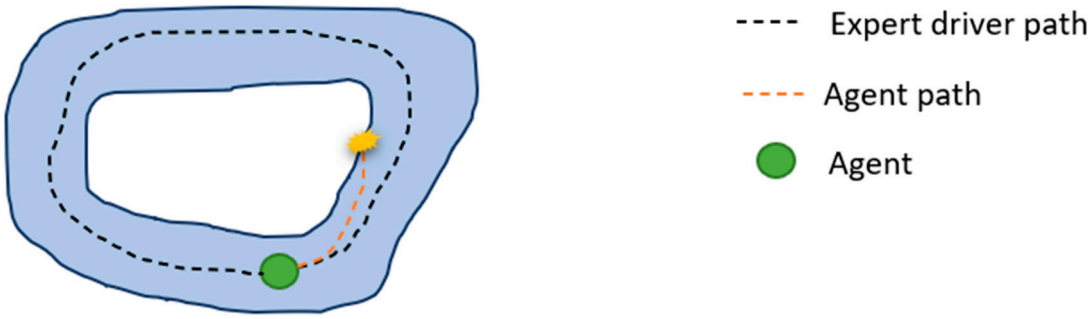

图 2. 模仿学习（从专家驾驶员路径收集的数据没有代理即将发生碰撞的实例，因此代理一旦进入碰撞路径就无法恢复）。

在[33]中，使用专家飞行员在搜索目标对象时选择的动作，在 CNN 的帮助下，制作了带有单目摄像头的小型四轴飞行器来学习控制器策略。作者收集并提供了用于训练的七个室内环境的数据集。该方法在五种不同的设置下进行了测试，无人机能够在 75% 的时间内到达目标。在[34]中，作者使用模仿学习和 Dijkstra 算法标记的动作开发了在线三维路径规划（OTDPP）。 3D障碍物图在每个维度上被分解为切片；在这些平面中执行路径规划，并将解决方案合并以获得最终的动作。网络学习奖励函数和转移概率来找到价值函数。还实施了视线检查，以找到到达目标的最短路径。该网络针对 A* 和 RRT 算法进行了测试，结果发现其性能优于这两种算法。在[35]中，研究人员使用 CNN 提取有用的特征，这些特征连接到完全连接的决策网络，该网络学习在人类操作员驾驶机器人时将原始输入深度图像与控制命令直接关联起来。在[36]中，作者使用改进的蚁群算法来避开远处的障碍物，并针对更近的障碍物修改人工势场来训练门控循环单元循环神经网络。尽管必须建立机器人和世界运动学模型，但经过训练的网络提供了平滑的机器人运动，并且与教师网络相比速度更快。在[37]中，使用 LSTM 的称为 OracelNet 的 RNN 用于规划使用 RRT、A* 和快速全局 bug 算法进行训练的全局路径。网络的执行速度比训练它的方法更快，但网络需要针对新环境进行训练。在[38]中，作者使用人工势场和模糊推理系统来生成用于训练神经网络的数据集。在开放区域，目标的吸引力拉动智能体，而在危险区域，考虑障碍物的斥力和障碍物的方向，利用模糊逻辑确定移动方向。将训练好的神经网络与真实动态室内环境中的动态窗口算法和蚁群优化进行比较，神经网络表现更好。在[39]中，作者使用了 CNN，它通过全局滚动预测算法学习 NAO 机器人的路径规划和碰撞避免。结果与动态障碍物二维网格世界中支持向量机方法和粒子群优化方法的结果进行了比较。在[40]中，作者使用三个连接到徒步旅行者头部不同方向的 GoPro 相机收集了 8 小时 30 fps 的视频数据。这些数据被用来训练

深度神经网络只需查看图像即可找到无人机需要行驶的方向。

3.3. Reinforcement Learning

在强化学习 [41] 中，代理从其环境的交互和奖励信号中学习，如图 3 所示，这与从标记数据中学习的监督学习或分析和聚类未标记数据的无监督学习不同。在强化学习中，智能体采取随机动作并迭代地尝试学习环境给予最大奖励的最佳动作。由于某些行为的效果可能会在不久的将来或稍后显现，因此考虑的是回报而不是奖励。回报“ R ”被定义为整个情节中未来奖励的折扣总和。

$$R = \sum_{t=0}^{T} \gamma^t r(s_t, a_t) \tag{1}$$

其中γ是折扣因子，$r(s_t$、$a_t)$是在s_t状态下采取a_t动作时的奖励。

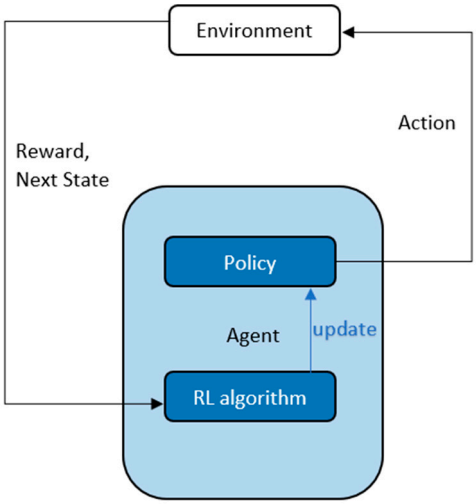

图 3. 强化学习——强化学习算法更新采取行动的策略，环境返回下一个状态并为每个行动提供奖励。强化学习算法使用奖励和下一个状态来更新策略以选择更好的操作。

根据智能体通过采取动作从状态获得的回报，每个状态都有一个状态值$V(s)$，状态中的每个动作都有一个与之对应的动作值$Q(s$、$a)$，贝尔曼方程[42]将其描述为：

$$V(s) = \mathbb{E}[R|s_0 = s] \text{ or } V(s) = \mathbb{E}[r(s) + \gamma V(s_{next})] \tag{2}$$

其中 $\mathbb{E}$ 是期望，状态的值是在遵循该状态的策略时该状态的预期回报。这里$r(s)$是在该状态下可以获得的所有奖励的总和。

$$Q(s,a) = \mathbb{E}[R|s_0 = s, a_0 = a] \text{ or } Q(s,a) = \mathbb{E}[r(s,a) + \gamma Q(s_{next}, a_{next})] \tag{3}$$

状态操作值或 Q-值是在状态 s_0 中采取操作 a_0 然后在整个事件中遵循策略的预期回报。因此，状态值和 Q-value 之间的关系由下式给出：

$$V(s) = \sum_{a \in A} \pi(a|s) Q(s,a) \tag{4}$$

其中 π 是在状态 s 下执行操作 a 的策略。在所有状态和动作已知且有限的问题中，可以形成 Q 表。这样的问题也称为马尔可夫决策问题（MDP）。代理采取一些行动，并且取决于

从环境收到返回后，Q 值会在 Q 表中更新。 Q 值根据以下等式更新：

$$Q'(s_t, a_t) = Q(s_t, a_t) + \alpha([r_t + \gamma Qmax(s_{t+1}, a_{t+1})] - [Q(s_t, a_t)]) \tag{5}$$

其中Q'是更新的Q值，α是学习率。在[6]中，作者开发了一种搜索和救援机器人，它能够决定机器人是否应该自主执行探索和受害者识别任务，或者仅使用强化学习将控制转发给人类操作员。该机器人使用 3D 地图传感器和 SLAM 来制作周围环境的 3D 地图和 2D 障碍物地图，并使用 MaxQ 算法，奖励机器人探索未访问过的区域。如果机器人将控制权交给人类操作员，机器人会继续从操作员的命令中学习，以便以后表现得更好。

基于模型的强化学习与无模型的强化学习

强化学习可以是基于模型的，也可以是无模型的。基于模型的算法需要学习（或提供）所有转换概率，如图 4 所示，它描述了智能体从一种状态转换到另一种状态的概率，可以通过动态编程技术来解决[43]。基于标准模型的算法交替使用模型预测控制收集样本和将转换（s_t；a_t；s_{t+1}）存储到数据集{D}中，以及更新转换模型参数以最大化存储在{D}中的转换的可能性[44]。从模型中学习的智能体可以快速学习策略，因为下一个状态已经已知，并且可以轻松预测未来的奖励，但不利的一面是，当状态空间复杂时，学习模型会很困难。

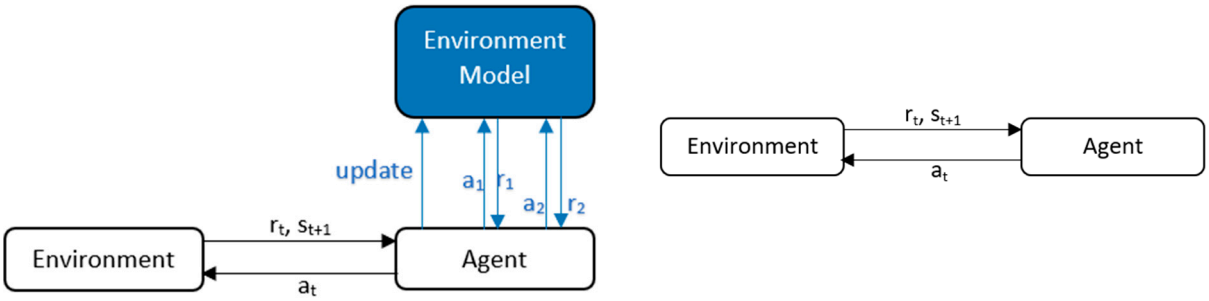

(**a**) Model-based RL (**b**) Model-free RL

图 4.基于模型的 RL 与无模型的 RL。 (a) RL 算法还学习模型动态以及代理策略网络参数，以帮助代理预测更好的动作。 (b) RL 算法仅学习代理策略网络参数来采取行动。

在[45]中，作者使用基于模型的强化学习，其中导航策略是通过去中心化策略共享多代理场景中的现实世界交互和来自深度转换模型的虚拟数据来训练的。过渡模型以自我监督的方式进行训练，可以预测未来的观察结果并生成用于政策训练的模拟数据。在[44]中，作者使用广义计算图和循环神经网络将基于模型的强化学习与无模型强化学习结合起来。代理（本例中的遥控汽车）通过在真实环境中使用单目摄像头进行训练，在几个小时内直接学习，并且表现优于 1 步和 N 步双 Q 学习。基于模型的部分根据当前状态和动作预测下一个状态，并使用交叉熵损失优化器修改模型以降低下一个状态的碰撞概率。模型范围控制无模型和基于模型的因子的数量，基于模型的部分固定为 3.6 m 前瞻。该汽车的平均行驶距离为 52.4 m，而 DQN 的平均行驶距离为 7.2 m。

虽然无模型技术样本效率低下并且导致收敛缓慢，但它们的性能被认为是最先进的。在以下部分中，将讨论无模型强化学习方法。

3.4. Deep Reinforcement Learning

为了解决高维状态空间中的维数灾难问题，*Q*-learning中的最优动作值函数Q可以通过近似值函数进行参数化，并将Q表的更新问题转化为函数拟合问题[46]，其中*Q*-values为 $Q(s, a; \theta) \approx Q(s, a)$ 其中 θ 是 *Q*-网络参数。

2013年，Google DeepMind提出了第一个深度*Q*-网络（DQN），它将卷积神经网络与强化学习中的*Q*-学习算法相结合，并将其应用于一些Atari游戏中[47]。 2016年3月，DeepMind团队开发了围棋游戏系统AlphaGo，并以4:1的战绩击败了世界围棋冠军李世石[44]。 2017年1月，AlphaGo升级版大师以3-0战胜世界顶级围棋大师柯洁。 AlphaGo 零 [48,49] 在不使用任何人类训练的情况下通过自对弈击败了所有以前的 AlphaGo 版本。代理还可以被训练来玩 FPS 游戏，仅接收像素和游戏得分作为输入 [50]。

DRL 已广泛用于解决自主路径规划和避免碰撞的问题。一般来说，神经网络是由在奖励函数引导的虚拟环境中交互的代理来训练的。神经网络将图像或激光雷达数据以及相对目标位置作为输入并输出运动，进而接收奖励。神经网络的目标是找到一种选择最佳可能行动并最大化奖励的策略。这可以通过改进 *Q* 值或直接策略来完成。静态环境下优先采用传统算法进行全局运动规划，然后采用深度强化学习算法进行动态避障[51]。

3.4.1.基于价值的方法

无模型强化学习可以进一步分为基于价值、策略和基于行动者批评家的方法。基于价值的DRL算法使用深度神经网络（DNN）来逼近价值函数，并使用时间差（temporal Difference，TD）学习或*Q*学习分别更新价值函数或动作价值函数，以激励机器人和其他智能体获得最优路径规划[14]。

数据质量网络

继 Google 的 DeepMind 在 2013 年提出 DQN 后，2015 年，Mnih 等人。改进了该算法，并用它玩了 49 个 Atari 游戏，无需更改不同游戏的任何参数，并且仅以像素和分数作为输入，表现接近人类玩家 [52]。 2016 年，[53] 中的作者首次使用开发的 DQN 来解决移动机器人路径规划问题，仅使用深度相机。

Q-学习算法通过机器人在环境中感知的信息不断优化策略，以达到最佳性能。它是最有效和最基本的强化学习算法之一，它使用贪心策略来选择动作，并且可以在不知道模型的情况下保证算法的收敛性[51]。

如图 5 所示，交互数据元组 {s, a, r, s ’ } 从环境中收集，并通过随机选择的策略存储在重放内存中，以更新网络参数。这样做是为了减少数据相关性并减少过度拟合。在 DQN 中，使用 ∈ 贪婪策略来选择操作。维护网络的两个副本，即预测网络和目标网络。预测网络使用当前状态和动作来预测 *Q* 值，网络参数为 θ，而目标网络则使用网络参数 θ'，使用同一元组的下一个状态，并且

预测该状态的最佳 Q 值，称为目标 Q 值。 Q 值使用以下等式更新：

$$Q'(s_t, a_t, \theta) = Q(s_t, a_t, \theta) + \alpha([r_t + \gamma Qmax(s_{t+1}, a_{t+1}, \theta')] - [Q(s_t, a_t, \theta)]) \tag{6}$$

其中 α 是一个称为学习率的超参数。预测网络中的参数不断更新，但目标网络的参数在每N次迭代后从预测网络中复制。均方误差损失函数与梯度下降一起使用来寻找最优值。损失函数如下：

$$L = \frac{1}{n}\sum([r_t + \gamma Qmax(s_{t+1}, a_{t+1}, \theta')] - [Q(s_t, a_t, \theta)])^2 \tag{7}$$

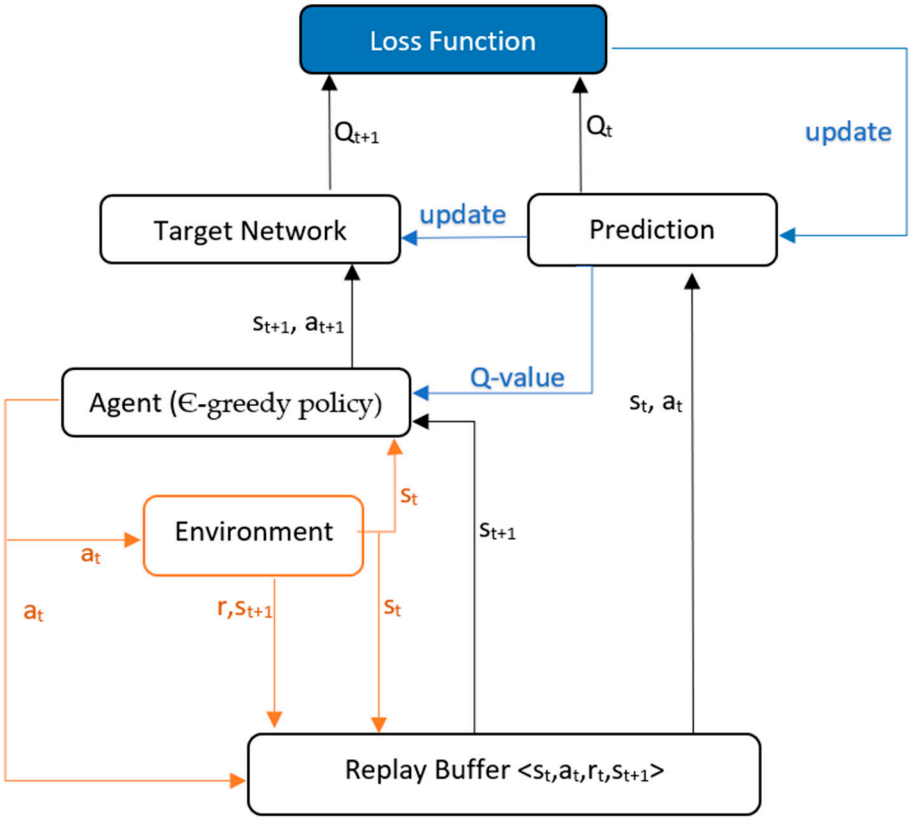

图 5. DQN 算法流程图 -（代理根据预测网络中的 Q 值采取操作，然后环境给出奖励和下一个状态，这些值存储在重播缓冲区中。预测网络从重播缓冲区中预测状态和操作的 Q 值，目标网络预测下一个状态（来自重播缓冲区）和下一个操作（由代理给出）的 Q 值。使用 Q 值和下一个 Q 值计算损失并更新预测网络，每隔几集将预测网络参数复制到目标网络）。

损失函数的值减少了。预测网络参数。这可以使用 SGD 来实现，SGD 是一种在线算法，它在处理每个训练样本后更新参数，而不是等待所有样本处理完毕后再更新参数，这使得 SGD 对于大规模问题非常有效，但也会使优化过程充满噪音且收敛缓慢；或者使用 Adam（自适应矩估计），这是另一种基于 SGD 的优化算法，可用于最小化目标函数。 Adam 使用自适应学习率，根据梯度的一阶矩和二阶矩调整每次迭代的步长。使用价值函数的当前估计来更新价值函数的过程也称为引导。

离策略算法独立于代理的决策来学习价值函数。这意味着行为策略和目标策略可以不同。第一个是代理用来探索环境和收集数据的策略，而第二个是代理尝试学习和改进的策略。这意味着代理可以使用某些行为策略完全随机地探索环境，并且可以使用数据来训练可以获得非常高回报的目标策略。另一方面，如果我们使用同策略算法，则行为和目标策略必须相同。这些算法从我们正在尝试学习的相同策略收集的数据中学习。在 DQN 中，使用 ϵ 贪婪策略来选择动作，并且 ϵ 的值在训练过程中发生变化，使得机器人在开始时进行探索，然后再利用奖励动作，使其成为一种离策略方法。

在[54]中，作者使用 DQN 训练代理在 DeepMind 实验室平台的模拟环境中收集苹果并避开柠檬。他们使用 80 × 80 灰度相机图像作为网络的输入。奖励函数非常简单，对苹果给予正奖励，对柠檬给予负奖励。结果表明，即使存在静态障碍，智能体也无法获得完美的奖励。在[4]中，作者改进了 DQN 和奖励函数来训练巡逻机器人在圆形路径上移动，同时避开障碍物。在[55]中，作者开发了一种自主无人机，以使用 DQN 拦截其他自主无人机。该模型未在真实无人机上进行测试，仅考虑二维网格世界进行模拟。

DDQN

基于DQN强化学习算法的机器人运动规划过程中还存在两个问题：一是Q值容易高度估计，二是样本相关性仍然较高。为了解决这两个问题，Van 等人。 [56]使用了基于双神经网络的双DQN算法。一个网络选择最优动作，另一个网络估计价值函数，可以更好地解决问题。

DQN 的目标值项也可以写为：

$$r_t + \gamma Qmax\left(s_{t+1}, a_{t+1}, \theta'\right) = r_t + \gamma Q\left(s_{t+1}, argmax_a Q(s_{t+1}, a_{t+1}; \theta'\right), \theta'\right) \tag{8}$$

这里，动作选择和 Q 值计算都是使用目标网络找到的。在双 DQN 中，动作选择由预测网络执行，而 Q 值由目标网络计算，如式（9）所示。结果发现，通过使用 DDQN 代替 DQN，可以解决高估问题，而无需任何额外的计算成本。

$$Q'(s_t, a_t, \theta) = Q(s_t, a_t, \theta) + \alpha\left(\left[r_t + \gamma Q\left(s_{t+1}, argmax_a Q(s_{t+1}, a_{t+1}; \theta), \theta'\right)\right] - \left[Q(s_t, a_t, \theta)\right]\right) \tag{9}$$

该解决方案首先由[46]应用于移动机器人路径规划。作者在激光雷达视图的观察窗口边缘找到了最接近全局路径的可访问点，并将其定义为局部目标。然后，他们使用 DDQN 来寻找路径，并使用惩罚每一步的奖励函数。 Schhaul[57]在DDQN的基础上提出了一种基于优先采样的DDQN网络。采用优先采样代替均匀采样，加快算法的收敛速度[14]。在[10]中，作者将 DDQN 与 DQN 以及带有优先体验重播 (PER) 的 DDQN 进行了比较。与 DDQN 相比，DQN 的 Q 值更高，但这是由于高估并且该值在训练后期下降。此外，具有 PER 的 DDQN 的奖励收敛得更快，但最终获得的值较低。在[58]中，路径规划任务分为回避模块、导航模块和动作调度器。局部避障由双流 Q 网络处理空间和时间信息，两者都使用带有经验回放的 DDQN，允许网络从特征而不是原始信息中学习。导航模块有在线和离线部分，其中离线部分在空白中进行训练

使用只有一个隐藏层的 Q-学习算法的环境。回避模块和离线导航模块分别训练，然后用于训练导航模块的在线部分。动作调度器最初使用回避模块和离线导航策略来收集状态动作奖励元组以进行经验回放，用于训练在线导航策略。

D3QN

Dueling DQN算法将Q值分解为状态值和优势值，从而提高了网络的学习效率[51]。优势值显示了在给定状态下选择一个动作相对于其他动作的优势有多大，并且没有必要知道每个动作在每个时间步的值。它显示了当前行动和平均绩效之间的差异。决斗架构与某些算法增强的集成导致在要求苛刻的 Atari 领域中比传统深度 RL 方法取得了重大进步 [59]。在[59]中，作者给出了 Atari 游戏 Enduro 的一个例子，在该游戏中，在碰撞即将发生之前没有必要知道要采取哪个动作。通过显式分离两个估计器，决斗架构可以了解哪些状态有价值（或没有价值），而不必了解每个动作对每个状态的影响：

$$A(s,a) = Q(s,a) - V(s) \tag{10}$$

其中$A(s$、$a)$是在状态s下采取行动a的优势。首先，将网络分成两个单独的流，一个用于估计状态值，另一个用于估计状态相关的动作优势。在两个流之后，网络的聚合模块组合状态值和优势输出。有三种方法可以做到这一点：简单的加法、减去最大值和减去平均值，其中减去平均值被发现可以给出最稳定的结果，如下所示[60]。

$$Q(s,a;\theta,\alpha,\beta) = V(s;\theta,\beta) + A(s,a;\theta,\alpha) - \frac{1}{|A|}\sum_{a'\epsilon A} A(s,a';\theta,\alpha) \tag{11}$$

其中θ表示卷积层的参数，而α和β是全连接层的两个流的参数[59]。在[61]中，作者使用 D3QN 网络来训练 TurtleBot 避开障碍物。他们还使用全卷积残差网络从 RGB 图像预测深度图像，并使用 FastSLAM 制作环境的 2D 地图。在[16]中，作者仅使用 RGB 相机作为输入，因为小型无人机无法处理 LiDAR 或深度相机，并且许多无人机预先配备了单目相机。他们使用全卷积残差网络，通过使用 Kinect 相机来训练网络，从 RGB 图像中获取深度图像。此外，由于 FCRN 输出的深度图像不准确，用于训练避障网络的深度图像会因添加噪声和模糊而受到损坏。深度图像是 D3Q 网络的输入，该网络输出线速度和角速度。奖励函数的设计使机器人尽可能快地移动，并因在同一位置旋转而受到惩罚。该情节在 500 步后结束，或者与惩罚发生碰撞。该模型首先在简单环境中进行训练，然后在复杂环境中进行训练。该机器人在没有任何碰撞的静态环境中进行了测试，并且训练速度是 DQN 的两倍。在[62]中，作者通过添加奖励塑造和集成 n 步引导来修改 D3QN。奖励函数包括基于潜力的奖励值，如果智能体更接近目标并朝着目标定位，则会给予更多奖励。与单步 TD 不同，单步 TD 一次仅对一个具有奖励的转换进行采样，而 n 步 TD 对“ n ”个连续转换进行采样，并且与单步 TD 相比，可以获得更多信息。在三个测试环境中，成功率比 D3QN 分别提高了 174%、65% 和 61%。

3.4.2.基于政策的

虽然基于价值的强化学习运动规划方法具有简单的优点，但它也有一些缺点：基于价值的强化学习是一种间接获得最优策略的方法。根据价值函数，通过贪心策略选择具有最佳价值的动作。每次面对相同的状态，选择的动作都是相同的。 DQN 也不适合连续控制或较大动作空间的场景，因为 DQN 的输出动作值是离散且有限的。基于价值的强化学习通过价值函数和策略进行迭代优化，其缺点是计算效率较低[14,51]。

策略梯度不是学习价值函数，而是直接尝试优化策略函数π。基于策略的方法没有目标网络，操作概率根据采取该操作收到的回报进行更新。

$$\pi(a|s,\theta) = P\{A_t = a, S_t = s, \theta_t = \theta\} \tag{12}$$

为了找到最佳策略，评估函数 J (的梯度如下所示) w.r.t. θ 的计算[41]：

$$J(\theta) = \sum\nolimits_{\pi} \pi(a|s,\theta) Q^{\pi}(s,a) \tag{13}$$

$$\nabla_{\theta} J(\theta) = \sum\nolimits_{\pi} \nabla_{\theta} \pi(a|s,\theta) Q^{\pi}(s,a) \tag{14}$$

$$\nabla_{\theta} J(\theta) = \sum\nolimits_{\pi} \pi(a|s,\theta) \frac{\nabla_{\theta} \pi(a|s,\theta)}{\pi(a|s,\theta)} Q^{\pi}(s,a) \tag{15}$$

$$\nabla_{\theta} J(\theta) = \sum\nolimits_{\pi} \pi(a|s,\theta) \nabla_{\theta} log \pi(a|s,\theta) Q^{\pi}(s,a) \tag{16}$$

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi}[\nabla_{\theta} log \pi(a|s,\theta) Q^{\pi}(s,a)] \tag{17}$$

基于策略的方法有很多缺点，因为它们对策略参数的初始化敏感，样本效率低，可能陷入局部极小值，并且性能差异很大。为了解决这些问题，引入了批评家网络来检查策略所采取的行动，这被称为演员批评家方法。

3.4.3.演员评论家

基于Actor-Critic（AC）的运动规划方法结合了策略梯度和价值函数，包括Actor和Critic两部分。其中，actor是相当于策略梯度的策略函数，负责生成动作并与环境交互。 Critic使用类似于DQN的价值函数来计算每一步的价值，得到价值函数。然后，价值函数用于评估演员的表现并指导演员下一阶段的行动[51]。

DDPG

深度确定性策略梯度（DDPG）[63]基于策略梯度、单步更新、减少方差的经验回放、参考目标网络和噪声注入的优点来鼓励探索并防止策略陷入局部极小值。参与者使用策略梯度来学习策略并在给定环境中选择机器人动作。相比之下，批评者使用 Q 值来评估演员的行为，这与 DQN 类似。不同之处在于，DQN 中的目标网络在 N 步后采用预测网络的参数，但在 DDPG 中，目标网络参数 φ' 更新为 $(1-\tau)\varphi' + \tau\varphi$，其中 τ 是一个小增益。 DDPG 是一种离策略方法，因此需要经验重播，从而使其样本效率更高。由于动作空间是连续的，因此函数 Q(s, a) 被假定为

关于参与者网络参数是可微的。因此，我们可以用 $\max_{\pi}Q(s,\pi(s))$ 来近似它，而不是每次希望计算 $\max_{a}Q(s, a)$ 时都运行昂贵的优化子例程。策略梯度可以通过两个偏导数相乘得到。一种是从批评家网络获得的 Q 值的导数。演员网络的输出动作，另一个是 w.r.t. 的动作。参与者网络的参数，如下式所示。

$$\nabla_{\theta^{\pi}}Q(s,a|\theta^{Q}) = \nabla_{a}Q(s,a|\theta^{Q}).\nabla_{\theta^{\pi}}\pi(s|\theta^{\pi}) \tag{18}$$

批评网络使用均方误差损失函数来更新网络参数，类似于基于值的方法。算法流程图如图6所示。

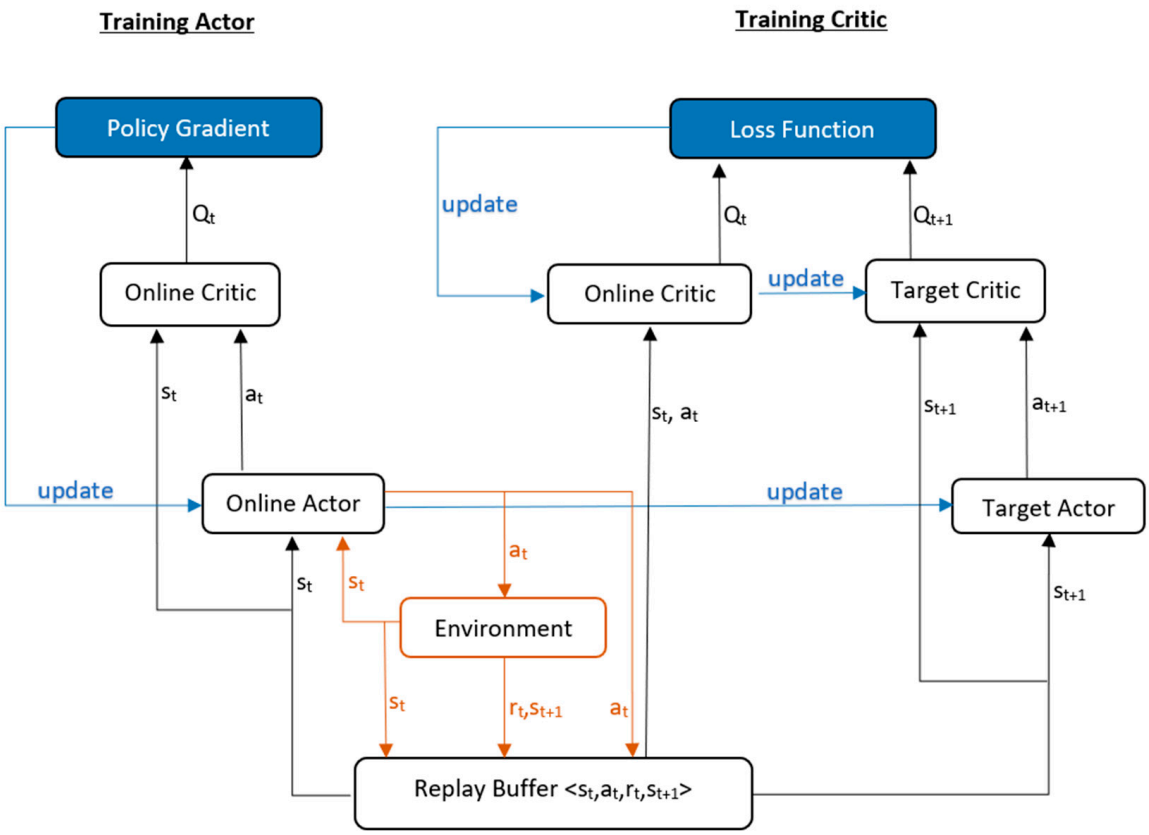

图 6. DDPG 算法流程图——（在线 actor 在环境中采取步骤，（状态、动作、奖励、下一个状态）元组存储在重播缓冲区中。在线批评者根据存储在重播缓冲区中的状态和动作预测 Q 值，而目标批评者从下一个状态（来自重播缓冲区）和下一个动作（来自目标参与者）预测下一个 Q 值。Q 值和下一个 Q 值用于计算损失并更新在线批评者。在线评论家网络参数用于每隔几集更新目标评论家网络，使用在线评论家计算的策略梯度更新在线演员网络参数，用于每隔几集更新目标演员网络。

在[37]中，作者使用多智能体DDPG算法来开发同步目标分配和路径规划，以实现无人机的协同控制。在这种情况下，评论家网络也从其他智能体获取信息，而行动者网络从一个智能体获取观察信息。该网络在具有威胁区域和其他代理的 2D 环境中进行训练。 150,000 次训练后网络变得稳定。在[64]中，比例控制器不是随机探索，而是用来驱动智能体直线朝目标前进，这加速了用于局部路径规划的DDPG算法的训练。评论家网络是一个 D3QN，决定是否 Q 值

行动网络优于控制器建议的行动并采取适当的行动。该网络在从空到稠的三种环境中进行训练，以实现迁移学习。在[65]中，作者使用RAdam优化器对DDPG进行了改进，其性能优于自适应学习率优化方法、SGD和Adam优化，并将其与好奇心算法相结合，提高了成功率和收敛速度。优先经验回放，即高奖励的经验有很高的概率被选中进行训练，并且还使用了迁移学习来提高结果。与原始DDPG算法相比，收敛速度提高了21%（15 h到11 h），成功率从50%提高到90%。

在[11]中，作者使用异步DDPG来规划本地路径。该网络仅采用10维激光数据来检测周围环境和相对目标位置作为输入，并输出连续的线速度和角速度命令。使用稀疏激光读数可以使网络在虚拟环境中接受训练后在真实环境中表现更好。样本收集过程由一个单独的线程负责，因此给它一个异步名称。据观察，DDPG 每次反向传播迭代都会收集一个样本，而并行 ADDPG 收集的样本数量几乎是其四倍。该网络与 ROS 中的 move-base planner 及其简化的 10 维输入版本进行了比较。结果发现，10D 简化的移动基地规划器需要人工干预才能完成任务，而 ADDPG 和移动基地规划器完成任务并执行类似的操作，但这两个版本的移动基地规划器都需要预先构建的障碍物地图来规划路径。作者预测，如果网络使用 LSTM 和 RNN，它的性能会更好。在[66]中，作者使用带有卷积层的DDPG作为输入（即顺序深度图像）来回忆机器人外围的障碍物，因为相机的视野较小。使用稀疏激光数据和 Erle-Rover 避障 ROS 包将该网络与 ADDPG 进行比较。尽管 ADDPG 的路径长度最短，但由于它仅使用激光传感器数据，只能看到一个水平面，只能看到风扇或椅子的杆子，但需要人工干预才能绕过此类障碍物。 CDDPG 还进行了动态障碍测试，表现令人满意。

为了进一步改善 DDPG 中的高估问题，双延迟 DDPG 使用两个目标批评网络，并且这两个网络中较小的一个用于损失函数计算。第二个目标网络在第一个目标网络更新后延迟几步进行更新。

在[67]中，作者将孪生延迟 DDPG (TD3) 与概率路线图算法相结合，并首先在 2D 环境中训练，然后在简单 3D 环境中训练，最后在复杂 3D 环境中训练。该网络与 A* + DWA、A* + TEB 和 TD3 进行比较，结果发现其性能优于所有三个网络。 TD3 还与 PPO、DDPG 和 SAC 进行了比较，发现其中表现最好。策略函数的更新频率是 Q 函数更新频率的一半。在[45]中，作者使用TD3方法来学习路径规划，该方法从去中心化策略共享多智能体场景中的现实交互和深度转换模型的虚拟数据中学习。 LiDAR 数据用于制作本地地图，有助于区分静止和移动障碍物并预测动态障碍物的未来位置，如图 7 所示。将该网络与 FDMCA 和 MNDS 导航方法进行比较，发现其性能优于两者。上述论文的摘要如表 1 所示。

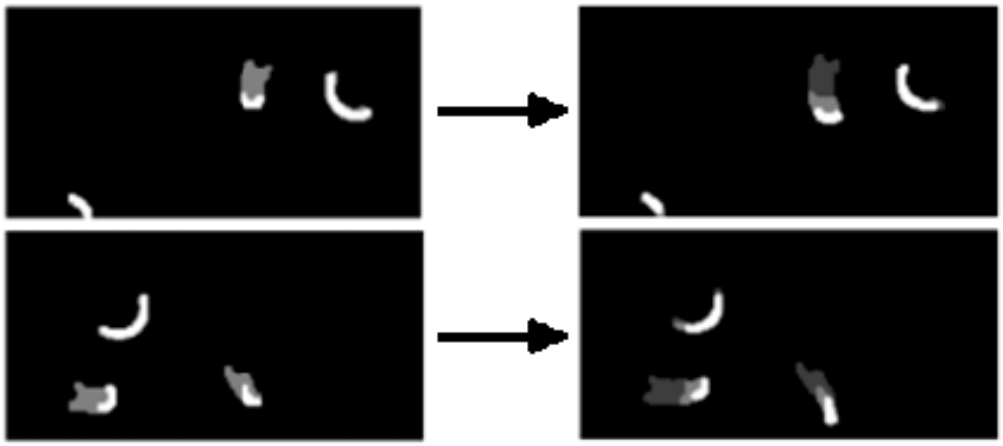

(**a**) Detection (**b**) Prediction

图7.解开的自我图[45]（图显示了动态和静态障碍物的LiDAR扫描。（a）部分以白色显示障碍物的当前位置，以灰色显示先前位置，（b）部分显示使用先前位置数据从网络预测的障碍物未来位置的期望。深灰色是先前位置数据，浅灰色和白色部分是预测）。

表 1. DDPG 方法摘要。

Ref.	Network Input	Network Output	Training	Reward Function	Optimization	Testing	Remarks
[64]	Last 3 laser scans, Velocity, Target position	Not mentioned	Stage, Gazebo	Collision penalty, Goal reward, Change in goal relative distance reward	Proportional controller assist	Real environment with static obstacles	Trains faster, less sensitive to network structure, better than DDPG
[65]	20D laser data	Angular and linear velocity	Gazebo	Collision penalty, Goal reward, change in goal relative distance reward	Curiosity module, RAdam optimizer, priority experience, transfer learning	Gazebo with dynamic obstacles	Convergence speed + 21%, success rate increased to 90% from 50%
[11]	10D laser data, target position, velocity,	Angular and linear velocity	V-Rep	Collision penalty, goal reward, change in goal relative distance reward	Asynchronous training	Real environment with static obstacles	Mapless navigation capability
[66]	Last 10 depth images, target position	Angular and linear velocity	Gazebo	Collision penalty, goal reward, turning penalty		Real environment with dynamic obstacles	Successful navigation with dynamic obstacles
[67]	10D laser data, velocity, target position	Angular and linear velocity	Gym, Gazebo	Collision penalty, goal reward, change in goal relative distance reward	Transfer learning	Gazebo with dynamic obstacles	Performs comparable to traditional methods
[45]	Last 10 laser scans, velocity, target position	Angular and linear velocity	Gazebo	Collision penalty, goal reward, change in goal relative distance reward, close to static and dynamic obstacles penalty	Disentangle ego motion, Conv. LSTM layer	Real environment with dynamic obstacles	Performs better than FDMCA and MNDS [45]

A3C

异步优势行动者批评家（A3C）[68]是标准行动者批评家算法的扩展，它使用多个并行的行动者学习者线程同时学习策略和价值函数，如图8所示。它可以从大量并行经验流中学习，这使得算法学习得更快。 A3C还使用优势函数（如D3QN）来缩放策略梯度，这有助于稳定学习过程并提高收敛速度。 A3C 是一种 on-policy 方法，这意味着它不需要经验重放缓冲区。它比 DDPG 更能适应超参数调整，因为 DDPG 对超参数的选择很敏感，例如

学习率和折扣因子。 A3C 仅限于具有离散动作空间的环境，而 DDPG 可以处理连续动作空间。

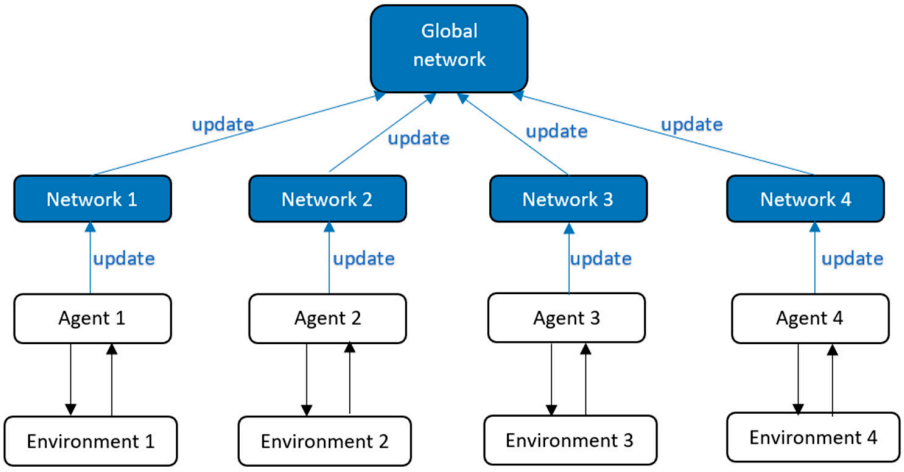

图 8. 异步代理学习（代理的多个实例与各自的环境交互并更新全局网络，在 N 个步骤后将其复制到各个网络）。

在 A3C 中，策略参数更新为

$$\theta = \theta + \alpha \nabla_\theta log \pi_\theta(a_t|s_t) A(s_t, a_t) + \beta \nabla_\theta H(\pi(s_t;\theta) \tag{19}$$

其中H是熵，α和β是网络参数。

在[69]中，作者从 RGB 相机图像构建了深度图像，并训练网络在使用 SLAM 闭环之前预测当前位置是否已被访问过。 A3C 网络的输入包括 RGB 图像、速度、先前选择的动作和奖励。他们没有使用深度作为输入，而是将其作为额外的损失，并发现它对学习过程更有价值。

在[7]中，作者开发了一种搜索救援机器人，可以在崎岖地形中导航到达目标。 ROS O ctomap 包用于从深度图像生成高程图。该方法对新环境具有鲁棒性，对于 90% 可遍历的地图，成功率约为 85%；对于 80% 可遍历的地图，成功率约为 75%。在[70]中，代理在带有地图的迷宫中随机生成。智能体必须首先找到它在地图上的位置，然后使用地图到达目标。不同的模块用于完成不同的任务。可见的局部地图网络构成局部地图。循环定位单元用于通过制作以自我为中心的局部地图并将其与给定地图进行比较以找到当前位置，从而基于局部地图来查找给定地图上的位置概率分布。地图解释网络在原始地图中找到奖励位置，尝试对其进行定位，并在了解地图上的墙壁、目标位置和其他奖励位置的同时找到到达目标的方法。作者使用 A3C 学习来训练反应代理和定位模块。他们还利用优先重放缓冲区来训练离策略，这对于 A3C 来说是非常规的。在训练期间，代理能够在大约是最大迷宫大小三倍的随机迷宫中找到目标。在[71]中，作者使用 Siamese actor-critic 方法，让代理只需在虚拟环境中拍摄目标视图图像即可到达目标，而不需要对环境进行 3D 重建。代理的多个实例与不同的目标并行训练。该模型与具有 4 个并行线程的常规 A3C 网络以及没有场景特定参数的 Siamese 网络的变体进行了比较，并且性能优于该网络。在[17]中，代理使用G A3C学习方法，从LiDAR和深度相机中获取融合数据，并输出线速度和角速度。 GA3C 是一种基于模型的 RL 方法，仍然使用 A3C 代理的大规模并行性，但每个代理不再拥有自己的全局网络副本。来自深度相机的点云数据被转换为 2D 激光扫描

使用ROS包与激光扫描数据融合。将噪声添加到输入数据中以避免过度拟合。该模型不是在 Gazebo 上进行训练，而是在用 C++ 编写的模拟器上进行训练，使用 AVX for SIMD 命令进行同步训练。该网络在真实环境中进行了测试，但只有静态障碍。在[72]中，作者使用GA3C来解决多智能体碰撞避免问题。附近智能体的状态被输入 LSTM 网络，最终状态与自我智能体的状态连接起来。该网络被命名为 GA3C-CADRL，并与 CADRL 进行比较，发现由于使用 LSTM 层来组合其他智能体的状态，因此与 CADRL 相比，该网络可以处理更多的智能体。在[73]中，作者使用 A3C 和好奇心模块进行路径规划。使用单独的神经网络根据当前状态和动作预测下一个状态，并将其与采取该动作后的实际下一个状态进行比较。预测的下一个状态与实际的下一个状态之间的差异用于检查该区域是新的还是已经探索过的。对于更大的差异，给予更多的内在奖励来激励探索。在初始 CNN 和输出层之间使用两个 LSTM 层，以便代理可以记住不同的环境观察结果。在[74]中，作者采用 A* 技术进行全局路径规划。然后利用激光雷达扫描数据来识别边界，边界根据激光雷达扫描范围和存在的障碍物而变化。从这些边界中，选择子目标作为本地路径规划器的临时检查点。采用 A3C 策略，并辅以 LSTM RNN，进行局部路径规划。与 CADRL、TED 和 DWA 相比，该网络表现出优越的性能。上述论文的摘要如表 2 所示。

表 2. A3C 方法摘要。

Ref.	Network Input	Network Output	Training	Reward Function	Optimization	Testing	Remarks
[69]	Last 3 RGB images, previous action, previous reward, agent velocity,	Rotation in small increments, accelerate forward, backward, and sideways, rotational acceleration.	Deepmind lab	Goal reward, reward in the maze to encourage exploration	Loop closure on position, RGB to depth conversion as loss function, stacked LSTM layer	Deepmind lab with static obstacles	Auxiliary tasks improve algorithm's performance
[7]	Elevation map, depth image, Agent orientation, relative goal position	Forward, backward, turn left and right	Gazebo	Goal reward, change in goal relative distance reward, undesirable terminal position penalty	LSTM layer	Gazebo with static obstacles	Navigation capability in unknown environment, 80% success rate
[70]	Last ego-motion estimation, goal orientation, last action, last reward, Maze Map, RGB image	Forward, backward, left, right, turn left and right.	DeepMind lab	Collision penalty, goal reward, relative distance to the goal Entropy of location probability distribution	Prioritized experience replay, modular Tasks	DeepMind lab with static obstacles	Agent learns to localize on map
[71]	Last 4 RGB images, target image	Forward step, 90-degree turn	AI2-THOR	Goal reward, time penalty		Real environment with static obstacles	AI2-THOR renders virtual environment close to real world thus algorithm performs better in real world.
[17]	Last 4 laser scans, target position	7 discrete actions	Custom for fast parallel training	Goal reward, Collision penalty, change in goal relative distance reward, undesirable terminal position penalty	Add noise to the input	Real environment with static obstacles	Simulations run 1000 times faster than conventional methods
[72]	Goal distance, obstacle position and velocity, distance to obstacle	11 discrete actions		Collision penalty, Goal reward, close to obstacle penalty	LSTM layer	Real environment with dynamic obstacles	Introduction of LSTM Layer improves performance
[73]	Current state, last action, last reward	8 discrete actions	DeepMind lab, Gazebo	Goal reward, collision penalty, change in goal relative distance reward, intrinsic reward	Intrinsic reward for exploration, stacked LSTM	Real environment with dynamic obstacles	Incorporating intrinsic Rewards doubled the extrinsic rewards collected

聚苯醚

近端策略优化（PPO）[75]是一种同策略强化学习方法，也使用优势函数，可以处理连续和离散控制，并且基于

TRPO（信任域策略优化）。由策略梯度法参考式（17）：

$$\nabla_\theta J(\theta) = \mathbb{E}_\pi[\nabla_\theta log\pi(a|s,\theta)Q^\pi(s,a)] \tag{20}$$

Or

$$\nabla_\theta J(\theta) = \mathbb{E}_\pi[\nabla_\theta log\pi(a|s,\theta)A^\pi(s,a)] \tag{21}$$

可以通过微分以下 w.r.t. 来获得θ：

$$J(\theta) = \mathbb{E}_\pi[log\pi(a|s,\theta)A^\pi(s,a)] \tag{22}$$

或者

$$J(\theta) = \mathbb{E}_\pi[\frac{\pi(a|s,\theta)}{\pi_{old}(a|s,\theta)}A^\pi(s,a)] \tag{23}$$

TRPO 在获取梯度之前将 Kullback-Leibler 散度添加到该评估函数中，使其：

$$J(\theta) = \mathbb{E}_\pi[\frac{\pi(a|s,\theta)}{\pi_{old}(a|s,\theta)}A^\pi(s,a) - \beta D_{KL}(\pi_{old}||\pi)] \tag{24}$$

PPO 将概率比从 $(1-\epsilon)$ 裁剪到 $(1+\epsilon)$，其中 ϵ 是一个超参数。它强制当前政策和旧政策的比率接近1，而不是惩罚政策之间的差异[76]。通过将裁剪和未裁剪概率比的最小期望值乘以优势函数来找到评估函数。

$$J(\theta) = \mathbb{E}_\pi[\min(\frac{\pi(a|s,\theta)}{\pi_{old}(a|s,\theta)}A^\pi(s,a),\ clipped\left(\frac{\pi(a|s,\theta)}{\pi_{old}(a|s,\theta)}\right)A^\pi(s,a))] \tag{25}$$

在[75]中，PPO 与 MuJoCo 环境中的 A2C、CEM、TRPO 等进行了比较。这些算法在七种环境中进行了测试，并在其中五种环境中表现优于所有其他算法。在[76]中，作者使用强化学习技术来解决轮腿机器人的路径规划问题。该策略将高度图图像观察结果映射到运动命令。他们将导航任务拆分为多个可管理的导航行为。该机器人为轮腿机器人，可以按照机器人常规动作执行诸如抬起身体越过高障碍、降低身体伸腿越过宽障碍、挤压身体通过狭窄走廊等动作。通过设置障碍物来专门教导机器人这些动作，使得机器人除了遵循这些特定动作之外没有其他方法来避开障碍物。随后，通过使用这些辅助策略训练一般策略来组合所获得的知识。为了在不运行模拟的情况下增加训练数据，场景中不改变动作序列的非必要方面（例如外观、位置和障碍物数量）被随机化，并且存储具有来自辅助策略的原始动作序列的动作-观察-返回元组，并使用来自在线探索的数据来训练主要策略。使用随机梯度上升来优化策略和价值函数。该政策的成功率约为80%。在[77]中，代理使用 PPO 来清理具有静态障碍物的未知网格环境。该网络在 5×5 环境中表现优于 DQN 和 D3QN。为了提高更大环境中的性能，输入被剪裁为仅包含八个周围的图块以及最近的未清理图块的位置。当智能体连续变得积极或没有奖励时，奖励函数还会给予额外的奖励。在 5×5 环境中训练的智能体在 20×20 环境中进行测试，其表现优于锯齿形和随机运动。

在[78]中，作者使用 PPO 在 Gazebo 中使用真实的月球表面数据模拟月球车。他们使用迁移学习来提高性能，奖励函数包括对使用地形坡度发现的漫游器滑动速率的惩罚。

流动站使用来自深度相机和激光雷达传感器的输入；数据通过 CNN 的不同层馈送到网络，然后与上一步的相对目标位置以及线速度和角速度合并。这里，政策输出是 10 个离散行动。该算法使用 Adam 优化器，并与两个参与者网络和一个评论家网络一起工作。该算法的平均成功率为 88.6%。

在[18]中，作者使用深度相机和 2D LiDAR 开发了一种防撞算法 CrowdSteer。该算法使用 PPO 进行多个阶段的训练，从不太复杂的静态场景到有行人的动态场景，然后在复杂的走廊场景中，机器人必须执行几次急转弯并避开只能在近距离观察到的行人，随后在真实环境中使用 TurtleBot 和 Jackal 机器人进行测试。据作者介绍，该算法的性能优于 DWA 和 Fan 的方法 [79]，但可能在高度宽敞的区域中表现出振荡行为，并在高度密集的环境中冻结。为了应对行人，奖励函数包括如果智能体太靠近任何障碍物的惩罚。在[8]中，作者将 PPO 与传统的 A* 搜索算法结合起来进行全局路径规划。该模型的性能优于 EPRQL、DBPQ、DDQNP 和 DWAQ。在[80]中，作者使用 Djikstra 找到一条带有检查点的近似路径，然后使用 PPO 遵循该路径，同时避开障碍，其性能甚至比 GAIL 和行为克隆更好。大约有四个检查点作为 PPO 模块的输入；该模块甚至学会了跳过检查点以更快地达到目标。上述论文的摘要如表 3 所示。

表 3. PPO 方法摘要。

Ref.	Network Input	Network Output	Training	Reward Function	Optimization	Testing	Remarks
[76]	Greyscale height map, target position, robot pose	Move in the x- and y-axis, Rotate, change height, change width	V-Rep	Collision penalty, time penalty, change in goal relative distance reward	Domain randomization	V-Rep with static obstacles	Use of domain randomized trajectory improves the output.
[77]	Surrounding 8 tiles, nearest uncleaned tile	Move forward, Turn 45 degree	Python GUI Tkinter	Cleaned tile penalty, wall collision penalty, rotation penalty, intrinsic reward	Intrinsic reward Transfer learning Elite set	Python GUI Tkinter	Navigation performed on a grid-based environment
[78]	Last 4 depth images, Last 3 laser scans, target position, velocity	10 discrete actions	Gazebo	Collision penalty, goal reward, change in goal relative distance reward, slip rate/angle penalty		Gazebo with static obstacles	Cannot reach target when target is very far or there are very large craters.
[80]	4 checkpoints, velocity, 12D laser data,	Linear and angular velocity	Unity	Checkpoint reward, time penalty, collision penalty,		Unity with static obstacles, maze-like maps	Algorithm sometimes jump checkpoints to give efficient paths.
[18]	Last 3 depth images, Last 3 laser scans, target position, velocity	Linear and angular velocity	Gazebo	Collision penalty, goal reward, change in goal relative distance reward, Close to obstacle penalty, angular velocity penalty, waypoint reward	Transfer learning	Real-world with dynamic obstacles	Susceptible to robot freezing in very dense environment, works well in complex, occluded scenarios and results in smoother trajectories
[8]	Laser scans	8 discrete actions	Custom	Collision penalty, goal reward, timestep penalty		Real-world with static obstacles.	Number of training epochs is much less compared to other methods

国家标准委员会

软演员批评家（SAC）[81]是一种深度强化学习算法，结合了演员批评家算法、最大熵模型和离线策略。作为一种离策略方法，它不需要为每个梯度步骤收集新样本。它基于孪生延迟深度确定性策略梯度（TD3）、随机策略和最大策略熵。此外，超参数更容易设置。为了防止移动机器人陷入局部最优并鼓励它们探索更多空间，SAC要求它们最大化累积奖励和最大熵[82]。 SAC的算法流程如图9所示。

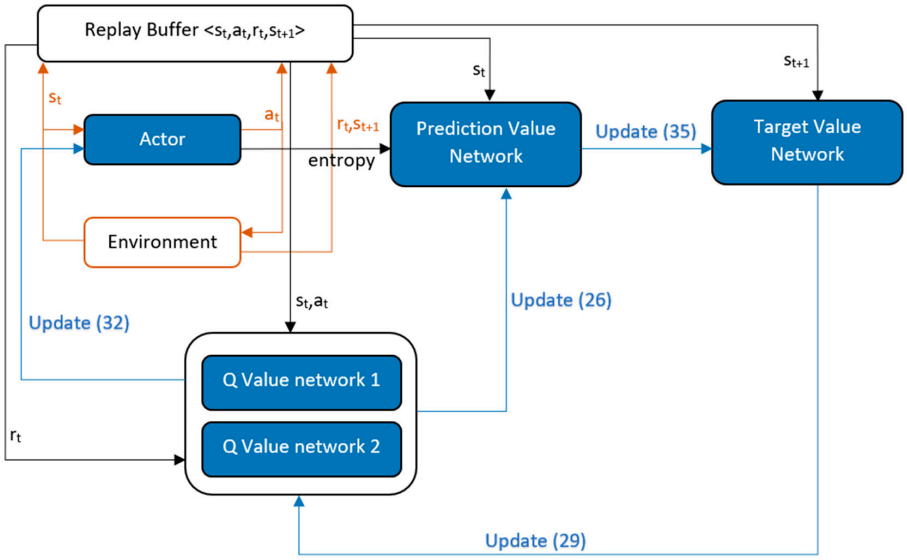

图 9.SAC 算法流程图。（更新括号中提到的方程式）。

在每个环境步骤中，策略 π_θ 采取操作，并且状态、操作、奖励和下一个状态元组保存在重放缓冲区中。然后预测值网络参数ψ更新为：

$$\psi \leftarrow \psi - \lambda_v \nabla_\psi J_v(\psi), \tag{26}$$

在哪里

$$\nabla_\psi J_v(\psi) = \nabla_\psi \mathrm{V}_\psi(s_t)\big(\mathrm{V}_\psi(s_t) - Q_\theta(s_t, a_t) + log\pi_\varphi(a_t|s_t)\big) \tag{27}$$

其源自：

$$J_V(\psi) = \mathbb{E}_{s_t \sim R}[1/2\big(V_\psi(s_t) - \mathbb{E}\big[Q_\theta(s_t, a_t) - log\pi_\varphi(a_t|s_t)\big]\big)^2] \tag{28}$$

其中 $-log\pi_\varphi(a_t|s_t)$ 是行动熵，由行动者网络给出。与 TD3 中一样，有两个 Q 值网络，两者都使用相同的算法进行更新，并且在等式（27）中选择具有较低值的一个。Q-value 网络参数 θ 更新为：

$$\theta \leftarrow \theta - \lambda_Q \nabla_\theta J_Q(\theta), \tag{29}$$

在哪里

$$\nabla_\theta J_Q(\theta) = \nabla_\theta \mathrm{Q}_\theta(a_t, s_t)\Big(\mathrm{Q}_\theta(s_t, a_t) - r(s_t, a_t) - \gamma V_{\psi'}(s_{t+1})\Big) \tag{30}$$

其源自：

$$J_Q(\theta) = \mathbb{E}[1/2\Big(Q_\theta(s_t, a_t) - \Big(r(s_t, a_t) + \gamma\mathbb{E}\Big[V_{\psi'}(s_{t+1})\Big]\Big)\Big)^2] \tag{31}$$

然后策略网络参数φ更新为：

$$\varphi \leftarrow \varphi - \lambda_\pi \nabla_\varphi J_\pi(\varphi), \tag{32}$$

在哪里

$$\nabla_\varphi J_\pi(\varphi) = \nabla_\varphi log\pi_\varphi(a_t|s_t) + \big(\nabla_{a_t} log\pi_\varphi(a_t|s_t) - \nabla_{a_t} Q_\theta(s_t, a_t)\big)\nabla_\varphi f_\varphi(\epsilon_t; s_t) \tag{33}$$

其中 Q_θ 是较低的，随机行为被分解为平均行为和标准偏差 ϵ_t。因此，该动作可以写为：

$$a_t = f_\varphi(\epsilon_t; s_t) \tag{34}$$

目标值网络参数ψ'更新为：

$$\psi' \leftarrow \tau\psi + (1-\tau)\psi' \tag{35}$$

在[81]中，作者将SAC与DDPG、PPO和TD3等其他算法的性能进行了比较，并在图10中给出了学习曲线。在[82]中，作者使用SAC让移动机器人自主避开静态和动态障碍物，用人工势方法改进奖励函数，同时规范化状态-动作对并使用优先经验来提供更快的决策。该算法在 Pygame 2D 模拟环境中进行了训练和测试，与 PPO 相比，发现性能更好。在[83]中，作者使用深度相机通过增量学习实现了 SAC，仅将一个水平面的数据作为 2D LiDAR。为了微调算法，代理在真实环境中使用监督节点进行训练，该节点检测碰撞并使用 PRM* 运动规划器和轨迹跟踪控制器将机器人移动到其起始位置。他们评估了三个不同的输入，即一帧、最后三帧和最后两帧，以及它们的差异进行比较，发现它们在相同的顺序下表现更好。在[84]中，作者将基于 SAC 的避障技术与路径规划器（在本例中为 A*）一起使用，并在虚拟环境中对它们进行训练，在虚拟环境中考虑惯性和摩擦动力学，动态障碍物遵循相同的去中心化策略，而一些动态障碍物则采用不同的策略，以实现快速学习。将结果与 PPO 进行比较，结果发现性能更好。在[85]中，作者使用 TFagents 上可用的 SAC 实现，重点研究了在有走廊和门口的封闭环境中与行人一起进行机器人导航的问题。该策略根据光学相互防撞 (ORCA) 模型对真实环境（例如超市和有行人的公寓）的 3D 重建进行增量训练。该策略与 ROS 导航堆栈进行比较，发现性能更好，因为 ROS-nav 堆栈存在机器人冻结问题；与 SARL 相比，两者的表现相似。在[86]中，作者尝试在SAC和DDPG中添加“ 基于速度范围的评估方法 ”。该技术根据速度范围提供额外的奖励。这会鼓励智能体按照预期的速度移动，并在不降低学习性能的情况下略微提高最大奖励。上述论文的摘要如表 4 所示。

表 4. SAC 方法总结。

Ref.	Network Input	Network Output	Training	Reward Function	Optimization	Testing	Remarks
[82]	Location and velocity of agent and obstacles, target location	Linear and angular velocity	Pygame	Face toward the target, move toward the target, close to obstacle penalty, terminal state reward	Prioritized experience replay, state action normalization	Pygame with dynamic obstacles	Performs better than PPO, tested in only 1 2D environment
[83]	Last 2 horizontal depth image planes and their difference, target position, last action	Linear and angular velocity	Gazebo	Goal reward, collision penalty, going toward goal reward, going away from goal penalty	Transfer learning	Real environment with dynamic obstacles	Maximum success rate is 47%
[84]	Last 3 laser scans, velocity, target position	Linear and angular velocity	Gazebo	Goal reward, collision penalty, going toward goal reward, rotation velocity penalty		Real environment with dynamic obstacles	Performed well in dynamic environment, unable to efficiently move in straight line. Might solve with more training in that environment.
[85]	LiDAR data, 6 waypoints, target position	Linear and angular velocity	Gibson	Goal reward, collision penalty, going toward waypoint reward, reaching waypoint reward, timestep penalty	Transfer learning	Gibson with dynamic obstacles	The learned policy demonstrates behaviors such as slowing down, navigating around pedestrians, and reversing to manage various interactions.

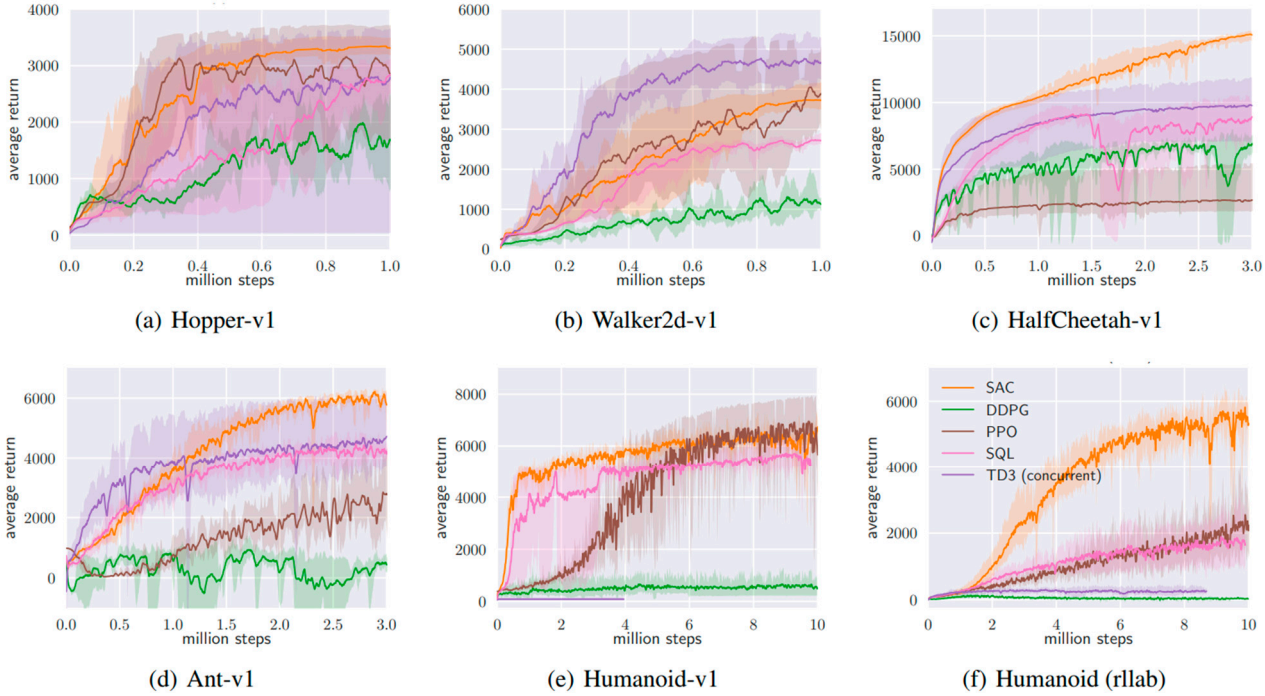

图 10. 几种 RL 方法在包括 SAC 在内的连续控制基准上的训练曲线。 [81]。

4. 将社交交互意识融入机器人导航

当机器人与人类共享同一空间时，机器人需要能够安全、适当地与人类互动，并意识到人们的个人空间，如图11a所示。为了实现这一目标，机器人需要能够以符合社会规范和环境期望的方式进行导航，从而确保安全和顺利共存。在静态环境中，移动机器人需要可靠地避免与静态物体发生碰撞，并规划到达目标位置的可行路径；在有行人的动态环境中，他们还需要以符合社会要求的方式行事，他们需要了解动态的人类行为，并根据特定的社会可接受的规则做出相应的反应。代理应该能够在图 11b 所示的情况下轻松导航。传统的解决方案可以分为两类：基于模型的和基于学习的。基于模型的方法旨在扩展具有社会兼容约束的多机器人导航解决方案。然而，社会力量参数需要针对每个特定场景进行仔细调整。另一方面，基于学习的方法旨在通过直接监督学习（例如行为克隆）或通过逆强化学习来恢复内部成本函数来直接恢复专家策略[32]。与基于模型的方法相比，基于学习的方法已被证明可以生成更接近人类行为的路径，但通常需要更高的计算成本。此外，由于人类行为本质上是随机的，因此根据行人路径计算的特征统计数据可能因人而异，甚至在同一场景下跑步也有很大差异[87]。

在[87]中，作者对 CADRL [88] 进行了改进，添加了超车、超车和交叉的规范，以诱导多智能体系统中的社会意识行为，引入深度强化学习的社会意识碰撞避免（SA-CADRL）。遵循 CADRL 的智能体往往会遵循一些约定，从而在机器人与机器人的交互中表现更好，但这与人类的期望并不一致。在仿真中与 ORCA 和 CADRL 进行比较后，该网络在具有用于定位的 LiDAR 的差动机器人、用于自由空间检测的三个深度相机和用于行人检测的四个单目相机上进行了测试。它使用扩散图算法进行全局路径规划，并使用 SA-CADRL 进行碰撞避免。

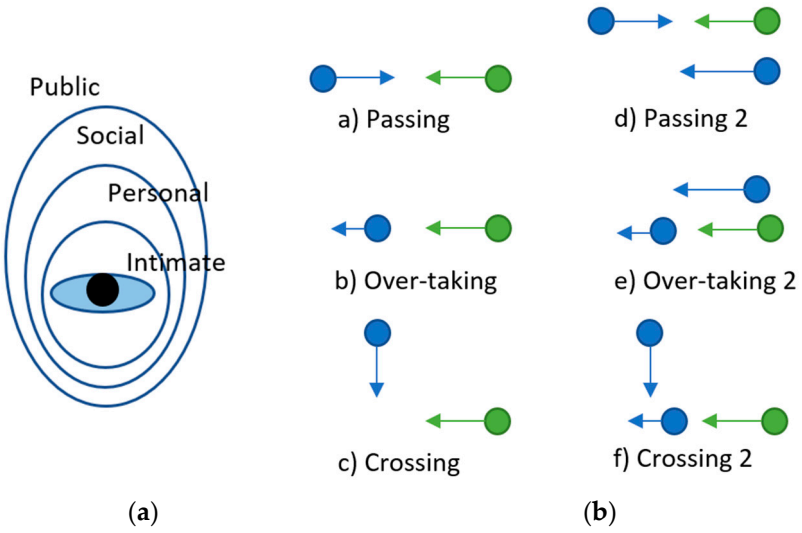

图 11.(a) 人们周围的无障碍空间； (b) 常见的导航场景。

在[32]中，作者采用了生成对抗性模仿学习（GAIL）策略，该策略改进了预先训练的行为克隆策略。行为克隆方法通过纯粹的监督学习来学习策略，但忽略了后续帧中样本之间的时间相关性；因此，它不能很好地推广到与训练数据偏差太大的场景。作者使用行为克隆来学习初始策略，然后应用 GAIL 通过获取时间相关性来改进。 GAIL 具有一个执行操作的生成器网络和一个像任何 actor-critic 方法一样的鉴别器网络。鉴别器网络使用TRPO规则来更新策略参数。行为克隆和 GAIL 网络都根据通过在使用社会力模型以符合社会规范的方式行为的模拟行人上安装深度相机收集的数据集进行训练。该方法在真实场景中的 TurtleBot 华夫饼上进行了测试。在[2]中，作者开发了一种群体冲浪方法，该方法使用 SPENCER 检测人群，并根据群体速度选择最好的可能跟随的群体，或者在行人不在附近时切换到边缘跟随进行局部规划，并使用 Google 地图进行全局路径规划。该方法生成机器人导航的子目标，这些子目标被发送到 SA-CADRL 以避免碰撞。该模型在真实环境中使用 Omron Adept Mobile 机器人的 PowerBot 进行了测试，该机器人配备了 3D LiDAR、2D LiDAR、RGBD 传感器、GPS 和 IMU。三维激光雷达用于检测人行道边缘，而RGBD传感器用于感知和跟踪行人。结果发现，行人检测参数需要根据照明条件进行调整。在[89]中，作者结合GA3C-CADRL-NSL和基于力的运动规划（FMP）来解决密集和动态环境中的运动规划问题。由于障碍物的斥力和目标的吸引力较弱，FMP 在密集环境中表现良好，但无法产生时间最优路径，使用 GA3C-CADRL-NSL 求解。目标函数是最小化达到目标的预期时间，策略函数包括熵项。该模型分多个阶段进行训练，从场景中的 2 个智能体开始到 10 个智能体，这比在相同数量的剧集中从一开始就使用 10 个智能体进行训练表现更好。 DRL-FMP 混合算法的性能优于 GA3C-CADRL、GA3C-CADRL-NSL、ORCA 和 FMP。训练和最终实验仅在 2D 和 3D 虚拟环境中进行。在[90]中，作者训练了远离不确定区域的不确定性感知代理。该代理将目标和障碍物的位置和速度作为输入，然后一组 LSTM 网络使用 bootstrapping 和 MC dropout 来预测一组动作的碰撞概率。避免发生高碰撞概率的动作。对于引导，需要训练多个网络，这些网络使用随机变量进行初始化，并在同一批次的不同批次上进行训练

数据集；因此，人们可以更有信心地采取这些网络中常见的行动。 MC dropout 用于近似不确定性并获取网络上的分布。然后，使用模型预测控制器来选择最安全的动作，并随着时间的推移增加对高度不确定动作的惩罚。该模型比在噪声增加、观测值下降、没有位置信息和速度信息的环境中没有动作不确定性的情况下训练的模型表现得更好。在[91]中，作者描述了自主移动机器人穿越十字路口并沿着人行道行驶的导航策略。该机器人使用行人按钮将自身对准十字路口附近，等待信号变绿，然后使用基于视觉的方法来检测十字路口以过马路。在[92]中，作者使用循环神经网络和 LSTM 来预测行人在不久的将来的意图。使用两组数据来训练神经网络，一组称为戴姆勒数据集，另一组称为上下文数据集。这些数据是使用放置在汽车挡风玻璃上的立体摄像机收集的。所提出的方法比其他三种现有方法（即 EKF-CV、IMM-CV/CA 和 MLP）表现更好。预测位置和实际位置用于衡量结果的表现。

5. 讨论

自主机器人从环境交互和决策中学习的能力对于它们在具有部分地图或没有地图的非结构化和动态变化的环境中的部署至关重要。与传统方法相比，这些方法相对容易编程，因为它们不需要预先编程的模型来工作，但它们仍然需要优化才能有效执行。下面讨论了 DRL 方法中可能出现的常见问题，并提供了解决这些问题的解决方案。

5.1. Challenges with DRL

● 在 DRL 方法最初实现期间定义的奖励函数仅包括达到目标的正奖励和碰撞的负奖励。因此，代理人采取行动的时间间隔很长，但无法确定行动的执行情况。机器人可能只会因碰撞而获得负奖励，因为通过随机动作达到目标的概率非常低，这可能会导致代理产生胆怯的行为。为了解决这个问题，使用了不同的技术，例如奖励塑造（其中添加接近目标或时间步惩罚的额外奖励）、内在好奇心模块（其中为探索新区域提供额外奖励）、内在奖励（如果代理逐步收集奖励则给予额外奖励）、到达全局规划器给出的航路点的奖励等。分层强化学习也被纳入其中，其中原始任务被分解为简单的任务。 ● 几乎所有 DRL 代理首先在虚拟环境中进行训练，然后在真实环境中进行微调。但虚拟环境无法完全复制真实环境，无论是照明条件、3D 模型、人体模型、机器人动力学、传感器性能还是其他复杂因素。这可能会导致代理在真实环境中表现不佳，但可以使用向输入数据添加噪声、使用低维激光数据、域随机化、迁移学习等技术来提高性能。考虑机器人动力学的虚拟训练环境也是首选。 ● 深度学习方法的一个大问题是灾难性遗忘，这意味着当网络接受新数据训练时，权重会更新，从以前的交互中学到的知识会被覆盖和遗忘。这个问题可以使用情景记忆系统来解决，该系统存储过去的数据并用新的例子重放它们，但它需要大量的工作记忆来存储和重放过去的输入。弹性权值合并通过计算Fisher信息矩阵量化网络参数的重要性来解决遗忘问题

前一个任务的权重。深度生成模型，例如深度玻尔兹曼机或变分自动编码器，可用于生成与观察到的输入密切匹配的状态。生成对抗网络可用于模仿从学习的过去输入分布生成的过去数据[93]。

5.2. Future Research Directions

● 目前，每项研究都集中在特定的环境上；尚未开发出适用于各种环境的解决方案，例如迷宫、有人类障碍的动态环境、人行道或简单的空旷环境。使用迁移学习在不同环境中训练代理可能会解决这个问题，但由于灾难性遗忘，解决方案可能不稳定。需要进一步利用和探索诸如不会发生灾难性遗忘的持续学习和使用 LSTM 网络等技术，以及人类意图检测和使用 Google 地图等服务进行全球路径规划，以开发可以在不同复杂性环境中无缝部署的移动机器人。不仅需要考虑不同类型的空间，还需要考虑不同的照明和环境条件，例如天气和自然光。 ● 正在进行的研究中，激光雷达或相机数据的预处理极其有限。端到端路径规划算法允许神经网络自行判断输入数据以找到有效关系，但可以通过增加输入数据来进一步提高决策性能。事实证明，诸如自运动解缠结之类的技术（使用两个连续 LiDAR 数据样本的差异而不是这两个样本）的性能更好。需要开发更多针对激光雷达和相机数据的方法，以提高网络的效率。 ● 使用无模型和基于模型的深度强化学习方法相结合的移动机器人路径规划的研究非常有限。该方法的优点是，由于基于模型的部分而导致计算要求较低，并且即使在没有良好的环境动力学模型的情况下也能够学习良好的策略。无模型方法可用于通过微调模型并提供更好的价值函数估计来提高基于模型的方法的性能。 ● 目前，机器人观察环境的水平非常低；一切都只被划分为可用的路径或障碍。一些同时使用摄像头和激光雷达的解决方案可以区分人类和其他障碍物，并可以使用不同的回避模块来规划路径。机器人可能需要使用对象检测模块来区分不同类型的障碍物，包括它们是否可以与之交互，例如门、楼梯、按钮等。与对象交互开辟了新的研究可能性途径。对于部署为援助机器人的机器人来说，它们应该能够学习物体的位置并快速抓取它们或将分散的物体放置在指定位置。需要开发融合传感器数据或使用不同传感器数据的不同模块的新方法。 ● DRL 的认知和理解能力需要利用人类专家的经验进一步增强。除了作为观察的视觉信息外，人类语言指令的集成也可用于提高机器人在实际部署应用中的规划性能。在某些情况下，还可以为代理提供仅包含地标的非比例或手绘地图，以帮助他们更有效地规划穿过未知环境的路径。 ● 元学习是一个相对较新的领域，正在为移动机器人的路径规划解决方案实施。它是一种机器学习，其中模型学习如何从新任务或环境中学习。元学习的目标是使模型能够快速适应新的任务或环境，而不是要求它针对每个新任务从头开始重新训练。一种常见的方法是使用“ 元学习器 ”或“ 元控制器 ”，它可以学习如何调整其他“ 基础学习器 ”的参数

或“ 基本控制器 ”，基于他们在不同任务上的表现。它可用于调整当前随机选择的超参数。该领域需要更多的研究来提供可行的解决方案。

6. 结论

随着人工智能的普及和强大计算硬件的发展，越来越多的研究正在自主移动机器人领域进行。在这篇综述中，讨论了应用深度神经网络解决移动机器人路径规划问题的不同方法。深度神经网络和强化学习的结合有望提供强大的解决方案。本综述讨论了几种方法及其应用。

虽然深度学习技术的能力无与伦比，但它们也面临着一系列挑战：它们计算密集，需要大量数据，并且对数据的复杂性很敏感。寻找最佳解决方案通常需要大量的计算资源和时间。然而，正在进行的研究已经揭示了多种可以缓解这些挑战的策略。优先体验重播 (PER) 等技术可提高数据效率，确保在训练期间更频繁地使用具有重要学习价值的数据。领域随机化技术增强了训练数据，而奖励塑造和内在奖励则增强了奖励密度，从而促进了绩效。迁移学习是一个福音，可以分阶段提升训练环境的复杂性。此外，控制器辅助在探索阶段为代理提供初步指导，为重播缓冲区播种有价值的数据。为了解决导航数据的时间维度问题，采用了基于 LSTM 的循环神经网络，增强了 DRL 方法的有效性。鉴于这些技术的优点，在使用 DRL 方法解决路径规划问题时应仔细考虑这些技术。

随着基于 DRL 的路径规划的进步及其在动态和未知地形中导航的能力的增强，很明显，这种方法对于在不确定环境中部署机器人具有重大前景。此类应用的例子非常广泛，从清洁和送货任务 [2]、商场协助 [3]、巡逻工作 [4]，到更复杂的场景，如自动驾驶、在家中帮助老年人 [5] 以及执行搜索和救援任务 [6,7]。此外，采矿、家庭服务、农业和自动化生产等行业可以从这些技术中受益匪浅[8]。

总之，随着我们在机器人和人工智能时代的前进，深度神经网络和强化学习之间的协同作用成为创建熟练、适应性强并为现实世界的挑战做好准备的移动机器人的基石。

作者贡献：Conceptualization、J.R.、X.L.和R.S.；方法论，R.S，X.L。和 J.R.；形式分析，R.S，X.L。和 J.R.；调查，R.S.；资源，J.R. 和 X.L.；数据管理，R.S.；写作——原始草稿准备，R.S.；写作——审查和编辑，X.L.和 J.R.；可视化，R.S.；监督，X.L.和 J.R.；项目管理，X.L. J.R. 所有作者均已阅读并同意手稿的出版版本。

资助：这项研究没有获得外部资助。

利益冲突：作者声明不存在利益冲突。

参考

1.伊克巴尔，J.；伊斯兰，俄罗斯；阿巴斯，S.Z.；汗，A.A.； Ajwad, S.A. 通过机电一体化系统实现工业任务自动化——从工业角度回顾机器人技术。 *Tech. Gaz.* 2016，*23*，917 – 924。 [交叉引用]2.杜，Y.；新泽西州赫瑟林顿；翁，C.L.；陈W.P.；金特罗，C.P.；克罗夫特，E.；范德洛斯，H.M.团体冲浪：基于行人的人行道机器人导航方法。 2019 年机器人与自动化国际会议 (ICRA) 会议记录，加拿大魁北克省蒙特利尔，2019 年 5 月 20-24 日；第 6518 – 6524 页。 [交叉引用] 3. Hurtado，J.V.；伦敦，L.； Valada, A. 从学习到再学习：减少社交机器人导航偏差的框架。 *Front. Robot. AI* 2021，*8*，650325。[交叉引用][PubMed]

4. 郑杰；毛，S。吴，Z。孔，P。基于深度强化学习的室内巡逻机器人改进路径规划。 *Symmetry* 2022，*14*，132。[交叉引用] 5. Ko，B.；崔，H.；洪，C.；金，J。权，O.； Yoo, C. 基于神经网络的家庭护理移动机器人自主导航。 2017 年 IEEE 大数据和智能计算国际会议 (BigComp) 会议记录，韩国济州，2017 年 2 月 13 日至 16 日；第 403 – 406 页。 [交叉引用]6.Doroodgar，B.； Nejat，G。一种基于分层强化学习的控制架构，用于杂乱环境中的半自主救援机器人。 2010 年 IEEE 国际自动化科学与工程会议论文集，加拿大安大略省多伦多，2010 年 8 月 21-24 日；第 948 – 953 页。 [交叉引用] 7. 张，K.；尼鲁伊，F.；菲科切利，M.； Nejat, G. 使用深度强化学习对未知崎岖地形环境进行机器人导航。 2018 年 8 月 6 日至 8 日在美国宾夕法尼亚州费城举行的 2018 年 IEEE 国际安全、安保和救援机器人研讨会 (SSRR) 会议记录；第 1-7 页。 [交叉引用] 8. Jin，X.； Wang, Z. 基于近端策略优化的移动机器人动态路径规划算法。 *Electron. Lett.* 2021 年，*58*，13 – 15。 [交叉引用] 9. Marin, P.；侯赛因，A.；戈麦斯，D.； Escalera, A. 基于 ROS 的自动驾驶汽车研究平台中的全局和局部路径规划研究。 *J. Adv. Transp.* 2018，*2018*，6392697。[交叉引用] 10. Feng，S.；塞巴斯蒂安，B.； Ben-Tzvi, P. 基于深度强化学习的碰撞避免方法。 *Robotics* 2021，*10*，73。[交叉引用] 11. Tai，L.；保罗，G.； Liu，M。虚拟到真实的深度强化学习：用于无地图导航的移动机器人的连续控制。 2017 年 IEEE/RSJ 国际智能机器人和系统会议 (IROS) 会议记录，加拿大不列颠哥伦比亚省温哥华，2017 年 9 月 24-28 日；第 31-36 页。 [交叉引用] 12. 勒梅罗，L.；易，D。迪亚纳蒂，M.； Mouzakitis, A. 端到端自动驾驶汽车模仿学习技术调查。 *IEEE Trans. Intell. Transp. Syst.* 2022 年，*23*，14128 – 14147。 [交叉引用] 13. Macek, K.；彼得罗维奇，I.； Peric, N. 移动机器人避障的强化学习方法。第七届高级运动控制国际研讨会论文集（目录号 02TH8623），斯洛文尼亚马里博尔，2002 年 7 月 3-5 日；第 462 – 466 页。 [交叉引用]14.赵，Y.；张，Y。 Wang, S. 基于深度强化学习算法的移动机器人路径规划综述。 *J. Phys. Conf. Ser.* 2021, *2138*, 012011。[交叉引用] 15. Wang, P. 自动驾驶中激光雷达和摄像头的比较研究。 *J. Phys. Conf. Ser.* 2021，*2093*，012032。[交叉引用] 16. 谢 L.；王，S。马卡姆，A.； Trigoni, N.通过深度强化学习实现基于单眼视觉的避障。 *arXiv* 2017，arXiv：1706.09829。 [交叉引用]17.苏尔曼，H.；杰斯特尔，C.；马歇尔，R。穆斯伯格，F.；埃尔哈吉，H.； Ardani, M. 用于室内环境中真正自主移动机器人导航的深度强化学习。 *arXiv* 2020，arXiv：2005.13857。 [交叉引用]18.梁，J.；帕特尔，美国；萨蒂亚莫西，A.J.； Manocha, D. 使用隐式多传感器融合和深度强化学习在密集人群中实时避免移动机器人碰撞。 *arXiv* 2020，arXiv：2004.03089。 [交叉引用] 19. Li，N.；何，C.；薛，J。林，L.；陈，G。傅，Y。 Lee, L. 固态 LiDAR 和基于纳米光子学的 LiDAR 传感器的进展回顾。 *Laser Photonics Rev.* 2022，*16*，2100511。[交叉引用]20.刘，W.；王，Z。刘X。曾，N.；刘，Y。 Alsaadi，F.E. 深度神经网络架构及其应用的调查。 *Neurocomputing* 2017 年，*234*，11-26。 [交叉引用] 21. Yu, J.；苏，Y。廖Y.神经网络和分层强化学习的移动机器人路径规划。 *Front. Neurorobot.* 2020，*14*，63。[交叉引用][PubMed]22。刘，K.；王L.；吴红。基于深度学习和半监督学习的宫内残留物图像识别与分析。 *IEEE Access* 2020，*8*，162785 – 162799。 [交叉引用] 23.Coşkun，M.；乌卡尔，A.；耶尔德勒姆，O.； Demir，Y。基于卷积神经网络的人脸识别。 2017 年现代电气和能源系统国际会议 (MEES) 会议记录，乌克兰克列缅丘克，2017 年 11 月 15 日至 17 日；第 376 – 379 页。 [交叉引用] 24. Abdel-Hamid, O.；穆罕默德，A.；江，H。邓，L.；佩恩，G.； Yu, D. 用于语音识别的卷积神经网络。 *IEEE/ACM Trans. Audio Speech Lang. Process.* 2014 年，*22*，1533 – 1545。 [交叉引用] 25. Nikitin，Y.；博热克，P.； Peterka, J. 带传感器支持的电力驱动器诊断的逻辑语言模型。 *Sensors* 2020，*20*，4429。[交叉引用] 26. Goldberg, Y.自然语言处理神经网络模型入门。 *J. Artif. Intell. Res.* 2016，*57*，345 – 420。 [交叉引用] 27.巴苏，J.；巴塔查亚，D.； Kim, T. 人工神经网络在模式识别中的应用。 *Int. J. Softw. Eng. Its Appl.* 2010，*4*，23-34。在线提供：https://www.earticle.net/Article/A118913（2023 年 5 月 20 日访问）。 28.张L.；张，Y。基于深度学习的室内移动机器人路径规划。 *Optik* 2020，*219*，165096。[交叉引用]

31. 奥萨，T.；帕贾里宁，J.；诺伊曼，G.；巴格内尔，J.A.；阿贝尔，P.； Peters, J. 模仿学习的算法视角。 *Found. Trends®Robot*. 2018 年，*7*，1 – 179。 [交叉引用] 32. Tai，L.；张，J。刘，M.； Burgard, W. 通过原始深度输入和生成对抗性模仿学习进行社会兼容导航。 2018 年 IEEE 国际机器人与自动化会议 (ICRA) 会议记录，澳大利亚昆士兰州布里斯班，2018 年 5 月 21-25 日；第 1111 – 1117 页。 [交叉引用] 33. Kim, D.K.； Chen, T. 用于实时自主室内导航的深度神经网络。 *arXiv* 2015，arXiv：1511.04668。 [交叉引用] 34.吴，K.；王，H。伊斯法哈尼，文学硕士； Yuan, S。通过深度神经网络在未知环境中实现实时路径规划。 *IEEE Trans. Intell. Transp. Syst.* 2020，*23*，2093 – 2102。 [交叉引用]35.Tai，L.；李，S。 Liu，M。一种无模型避障的深度网络解决方案。 2016 年 IEEE/RSJ 国际智能机器人和系统会议 (IROS) 会议记录，韩国大田，2016 年 10 月 9-14 日；第 2759 – 2764 页。 [交叉引用] 36.袁，J.；王，H。林，C.；刘，D.； Yu, D. 一种用于移动机器人动态路径规划的新型 GRU-RNN 网络模型。 *IEEE Access* 2019，*7*，15140 – 15151。 [交叉引用] 37. Chehelgami，S.；阿什塔里，E.；巴斯里，文学硕士；马苏勒，M.T.； Kalhor, A. 使用快速无碰撞路径生成器进行基于安全深度学习的全局路径规划。 *Robot. Auton. Syst.* 2023，*163*，104384。[交叉引用] 38. Wang, D.；陈，S。张，Y。动态环境中移动机器人的路径规划：模糊人工势场和可扩展神经网络。 *Artif. Life Robot.* 2020，*26*，129 – 139。 [交叉引用] 39. 卢，Y.；易，S。刘，Y。季勇。一种基于深度学习的仿生机器人路径规划新方法。 *Assem. Autom.* 2016，*36*，186 – 191。 [交叉引用] 40. 朱斯蒂，A.；古兹，J.；奇雷桑 (Ciresan)，哥伦比亚特区；他，F.-L.；罗德里格斯，J.P.；丰塔纳，F.；费斯勒，M.；福斯特，C.；施米德胡贝尔，J.；迪卡罗，G.；等人。移动机器人森林步道视觉感知的机器学习方法。 *IEEE Robot. Autom. Lett.* 2015，*1*，661 – 667。 [交叉引用] 41.萨顿，R.S.； Barto, A.G. *Reinforcement Learning: An Introduction*，第二版；麻省理工学院出版社：美国马萨诸塞州剑桥，2014 年。 42. Arulkumaran, K.；戴森罗斯，M.；布伦戴奇，M.； Bharath, A. 深度强化学习简要概述。 *arXiv* 2017，arXiv：1708.05866。 [CrossRef] 43. Huang, Q. 基于模型或无模型，强化学习方法综述。 2020 年国际计算与数据科学会议 (CDS) 会议记录，美国加利福尼亚州斯坦福，2020 年 8 月 1-2 日；第 219-221 页。 [交叉引用] 44.卡恩，G.；维拉弗洛尔，A.；丁，B.；阿贝尔，P.； Levine, S. 用于机器人导航的具有广义计算图的自监督深度强化学习。 2018 年 IEEE 国际机器人与自动化会议 (ICRA) 会议记录，澳大利亚昆士兰州布里斯班，2018 年 5 月 21-25 日；第 1-8 页。 [交叉引用]45.崔，Y.；张，H。王，Y。 Xiong, R. 学习具有社交意识的机器人导航的世界转换模型。 2021 年 IEEE 国际机器人与自动化会议 (ICRA) 论文集，中国西安，2021 年 5 月 30 日至 6 月 5 日；第 9262 – 9268 页。 [交叉引用] 46. 雷 X.；张，Z。董鹏。基于深度强化学习的未知环境动态路径规划。 *J. Robot.* 2018，*2018*，5781591。[交叉引用] 47。Mnih，V.；卡武克库奥卢，K.；银，D.；格雷夫斯，A.；安东诺格鲁，I.；维尔斯特拉，D.； Riedmiller, M. 用深度强化学习玩 Atari。 *arXiv* 2013 年，arXiv：1312.5602。 [交叉引用] 48. 银，D.；施里特威瑟，J.；西蒙尼扬，K.；安东诺格鲁，I.；黄，A。格斯，A.；休伯特，T.；贝克，L.；赖，M。博尔顿，A.；等人。在没有人类知识的情况下掌握围棋游戏。 *Nature* 2017，*550*，354 – 359。 [交叉参考] [PubMed] 49. Tang，Z.；邵，K.；赵，D。朱勇。深度强化学习最新进展：从AlphaGo到AlphaGo Zero。 *Control. Theory Appl.* 2018 年，*34*，1529 – 1546。 50.兰普尔，G.； Chaplot，D.S. 使用深度强化学习玩 FPS 游戏。 *Proc. Conf. AAAI Artif. Intell.* 2017 年，*31*。 [交叉引用] 51.Sun，H.；张，W。于，R。张，Y。移动机器人的运动规划——专注于深度强化学习：系统回顾。 *IEEE Access* 2021，*9*，69061 – 69081。 [交叉引用] 52. Mnih，V.；卡武克库奥卢，K.；银，D.；鲁苏，A.A.；维内斯，J.；贝尔马尔，M.G.；格雷夫斯，A.；里德米勒，M.；菲杰兰，A.K.；奥斯特洛夫斯基，G.；等人。通过深度强化学习实现人类水平的控制。 *Nature* 2015，*518*，529 – 533。 [交叉引用]53.Tai，L.； Liu, M. 基于 *Q* 学习网络的机器人探索策略。 2016 年 IEEE 国际实时计算和机器人会议 (RCAR) 会议记录，柬埔寨吴哥窟，2016 年 6 月 6-10 日；第 57-62 页。 [交叉引用]54.Xin，J.；赵，H。刘，D.； Li，M。深度强化学习在移动机器人路径规划中的应用。 2017 年中国自动化大会 (CAC) 会议记录，中国济南，2017 年 10 月 20-22 日；第 7112 – 7116 页。 [交叉引用] 55.陈，D.；魏，Y。王L.；洪，C.S.；王，L.-C.；Han, Z. 基于深度强化学习的四旋翼无人机追踪和逃避问题策略

58.王，Y.；他，H.； Sun, C. 学习通过模块化深度强化学习穿越复杂的动态环境。 *IEEE Trans. Games* 2018，*10*，400 – 412。 [交叉引用]59.王Z.；斯考尔，T.；赫塞尔，M.；哈瑟尔特，H.V.；兰克托，M.； De-Freitas, N. 用于深度强化学习的决斗网络架构。第 33 届国际机器学习会议论文集 - 第 48 卷 (ICML ’16)，JMLR，美国纽约州纽约市，2016 年 6 月 19-24 日；第 1995 – 2003 页。 [交叉引用] 60. 黄，Y.；魏，G。 Wang, Y. V-D D3QN：具有决斗架构的双深度 *Q* 学习网络的变体。 2018 年第 37 届中国控制会议 (CCC) 论文集，中国武汉，2018 年 7 月 25-27 日；第 9130 – 9135 页。 [交叉引用] 61. Wen，S.；赵，Y。袁X.；王，Z。张，D。 Manfredi, L. 未知环境下基于深度强化学习的主动 SLAM 路径规划。 *Intell. Serv. Robot*. 2020，*13*，263 – 272。 [交叉引用]62.尹，Y.；陈，Z.；刘，G.；郭，J。使用深度强化学习框架的无地图局部路径规划方法。 *Sensors* 2023，*23*，2036。 [交叉引用] [PubMed] 63. Lillicrap，T.P.；亨特，J.J.；普里策尔，A.；赫斯，N.；埃雷兹，T.；塔萨，Y.；银，D.； Wierstra, D. 通过深度强化学习进行连续控制。 *arXiv* 2015，arXiv：1509.02971。 [交叉引用]64.谢L.；王，S。罗莎，S.；马卡姆，A.； Trigoni, N. 使用训练轮学习：使用简单的控制器加速深度强化学习的训练。 *arXiv* 2018，arXiv：1812.05027。 [交叉引用] 65. Li，P.；丁X。孙，H.；赵S.； Cajo, R。基于改进DDPG算法的移动机器人动态路径规划研究。 *Mob. Inf. Syst*. 2021，*2021*，5169460。[交叉引用] 66.Cimurs，R.；李，J.H.；苏，I.H.连续行动空间中深度强化学习的目标导向避障。 *Electronics* 2020，*9*，411。[交叉引用] 67. 高，J.；叶，W。郭，J。 Li，Z。室内移动机器人路径规划的深度强化学习。 *Sensors* 2020，*20*，5493。[交叉引用] 68。Mnih，V.；巴迪亚，A.P.；米尔扎，M.；格雷夫斯，A.； Lillicrap，T.P.；哈雷，T.；银，D.； Kavukcuoglu, K. 深度强化学习的异步方法。 *arXiv* 2016，arXiv：1602.01783。 [交叉引用] 69. Mirowski，P.；帕斯卡努，R.；维奥拉，F.；索耶，H.；巴拉德，A.J.；巴尼诺，A.；丹尼尔，M.；戈罗申，R.；西弗雷，L.；卡武克库奥卢，K.；等人。学习在复杂环境中导航。 *arXiv* 2016，arXiv：1611.03673。 [交叉引用] 70. Brunner，G.；里克特，O.；王，Y。 Wattenhofer, R. 使用深度强化学习教机器阅读地图。 *Proc. Conf. AAAI Artif. Intell*. 2018 年，*32*。 [交叉引用]71.朱，Y.；莫塔吉，R.；科尔夫，E.；林，J.J.；古普塔，A.； Farhadi, A. 使用深度强化学习在室内场景中进行目标驱动的视觉导航。 2017 年 IEEE 国际机器人与自动化会议 (ICRA) 会议记录，新加坡，2017 年 5 月 29 日至 6 月 3 日；第 3357 – 3364 页。 [交叉引用]72.埃弗雷特，M.；陈YF； J.P. 如何利用深度强化学习在动态决策代理中进行运动规划。 *arXiv* 2018，arXiv：1805.01956。 [交叉引用] 73. Shi, H.；施L.；徐，M。黄K.-S。具有深度强化学习的移动机器人端到端导航策略。 *IEEE Trans. Ind. Inform*. 2019，*16*，2393 – 2402。 [交叉引用] 74.王X.；孙，Y。谢，Y。宾，J.；肖，J。具有地标生成器的深度强化学习辅助自主导航。 *Front. Neurorobot*. 2023，*17*，1662 – 5218。 [交叉参考] [PubMed] 75. 舒尔曼，J.；沃尔斯基，F.；达里瓦尔，P.；雷德福，A.； Klimov, O. 近端策略优化算法。 *arXiv* 2017 年，arXiv：1707.06347。 [交叉引用]76.陈X.；加迪尔扎德，A.；福克斯森，J.； Jensfelt, P. 通过深度强化学习获得轮腿机器人在复杂环境中的导航技能。 *arXiv* 2018，arXiv：1804.10500。 [交叉引用] 77. 穆恩，W.；帕克，B.； Nengroo，S.H.；金，T。 Har, D. 使用强化学习的清洁机器人路径规划。 *arXiv* 2022，arXiv：2208.08211。 [交叉引用]78.于X.；王，P。张，Z。基于学习的具有安全约束的月球车端到端路径规划。 *Sensors* 2021，*21*，796。[交叉引用] 79. Long，P.；范尔，T.；廖X.；刘，W.；张，H。 Pan, J. 通过深度强化学习实现最佳去中心化多机器人碰撞避免。 *arXiv* 2017，arXiv：1709.10082。 [交叉引用]80.Taschin，F.； Canal, O. 使用 PPO 自学车辆控制。校园人工智能。 2020 年。在线提供：https://campusai.github.io/pdf/autonomous_driven.pdf（于 2023 年 5 月 20 日访问）。 81.哈诺贾，T.；周，A.；阿贝尔，P.； Levine, S. Soft Actor-Critic：使用随机 Actor 的离策略最大熵深度强化学习。 *arXiv* 2018，arXiv：1801.01290。 [交叉引用] 82.杨，L.；毕，J。 Yuan, H. 具有深度强化学习的移动机器人动态路径规划。 *IFAC-PapersOnLine* 2022 年，*55*，19-24。 [交叉引用] 83. Chaffre，T.；莫拉斯，J.；陈汉唐，A.； Marzat, J. 具有增量环境复杂性的模拟到真实迁移，用于基于深度的机器人导航的强化学习。第 16 届国际信息学会议论文集

86. Lee HyeokSoo、Jeong Jongpil，基于速度范围的奖励塑造技术，通过 LiDAR 传感器和深度强化学习实现有效的无地图导航。 *Front. Neurorobot.* 2023，*17*，1662 – 5218。 [交叉引用]87.陈Y.F.；埃弗里特，M.；刘，M.；如何，J.P. 通过深度强化学习进行社会意识运动规划。 *arXiv* 2017，arXiv：1703.08862。 [交叉引用]88.陈YF；刘，M.；埃弗里特，M.； J.P. 如何通过深度强化学习实现去中心化非通信多智能体碰撞避免。 IEEE 国际机器人与自动化会议论文集，新加坡，2017 年 5 月 29 日至 6 月 3 日；第 285 – 292 页。 [交叉引用] 89. Semnani，S.H.；刘，H.；埃弗里特，M.；德鲁特，A.； J.P. 如何通过深度强化学习进行密集和动态环境的多智能体运动规划。 *IEEE Robot. Autom. Lett.* 2020，*5*，3221 – 3226。 [交叉引用] 90. Lutjens，B.；埃弗里特，M.； J.P. 如何利用模型不确定性估计来安全强化学习。 *arXiv* 2019，arXiv：1810.08700。 [交叉引用] 91. Chand，A.； Yuta, S. 户外移动机器人自主穿越道路的导航策略和路径规划。 2011 年第 15 届先进机器人国际会议 (ICAR) 会议记录，爱沙尼亚塔林，2011 年 6 月 20-23 日；第 161 – 167 页。 [交叉引用] 92. 萨利赫，K.；霍斯尼，M.； Nahavandi, S. 使用堆叠循环神经网络通过运动轨迹预测行人的意图。 *IEEE Trans. Intell. Veh.* 2018，*3*，414 – 424。 [交叉引用] 93. Shin，H.；李，J.K.；金，J。 Kim, J. 通过深度生成重播进行持续学习。 *arXiv* 2017，arXiv：1705.08690。 [交叉参考]

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.