提高强化学习中基于潜力的奖励塑造的有效性

Henrik Müller
L3S 研究中心
德国汉诺威 hmuller@l3s.de

Daniel Kudenko
L3S 研究中心
德国汉诺威 kudenko@l3s.de

5202beF3]GL.sc[1v70310.2052:viXra

抽象的

基于潜力的奖励塑造通常用于将如何解决任务的先验知识纳入强化学习中，因为它可以正式保证策略不变性。因此，最优政策和政策按回报排序不会因基于潜力的奖励塑造而改变。在这项工作中，我们强调了有效的基于潜力的奖励塑造对初始 Q 值和外部奖励的依赖，这决定了智能体利用塑造奖励来指导其探索并提高样本效率的能力。我们正式推导了如何使用势函数的简单线性平移来提高奖励塑造的有效性，而无需更改势函数中的编码偏好，也无需调整初始 Q 值，这在深度强化学习中可能具有挑战性且不受欢迎。我们展示了连续潜在函数在正确分配正负奖励塑造值方面的理论局限性。我们在具有稀疏和无信息奖励函数的 Gridworld 域以及 Cart Pole 和 Mountain Car 环境中实证验证了我们的理论发现，在这些环境中我们展示了我们的结果在深度强化学习中的应用。

关键词

强化学习、奖励塑造、基于潜力的奖励塑造

1 简介

奖励塑造是一种常见的方法，通过将某种形式的外部指导纳入奖励函数来加速强化学习代理的训练，从而改善对环境的探索。

在这项工作中，我们关注基于潜力的奖励塑造[12]。基于潜力的奖励塑造的主要吸引力是保证政策不变性。尽管奖励发生了变化，具有成形奖励函数的 MDP 的最优策略仍然与原始 MDP 的最优策略相同。基于潜力的奖励塑造利用潜在函数为每个状态分配善良（或潜力）的启发值，随后根据执行动作之前和之后状态潜力之间的差异得出奖励塑造。

先前对基于潜力的奖励塑造的理论评估已经给出了如何构建有效的潜力函数的指导[5, 6]，但他们忽略了奖励与状态动作值初始化之间的内在联系。虽然基于势的奖励塑造已被证明相当于通过添加势函数来改变 Q 值初始化[17]，但之前的工作尚未解决两个关键问题：首先，Q 值初始化和外部奖励如何影响基于潜力的奖励塑造中的样本效率；其次，如何修改势函数以提高样本效率而不改变对状态的编码偏好。

在本文中，我们提出了对包含恒定偏差 ε 的势函数的修改。我们证明，势函数的恒定偏差可用于稀疏奖励设置，通过减少中间奖励和初始 Q 值之间的差异来改善正形奖励和负形奖励的归因，从而提高样本效率。我们表明，扩展潜在函数本质上限制了其在终端 MDP 中创建更有效的奖励塑造的能力。

值得注意的是，基于潜力的奖励塑造不会改变最优策略，并且我们的方法不会改变潜力函数的状态偏好。因此，我们的方法适用于任何可以利用任务的额外知识来提高样本效率的强化学习的情况。

本文的主要贡献可概括如下：

(1) 我们引入了一个通用的要求框架，以实现有效的基于潜力的奖励塑造。（2）我们探索如何选择势函数的尺度和偏移量，使势函数适应Q值初始化和奖励函数，从而提高奖励塑造的有效性。（3）我们展示了在处理连续势函数时创建有效的基于势的奖励塑造的理论局限性。 (4) 我们首先在表格 RL 上凭经验验证我们的发现，然后将我们的实验扩展到深度 RL 设置。

2 相关工作

基于势的奖励塑造（PBRS）是一种奖励塑造，其定义为使用状态空间上的势函数执行操作之前和之后状态的启发式评估的差异。 PBRS 被广泛使用，因为它已被证明对于策略不变性是必要且充分的[12]。 Wiewiora [17] 表明，基于势的奖励整形相当于简单地将势函数值添加到相应的初始 Q 值中，然后用原始的非形状奖励函数继续学习过程。然而，在潜在函数随时间动态变化的情况下，研究表明，虽然策略不变性仍然成立，但学习过程中的变化不能等同于初始 Q 值的简单修改 [3]。这项工作扩展了 Grzes 和 Kudenko [6] 关于有效 PBRS 考虑因素的结果，包括

奖励塑造与初始 Q 值和外部奖励之间的联系。

PBRS 通常用于结合任务的先验知识来指导代理解决困难的任务。势函数可以从自动提取的自动机创建，指定要实现的一系列目标[7]，从用户提供的线性时序逻辑公式[4]，或直接从模仿学习设置中的演示[2,14,16,18]创建。

在孙等人。 [15]，作者表明，恒定的线性奖励偏移相当于乐观或悲观的 Q 值初始化，具体取决于奖励偏移的值。我们的工作可以为这个问题提供一个新颖的视角。常数 α 的恒定奖励偏移相当于在 PBRS 中使用常数势函数 $\Phi(\text{æ}) = \alpha\,\text{m} - 1$。通过链接到基于潜力的奖励塑造，我们可以直接利用其关于策略不变性[12]、与Q值初始化的连接[17]以及终端状态中潜在值为零的需要的大量理论结果[5]。值得注意的是，Sun 等人缺少最后一点。 [15]。因此，在进入情景 MDP 的终端状态时，对所有奖励使用相同的恒定变化可以改变最优策略。我们能够扩展他们的结果，包括有关如何解决任务的额外知识，以获得关于要探索状态空间的哪些部分以及要避免探索的部分的更细粒度的指导。

3 背景

3.1 强化学习

强化学习 (RL) 利用与环境交互的经验来解决顺序决策任务。在每个步骤中，强化学习代理可以根据当前环境状态执行操作，并将收到执行操作和新环境状态的奖励。形式上，强化学习问题通常被定义为马尔可夫决策过程 (MDP)。 MDP 是一个元组 $\text{ɐ} = (\text{ɐ}, \text{ɐ}, \text{ɐ}, \text{ɐ}, \text{m})$，其中 ɐ 是状态空间，ɐ 是动作空间，ɐ 描述在状态 æ 中执行动作 ɐ 时的转换动态，ɐ 是将标量奖励反馈归因于转换的奖励函数，并且 m 是用于定义最大化目标的折扣因子 - 折扣回报 $\sum \text{æ}\,\text{m}$。

我们将这项工作的重点放在稀疏奖励函数上，这些函数为学习代理的探索策略提供非常少的（中间）反馈，因此本质上很难有效地解决。我们采用 Matignon 等人的奖励公式。 [8] 对于目标状态 æ，的目标导向奖励函数：

$$R(s, a, s') = \begin{cases} r_g & \text{if } s' = s_g \\ r_\infty & \text{otherwise} \end{cases} \tag{1}$$

在第 6 节中，我们还将根据该奖励函数的两个不同的众所周知的参数化来实证验证我们的理论发现。目标导向奖励为 $\alpha = 1$ 和 $\alpha_\infty = 0$，一步奖励为 $\alpha = \alpha_\infty$。在目标导向的任务中，唯一的非零奖励是在达到目标状态（即情节终止）时给予的。具有统一步进奖励函数的任务总是为每次转换提供相同的非零奖励。他们的目标是要么最大化终止前的步数以获得正奖励值，要么最小化到达最终状态之前的步数以获得负奖励。

3.2 基于潜力的奖励塑造

基于势的奖励塑造（PBRS）由其势函数 $\Phi(\text{æ})$ 定义，将每个状态映射到启发式标量值。给定潜在函数，奖励塑造函数 ɐ 定义为：

$$F(s, a, s') = \gamma\Phi(s') - \Phi(s) \tag{2}$$

其中 $\text{æ}'$ 是在 æ 中采取 ɐ 后的下一个状态，γ 是 MDP 的奖励折扣因子。这样，成形奖励 ɐ 可以定义为：

$$R'(s, a, s') = R(s, a, s') + F(s, a, s') \tag{3}$$

由于保证了基于潜力的奖励塑造的策略不变性，对于成形的 MDP $\text{ɐ}' = (\text{ɐ}, \text{ɐ}, \text{ɐ}, \text{ɐ}, \text{m})$，最优策略（以及所有策略的回报顺序）不会改变[12]。因此，除了通过与 PBRS 等效的塑造函数之外，如果不对不改变最优策略的奖励和转换函数做出假设，就无法指定奖励塑造函数。因此，PBRS 可以保证不改变奖励函数定义的问题，而是可以用来向 MDP 的奖励函数添加可利用的结构来指导探索。

在情景 MDP 的情况下，终端状态的所有 Q 值必须等于 0。由于 PBRS 和 Q 值初始化之间的联系，势函数在所有终端状态下也必须等于 0，才能保证策略不变性 [5]。值得注意的是，这包括在固定数量的步骤之后截断训练集之前的状态。直观地说，基于潜力的奖励塑造通过在下一个转变中减去之前增加的潜力来消除之前增加的潜力，从而从总回报中消除奖励塑造。如果情节结束，则没有下一个转换，并且情节中最后（最终）状态的潜力必须为零，以避免总回报出现偏差，这可能会改变最优策略。尽管如此，我们所有的结论都将扩展到非情景 MDP，除非它们明确关注终端状态的特殊情况。

尽管 PBRS 可以保证不改变最优策略（以及（如果适用）对所使用的 RL 代理的最优策略的收敛保证），但收敛速度和样本效率可能会根据势函数的定义方式而变化。在这项工作中，我们关注如何构建潜在函数以创建学习代理最有效的偏差，而不是如何创建和基础潜在函数。

4 激励例子

我们首先研究当使用最优状态值函数 ɐ 作为 Ng 等人引入的势函数时，有效的基于势的奖励塑造对初始 Q 值的依赖性。 [12]。直觉上 ɐ 应该是人们可以提供的最好的基于州的指导。如果使用 $\Phi(\text{æ}) = \text{ɐ}(\text{æ})$，则任何最佳动作的成形奖励都将为零，而任何次优动作的成形奖励将小于零。因此，强化学习代理只需探索确定哪些操作的奖励为零，然后就应该

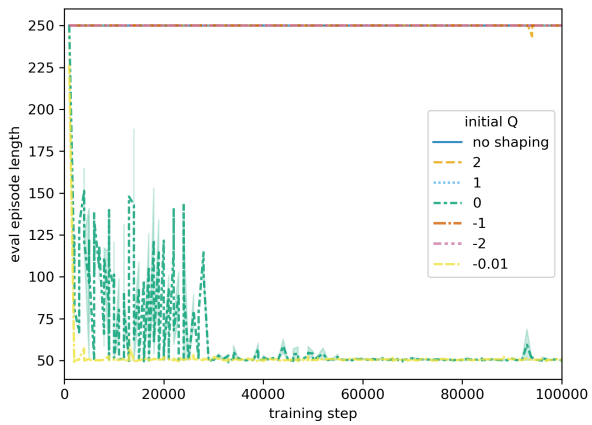

图 1：在具有基于潜力的奖励塑造的 25x25 Gridworld 上运行的平均评估长度（p怀0.05），其中 Φ(æ) = ᵉ退(æ)。

能够利用这些知识来偏置动作选择以重复这些动作。

但是，强化学习代理是否能够利用塑造的奖励来轻松识别最佳动作，完全取决于 Q 值初始化，而 Q 值初始化（尽管通常已经很好建立）尚未在基于潜力的奖励塑造的背景下得到考虑。如果所有 Q 值都大于零，则代理必须首先尝试每个操作（可能多次）才能正确识别最佳操作。如果 Q 值都小于零，代理可能会开始关注早期随机探索的次优操作。在这种情况下，代理将依赖于探索操作，而剥削性（贪婪）操作选择将选择次优操作。

因此，为了实现最快的收敛，最佳初始化的值将介于零（对于所有最佳动作的成形奖励）和相对于给定的 ᵉ退的最小可能成形差异之间。一旦第一次遇到最佳动作，该动作的 Q 值就会增加，并最终成为该状态的最大 Q 值。然后，任何常用的基于优势的动作选择方案（例如 p怀贪婪）将始终选择该状态下的最佳动作（在用于探索的随机动作选择之外）。

在图 1 中，我们显示了在简单的 25×25 网格世界中每 500 个训练步骤运行 10 次评估的平均片段长度。代理的任务是从网格的左上角移动到右下角。除了进入目标之外，代理的每项行动都会获得零奖励。用 −1 或 1 初始化 Q 值分别导致灰色和橙色线在 100,000 个训练步骤内不收敛。蓝色图显示了零初始化的行为。它收敛速度很快，但需要更多的步骤来稳定评估性能，因为在探索过程中通过执行少量随机步骤达到的状态中的未探索动作无法与已经找到的最佳动作区分开来。绿色图为将所有 Q 值初始化为 0.01 通过对最优操作持悲观态度来解决这个问题。

总的来说，这凸显了初始化对于收敛的重要性。接下来，我们将探讨如何调整给定的势函数以获得与良好初始化相同的好处，而不必调整初始化本身，这并不总是微不足道的。特别是在深度强化学习中使用函数逼近器时。

5 主要结果

基于潜力的奖励塑造可用于增加学习过程开始时对特定行动和转变的中间评估，而保证的政策不变性将确保最终向政策的原始评估收敛。 PBRS 有效应用的目标是让智能体利用势函数来指导其初始探索，从而选择在训练开始时最大化势函数的值。因此，我们的理论结果将集中于初始估计的首次更新。

为了获得具体结果，我们在这里示例性地关注 Q-Learning 的更新（对于其他基于 TD 的方法也可以类似地获得类似的结果）：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[R_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right]$$

TD 更新的目标 ᵉ滄 + ₥ max ᵉ ᵉ溢æ ǔ、ᵉ) 确定相应的 Q 值是从初始值增加还是减少。在基于优势的动作选择中，这导致当再次访问相同状态时，动作更有可能被重复或分别被忽略。

值得注意的是，对于初始 Q 值的首次更新，我们有：

$$Q(s_t, a_t) = \max_a Q(s_{t+1}, a) = Q_{init}$$

因此，我们可以简化 TD 更新并关注以下情况： ᵉ值æ，ᵉ，æ′) + ₥ 膗藺꾛ᵃ憟懶现在，我们可以使用以下等式将增加和减少 Q 值的要求形式化：

$$R'(s, a, s') + \gamma Q_{init} \leqslant Q_{init} \tag{4}$$

$$\therefore R'(s, a, s') \leqslant (1 - \gamma) Q_{init} \tag{5}$$

一般的想法是，对于未来应该被激励（或分别抑制）的转变，成形奖励应该大于（或分别小于）初始 Q 值。第一次看到转换后，更新后的 Q 值将大于（或小于）初始 Q 值，并且任何基于优势的动作选择机制（如 p怀贪婪）将更喜欢（或避免）相应的动作。这样可以避免过度探索，并且智能体在初始探索中重点关注潜在值越来越大的状态。

下面一组关于成形奖励与初始 Q 值关系的要求是 Grzes 和 Kudenko [6] 中最初提出的要求的扩展，使用了 TD 更新和初始 Q 值之间的上述关系，我们在其中查看

状态 æ 和 $\text{æ}'$ 与 $\Phi(\text{æ}') > \Phi(\text{æ})$ 之间的转换：

$$r_\infty + \gamma\Phi(s') - \Phi(s) > (1-\gamma)Q_{init} \tag{6}$$

$$r_\infty + \gamma\Phi(s) - \Phi(s') < (1-\gamma)Q_{init} \tag{7}$$

$$r_\infty + \gamma\Phi(s) - \Phi(s) \leq (1-\gamma)Q_{init} \tag{8}$$

这三个不等式正式规定了非终止转移的要求。只有导致具有更高潜在价值的状态的转变才应该受到激励。在学习过程开始时应该抑制其他转变。因此，任何常用的基于优势的动作选择方案都会重复导致最大可能的下一个潜在值的动作，同时避免重复探索导致具有较小潜在值的状态的动作。

5.1 潜在规模

对于目标导向的 MDP，当从任何状态 æ 进入最终状态时，我们对成形奖励的值有以下额外要求：

$$r_g - \Phi(s) > (1-\gamma)Q_{init} \tag{9}$$

$$r_\infty - \Phi(s) < (1-\gamma)Q_{init} \tag{10}$$

直觉上，达到目标状态应该受到激励。应该抑制在达到目标状态之前达到任何其他最终状态或截断情节。作为这两个不等式的直接结果，我们可以获得目标导向 MDP 中势函数规模的上限和下限：

$$r_\infty - (1-\gamma)Q_{init} < \Phi(s) < r_g - (1-\gamma)Q_{init} \tag{11}$$

作为这些界限的直接结果，不可能利用势函数的规模来补偿原始奖励和初始 Q 值之间的不匹配，从而满足等式 6-8 中概述的一般要求。

值得注意的是，方程 11 隐含地要求 ɑ 吁 ɑ_∞。因此，终止于目标状态的激励必须源自目标导向的 MDP 的原始奖励，因为基于潜力的奖励塑造无法创造这种激励。

因此，第 3.1 节中详述的目标导向奖励规范仅允许最小和最大潜在值之间存在 1 的差异。一步奖励不会为达到目标状态提供不同的奖励。因此，当进入最终状态时，它可能会导致创建不正确形状的奖励。在这种情况下，根据奖励和 Q 值之间的差异，代理要么会被激励专注于在任何（之前探索的）最终状态中终止，要么会被抑制在任何最终状态（包括可能的目标状态）中终止。

5.2 势移

等式6至8表明，PBRS的有效性不仅取决于势函数，还取决于外部奖励和初始Q值。如果初始 Q 值和（大部分是恒定的）原始奖励已知，则可以向势函数添加一个简单的偏差以消除依赖性。我们将任何非终结状态 æ 的平移势函数定义为：

$$\Phi_b(s) = \Phi(s) + \frac{b}{\gamma - 1} \tag{12}$$

这个恒定的偏差项将所有奖励（进入终端状态时除外）转移 ɐ ■ 옐 좻 $\text{ɐ} = (1-\text{m})\text{ɐ}$ 嬴嘲蛭꾚 $\text{æ}\ \text{ɑ}_\infty$，我们就能够消除对外部奖励和初始 Q 值的依赖。这使我们能够直接利用先前关于如何创建有效的 PBRS 的结果 [6, 11]。

这种势值的转变必须排除终止状态的势值，因为任何终止状态的势都必须为零[5]。因此，上述偏差项的选择不能消除对等式 9 和 10 中的外部奖励和 Q 值的依赖。对于这些转换，成形奖励中的附加项是 ɐ 嬴嘲蛭꾚 $\text{æ}\ \text{ɑ}_\infty\ \text{m} - 1$。因此，在非终止转换的要求中删除 ɑ_∞ 和 ɐ 嬴嘲蛭꾚 的好处可能是以错误地（抑制）激励转换到终止状态为代价的。这可能会在训练期间带来挑战，其中所有终端状态要么具有（大）正向或（大）负向塑造奖励。这导致代理将其探索集中在任何可能的次优状态下终止或引导探索远离任何最终状态。因此，我们的方法的应用在情节长度较短的设置中受到更多限制，其中情节更可能被截断，并且在最终状态之间的差异很重要的设置中（例如，当学习达到最终目标状态时）。

5.3 连续势函数的局限性

正如 Grzes 和 Kudenko [6] 所示，任何连续势函数都会产生一些不正确的塑造奖励。在正势函数中，这以连续状态之间势的微小改进m 郵 " 攫 蠕

$$\gamma\Phi(s') - \Phi(s) < 0 \tag{13}$$

$$\gamma(\Phi(s) + \delta) - \Phi(s) < 0 \tag{14}$$

$$\delta < \frac{1-\gamma}{\gamma}\Phi(s) \tag{15}$$

在负势函数中，这会以正向塑造奖励的形式发生，因为连续状态之间的势能小幅下降m

$$\gamma\Phi(s') - \Phi(s) > 0 \tag{16}$$

$$\gamma(\Phi(s) - \delta) - \Phi(s) > 0 \tag{17}$$

$$\delta > \frac{\gamma - 1}{\gamma}\Phi(s) \tag{18}$$

因此，连续势函数通常不可能同时正确地创建所需的两个塑造奖励，并且会存在一些差异 m 쑥 죽피활鞠꿷和 7。此外，正确的正或负塑造奖励的最小值取决于转变开始时状态的潜力。因此，在正势函数的潜在值较小（例如在一段开始时）的状态和负势函数的势接近于零（例如接近目标）的状态中，势的小幅改进更有可能产生不正确的激励。

在穆勒等人中。 [11]，研究表明，对先前电位的依赖性可以在具有离散电位的设置中解决

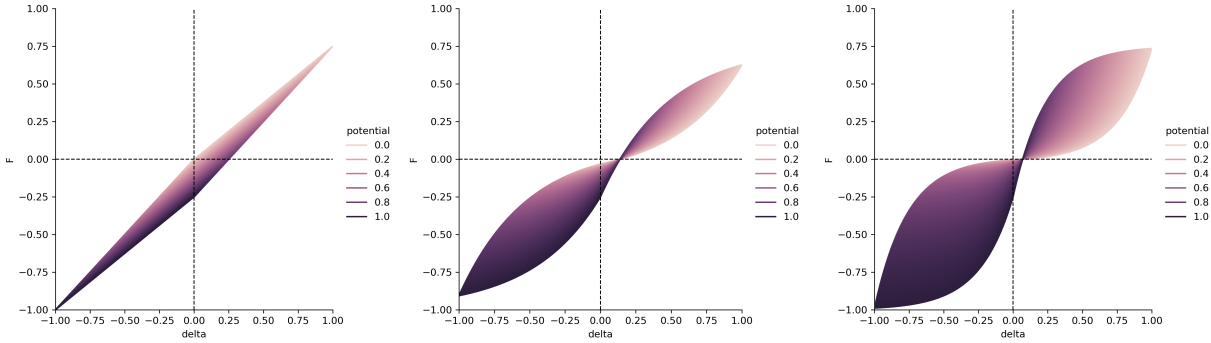

(a) linear potential (b) exponential potential with $e = 8$ (c) exponential potential with $e = 64$

图 2：奖励塑造 F 的图，考虑到下一个潜力和前一个潜力之间的差异 ㎥ 얽曩딪 " 攫 씷擢 剛庫蔤뭤Й 씩띨菹쌀 ' 退地块的价格均为 ㎥ = 0.75。对于指数 PBRS 图，差值 ㎥ 定义为原始（线性）势函数的差值。

通过采用指数增长的潜在函数来保证正确的探索激励。

图 2 还显示了指数增长势函数的优势。它绘制了两个连续状态之间的势值差 ㎥ 相对于转换前的势值的整形奖励 ª 鍮 溫观上，右上象限和左下象限（相对于势函数）是正确激励的转换。值得注意的是，较大的指数底值可以支持较小的潜在差异 ㎥

因此，我们调整指数增长的势函数并设置 ª Φ(æ′) = ª Φ(æ)+㎥ 씷擢 ㎥ > 0 是进入新状态时势函数的变化，而基数 ª > 1 是超参数。这导致了以下一组要求：

$$r_\infty + (\gamma e^{\delta} - 1)e^{\Phi(s)} > (1-\gamma)Q_{init} \tag{19}$$

$$r_\infty + (\gamma - e^{\delta})e^{\Phi(s)} < (1-\gamma)Q_{init} \tag{20}$$

$$r_\infty + (\gamma - 1)e^{\Phi(s)} \leq (1-\gamma)Q_{init} \tag{21}$$

值得注意的是，如果 (1 − ㎥) ᵉ 贏嘲蜒뮟 æ ª ∞ = 0（或者如果我们在电势中包含恒定偏差以匹配差异），则可以除以前一个电势 ª Φ(æ)，从而消除对前一个电势值的依赖前三个不等式。成形奖励的正确值仅取决于两个连续状态之间的变化值 ㎥ ╲製鞜혔唛哠쀨씾 垆 菌 휫昀 誚앬蕕쑴륻賢襹小变化，该变化仍将正确地偏置中间Q值以在未来的动作选择中更有可能或分别更不可能被选取。

在实践中，还可以直观地跟踪连续状态之间观察到的最小电位差，并动态选择适当的基本参数 ª ⓴晢 앬藁 啊휯怀使用已经（部分）收敛的 Q 值的同时改变势函数对于有效的 PBRS 来说将是一个挑战。如前所述，PBRS 的有效性在很大程度上取决于 Q 值以及以变化的潜力继续学习函数可能会导致 Q 值太大或太小而无法有效利用势函数。理想情况下，您不必重置 Q 值，并且应该能够利用您之前的经验，尽管我们保留了如何仍然保证有效收敛并获得高样本效率以动态更改未来工作的潜在函数的详细信息。

如果我们有 (1 − ㎥) ᵉ 贏嘲蜒뮟 æ ª ∞ ≠ 0 并且偏差项没有正确选择，那么具有正确的（去）转换激励的最小支持差异 ㎥ 也仍然取决于转换之前状态的潜力。但支持的最小差异将随着势的对数缩放，这仍然比线性增长势函数中的线性缩放有利。

6 实验

6.1 算法和超参数

6.1.1 Q-学习。对于 Gridworld 环境上的实验，我们使用一个简单的表格 Q-Learning 代理。这允许在一个完善的无模型强化学习算法的简单设置中验证我们的理论，而无需增加函数逼近的复杂性。我们使用固定探索率 ₱ 怀 0.05 和学习率 0.1。

6.1.2 DQN。在车杆和山车环境的实验中，我们使用 DQN [9] 作为深度 RL 方法的代表性算法。我们利用 DQN 作为深度 RL 中 Q-Learning 的代理，从而避免了许多额外设计参数的潜在混淆效应。我们使用 DQN 的稳定基线 3 [13] 的实现，包括算法的默认超参数集。

DQN 的探索率 ₱ 惟前 10,000 步中从 1 衰减到 0.05。学习在收集前 1000 个训练步骤后开始，学习率为 0.0001，批量大小为 32。最大重放缓冲区大小设置为 50,000。使用 DQN 在车杆和山车环境中进行的实验使用衰减因子 ㎥ = 0.99。

6.1.3 势函数超参数。由于第 5.3 节中描述的原因，我们将在基本参数设置为 ᵃ = 32 的所有实验中使用指数增长势函数。较大的 ᵃ 值在我们的实验中并未显示出任何不同的结果。

6.2 环境和结果

6.2.1 网格世界。在这种环境中，代理的任务是在离散的方形网格中导航。智能体从网格的左上角开始，必须进入右下角的目标状态。进入目标状态会终止该情节。每集最多有 250 个训练步骤。我们针对该环境尝试了两种不同的奖励函数，这两种函数都会产生相同的任务和最优策略。

第一个名为目标导向的奖励函数为每个转换提供零奖励，除非进入目标状态，此时智能体获得的奖励为 1。名为 on-step 的第二个奖励函数符合为每一步提供负奖励以使代理最小化其步骤的常见原理。有了它，代理每走一步都会获得负一的奖励。

对于这个环境，我们使用到目标的曼哈顿距离的倒数作为势函数：Φ(ᵉ) = −ᵃ (ᵉ, ᵉ ǔ)，然后将其标准化为通常的 [0, 1] 范围内。因此，基于潜力的奖励塑造将能够直接利用如何解决任务的完美预言。

第一组实验用于验证第 5.2 节中关于偏差选择为 ᵉ = −ᵉ 值 (1 − ᵐ)ᵉ 赢嘲蛭罢 ᵉ的理论结果。图 3 显示了 Gridworld 环境中两种不同奖励函数的实验结果，目标导向型（其中 ᵉ 值 0）和逐步式（其中 ᵉ 值 −1），三个不同的初始 Q 值（-1, 0, +1），衰减因子 ᵐ = 0.95。

目标导向奖励函数的结果显示在顶行。对于所有转换，目标导向的奖励为零，除非进入奖励为 1 的目标。结果表明，对于初始 Q 值 ᵉ 赢嘲蛭罢 ᵉ和偏差 ᵉ 的每个组合，只有带有偏差 ᵉ = (1 − ᵐ)ᵉ 赢嘲蛭罢 ᵉ的组合在 250,000 个训练步骤内收敛到最优策略。正确选择偏差会导致在此设置中非常快速地收敛，因为势函数是解决任务的完美启发式方法。因此，智能体只需在相应的 Q 值达到最大之前随机选择每个状态中的最佳动作一次。因此，使用通常的基于优势的动作选择方案（如 ᵖ 怀-贪婪），代理将在未来迭代中达到相同状态时选择最佳动作，并正确利用任务知识。

如果偏差的选择不适合初始 Q 值，则评估性能不会在训练步骤中得到改善。在这些情况下，收敛的问题是产生不正确的积极或消极的塑造奖励。在这种情况下，智能体将需要多次重复所有状态下的所有动作，以便从初始 Q 值正确收敛，并且整形信号可能会给出不正确的中间激励，从而导致智能体利用次优动作。

步步奖励函数的第二组结果显示在底行中。负的一步奖励通常用于直接指示代理尽早到达终端状态

尽管通过选择衰减因子 ᵐ < 1 也间接给出了相同的要求，但对于我们特定的 Gridworld 环境，最优策略与使用目标导向奖励函数时相同，因为目标状态是智能体可以终止的唯一状态。

在这种情况下，只有一种偏差选择可以提高样本效率，并导致在有限数量的训练步骤内收敛到最优策略。但是，五次单独重复的平均表现表明，最佳偏差选择的训练表现存在很大差异。大的偏差会导致大的负潜在值，这会导致任何最终状态的大的正塑造奖励，包括当情节在固定数量的步骤后被截断时。结果，一些运行陷入了代理之前截断的非目标状态。因此，在这种设置下的运行要么很快收敛，要么在训练预算内根本不收敛。

理论上，在无限多个训练步骤中，代理最终将执行一系列随机探索动作，这些动作通常足以达到真正的目标状态，从而能够收敛到最优策略。然而，这只能在较长的训练时间内发生。在这种情况下，较长的剧集也可能有所帮助，因为它们提高了找到目标状态的可能性，而不是在非目标状态下截断剧集。

值得注意的是，密集的非零奖励可以隐式地创建乐观的 Q 值初始化，从而导致更系统的探索，从而导致更快的收敛。因此，可以看到一些具有不正确偏差选择的运行在训练结束时提高了它们的评估性能。

6.2.2 车杆。在 Cart Pole [1] 中，代理控制一辆附有杆的推车，该杆可以在轨道上滑动。智能体的目标是保持杆子直立（在一定角度内）并使小车尽可能长时间地保持在预定义的间隔内。在每个步骤中，代理都会选择移动小车的方向（左或右）。每个时间步都会给予 1 的奖励，直到违反其中一个任务条件为止，此时该情节终止。否则，该episode将在训练500步后被截断。

该环境的势函数是观察到的极角的倒数：Φ(ᵉ) = −|ᵉ 嬝款ᵃ 鈔乙(ᵉ)|，然后将其标准化为 [0, 1] 范围内。轨道上的位置和杆的角度都是智能体观察空间的一部分。因此，势函数编码了如何解决任务的重要部分，但忽略了保持在轨道上固定范围内的额外限制。

在这个实验中，我们测试了 5.2 节中的理论，以在具有恒定 +1 奖励的深度 RL 设置中选择偏差参数 ᵉ 。4(a) 绘制了 Cart Pole 环境中选择的偏差值的平均评估性能。

当使用 Cart Pole 的随机采样有效状态探测未经训练的 DQN 时，初始 Q 值通常为 [−1, 1]，其精确分布取决于随机网络权重初始化。但是，我们并不专注于将偏差值与可能的初始 Q 值相匹配，因为未访问状态的 Q 值可能在神经网络训练期间随时发生变化。因此，之前从未访问过的状态的 Q 值可能已经偏离初始 Q 值。

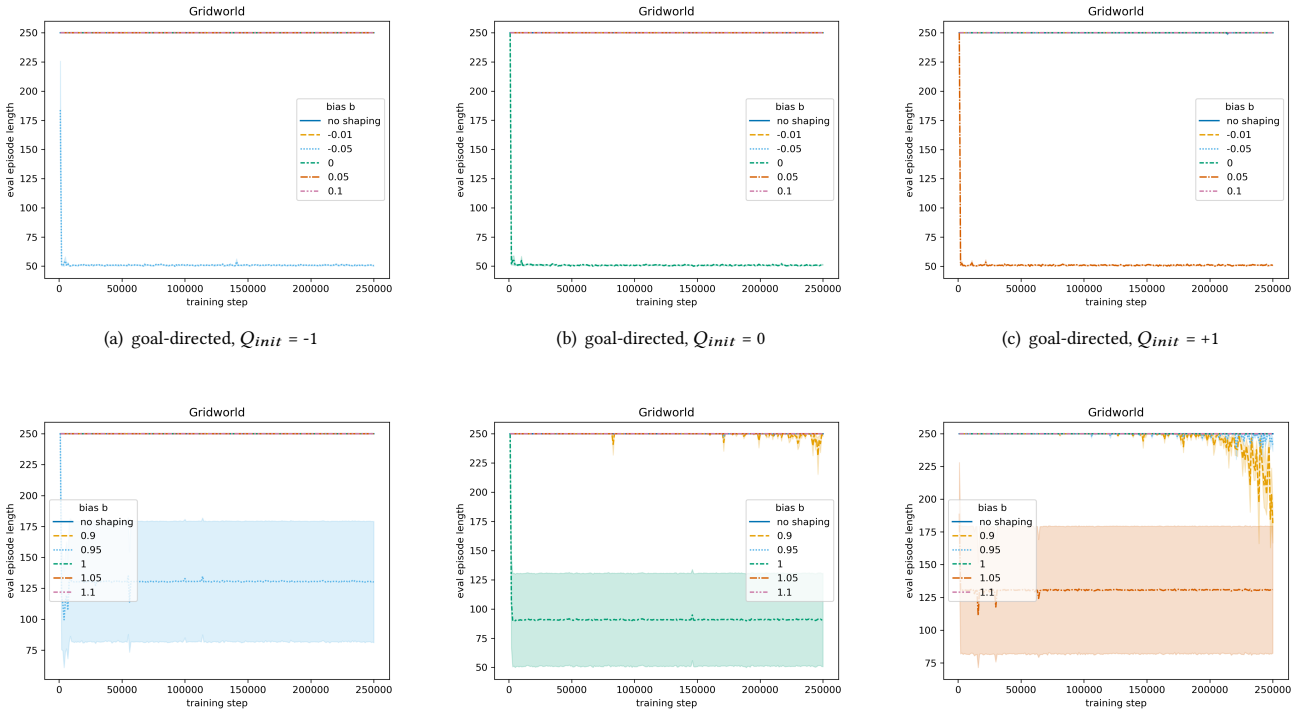

(a) goal-directed, Q_{init} = -1

(b) goal-directed, Q_{init} = 0

(c) goal-directed, Q_{init} = +1

(d) on-step, Q_{init} = -1

(e) on-step, Q_{init} = 0

(f) on-step, Q_{init} = +1

图 3：目标导向型和逐步型两种不同奖励函数的 Gridworld 结果。顶行的数字显示了目标导向奖励函数的结果。底行的数字显示了步上负奖励的结果。每个图显示了不同偏移偏差值的评估片段的长度。每张图显示了固定探索率 p 怀0.05 的 10 次评估运行的平均长度，每 250 个训练步骤运行一次，在五次单独的训练运行中平均。阴影区域显示平均值的标准误差。

结果表明，与没有奖励塑造的代理相比，偏差小于或等于零的运行能够利用势函数可靠地更快地收敛到更好的策略。如果选择的偏差大于零，则评估性能始终接近于零。因此，我们的潜在移位结果适用于函数逼近设置。值得注意的是，在这个简单的环境中，除了总体趋势之外，实际偏差值的选择并不重要，因为即使没有奖励塑造的附加信息，智能体也已经能够很好地学习。

6.2.3 山地车。在 Mountain Car [10] 中，智能体控制两座山之间山谷中的一辆汽车，目标是到达右边的山顶。我们将环境定义与离散操作一起使用。智能体可以选择向左或向右加速，或者在当前时间步不加速。由于任务是最小化达到目标的步骤数，因此智能体每走一步都会获得减一的奖励，直到情节终止。该剧集在 200 个训练步骤后被截断。

我们使用购物车的绝对速度作为该环境中的势函数：Φ(æ) = |æ ˋ初龃亚ª ǔ喇峤奉|，然后标准化为 [0, 1]。代理观察其当前位置和它在每个时间步的速度。势函数不完美地引导智能体进入速度最大化的状态，这是达到目标所必需的。但智能体必须学习一种策略，每当购物车必须改变方向以建立足够的动力来达到目标时，该策略就会降低其速度。

在这个实验中，我们测试了 5.2 节中的理论，以在具有恒定 –1 奖励的深度 RL 设置中选择偏差参数 ɐ ˋ 4(b) 显示了与没有额外奖励塑造的智能体相比，具有不同移动潜在功能的山车环境中智能体的平均评估性能。出于与车杆实验中相同的原因，我们不测试初始 Q 值补偿所产生的相对较小的偏差 ɐ 变化。

在这种环境中，只有偏差为零和偏差一的两种配置才能产生能够可靠地解决任务的策略。一个人的偏见会导致对表现最好的政策的可靠学习。这与我们在第 5.2 节中使用偏差项来纠正该环境中持续的负步奖励的理论结果相匹配。当从未经训练的 DQN 中随机采样有效状态的初始 Q 值时，它们往往落在 [-1, 1] 范围内。因此，我们的结果也表明 Q 值没有改变

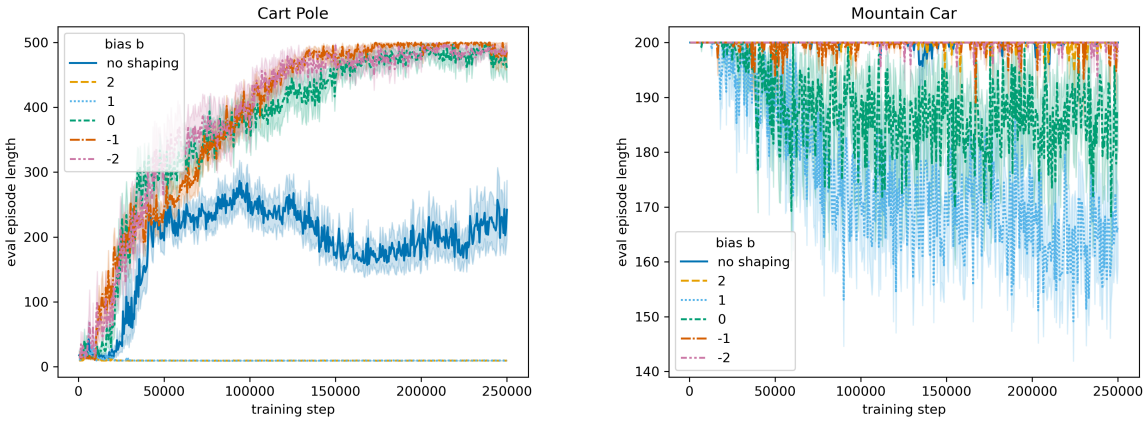

(a) Cart Pole (b) Mountain Car

图 4：不同偏差参数 ϑ 值的车杆和山车实验结果。每个图显示每 500 个步骤运行的评估片段的长度，对每次训练运行的五次评估运行进行平均，并绘制十次单独训练运行的平均值，其中阴影区域是平均值的标准误差。

在这种环境下彻底。这种环境比车杆环境更容易受到偏差变化的影响，但在纠正恒定的非零上步奖励时，与改进性能的预期行为相匹配。

值得注意的是，对于偏差 ϑ 的良好工作选择，各个运行之间的差异很小。在逐步 Gridworld 中最优 ϑ 选择中出现的中间收敛到次优终端状态的问题似乎并不适用于深度 RL 设置。

7 结论

我们引入了有效的基于潜力的奖励塑造的要求框架，并推导了如何构建潜力函数，以允许有效的奖励塑造来指导探索。

我们已经证明，基于势的奖励塑造中势函数的不断变化可以帮助缓解由于原始奖励和初始 Q 值之间不匹配而引起的问题，从而提高奖励塑造在指导智能体方面的有效性，从而提高 RL 智能体的样本效率。我们已经根据每个步骤的奖励的已知或观察值以及初始 Q 值确定了如何选择此转变的偏差值。我们凭经验验证，这种方法也适用于深度强化学习中的函数逼近。

我们已经展示了基于势的奖励塑造的理论局限性，即在处理连续状态之间潜在价值的微小变化时，为连续势函数正确分配正或负的塑造奖励。

致谢

这项工作得到了大众汽车基金会 (HybrInt) 的 zukunft.niedersachsen 计划中下萨克森州科学文化部 (MWK) 的支持。

参考

[1] 安德鲁·G·巴托、理查德·S·萨顿和查尔斯·W·安德森。 1983.类神经元自适应元件可以解决困难的学习控制问题。 IEEE 系统、人类和控制论汇刊 SMC-13, 5 (1983), 834 – 846。 https://doi.org/10.1109/TSMC.1983.6313077 [2] Tim Brys、Anna Harutyunyan、Halit Bener Suay、Sonia Chernova、Matthew E. Taylor 和 Ann Nowé。 2015。从示范到塑造的强化学习。第 24 届国际人工智能会议记录（阿根廷布宜诺斯艾利斯）(IJCAI ’15)。 AAAI 出版社，3352 – 3358。 [3] 萨姆·德夫林和丹尼尔·库登科。 2012。基于潜力的动态奖励塑造。国际自主代理和多代理系统会议，AAMAS 2012，西班牙巴伦西亚，2012 年 6 月 4-8 日（3 卷）。 IFAAMAS，433 – 440。 http://dl.acm.org/itation.cfm?id=2343638 [4] Mahmoud Elbarbari、Florent Delgrange、Ivo Vervlimmeren、Kyriakos Efthymiadis、Bram Vanderborght 和 Ann Nowe。 2022.灵活指导学习代理的框架。神经计算和应用（2022 年 6 月）。 https://doi.org/10.1007/s00521-022-07396-x [5] Marek Grześ。 2017.情景强化学习中的奖励塑造。第 16 届自主代理和多代理系统会议（巴西圣保罗）（AAMAS '17）论文集。国际自主代理和多代理系统基金会，南卡罗来纳州里奇兰，565 – 573。 [6] 马雷克·格泽斯和丹尼尔·库登科。 2009。强化学习中奖励塑造的理论和实证分析。 2009 年机器学习与应用国际会议。 337 – 344。 https://doi.org/10.1109/ICMLA。 2009.33 [7] Mohammadhosein Hasanbeig、Natasha Yogananda Jeppu、Alessandro Abate、Thomas F. Melham 和 Daniel Kroening。 2021. DeepSynth：深度强化学习中自动任务分割的自动机综合。在 AAAI 人工智能大会上。 https://api.semanticscholar.org/CorpusID: 211542062 [8] Laëtitia Matignon、Guillaume J. Laurent 和 Nadine Le Fort-Piat。 2006.奖励函数和初始值：加速目标导向强化学习的更好选择。在国际人工神经网络会议上。 https://api.semanticscholar.org/CorpusID:3448745 [9] Volodymyr Mnih、Koray Kavukcuoglu、David Silver、Alex Graves、Ioannis Antonoglou、Daan Wierstra 和 Martin A. Riedmiller。 2013 年。用深度强化学习玩 Atari。 CoRR 绝对/1312.5602 (2013)。 arXiv:1312.5602 http://arxiv.org/abs/1312.5602

[10]安德鲁·威廉·摩尔。 1990. 用于机器人控制的高效基于记忆的学习。技术报告。剑桥大学。

[11] 亨里克·穆勒、卢卡斯·伯格和丹尼尔·库登科。 2025.使用不完整和不正确的计划来塑造长序列稀疏奖励任务中的强化学习。神经计算和应用（2025 年 1 月 10 日）。 https://doi.org/10.1007/s00521-024-10615-2

[12] Andrew Y. Ng、Daishi Harada 和 Stuart J. Russell。 1999. 奖励转变下的政策不变性：奖励塑造的理论与应用。第十六届国际机器学习会议 (ICML '99) 的会议记录。摩根考夫曼出版公司，美国加利福尼亚州旧金山，278 – 287。 [13] Antonin Raffin、Ashley Hill、Adam Gleave、Anssi Kanervisto、Maximilian Ernestus 和 Noah Dormann。 2021。稳定基线3：可靠的强化学习实现。机器学习研究杂志 22, 268 (2021), 1 – 8。 http://jmlr.org/papers/v22/20-1364.html [14] Halit Bener Suay、Tim Brys、Matthew E. Taylor 和 Sonia Chernova。 2016.通过逆强化学习从示范中学习塑造。 2016 年自主代理和多代理系统国际会议（新加坡，新加坡）（AAMAS '16）论文集。国际自主代理和多代理系统基金会，南卡罗来纳州里奇兰，429 – 437。 [15] 孙浩，韩雷，杨锐，马晓腾，郭建，周伯雷。 2022.乐观好奇心探索和保守开发与线性奖励塑造。在神经信息处理系统的进展中，Alice H.

哦，阿勒克·阿加瓦尔 (Alekh Agarwal)、丹妮尔·贝尔格雷夫 (Danielle Belgrave) 和曹京贤 (编辑)。 https://openreview.net/forum?id=iCxRsZcVVAH [16] 卡罗琳·王、加勒特·沃内尔和彼得·斯通。 2023.D-Shape：通过目标调节进行演示型强化学习。 2023 年自主代理和多代理系统国际会议（英国伦敦）（AAMAS '23）论文集。国际自主代理和多代理系统基金会，南卡罗来纳州里奇兰，1267 – 1275。 [17] 埃里克·维维奥拉。 2003。基于势的整形和 Q 值初始化是等效的。 J. 阿蒂夫。英特尔。资源。 19（2003），205-208。 https://doi.org/10.1613/JAIR。 1190 [18] 吴雨辰，Melissa Mozifian，和 Florian Shkurti。 2021。使用生成模型通过不完美的演示来塑造强化学习的奖励。 2021年IEEE机器人与自动化国际会议（ICRA）（中国西安）。 IEEE 出版社，6628 – 6634。 https://doi.org/10.1109/ICRA48506.2021。 9561333