基于专家引导稳定化的深度 Q 网络变体用于密集森林环境自主导航

作者姓名
xxx 大学 xxx 学院
城市，中国
xxx@xxx.edu.cn

摘要—在非结构化森林环境中实现自主导航面临重大挑战，原因在于障碍物密集、通道狭窄以及地面车辆的运动学约束。本文提出一套综合性深度 Q 网络（DQN）森林导航框架，融合了：(1) 六种 DQN 变体，涵盖 MLP 与 CNN 两种网络架构，以及标准 DQN、Double DQN 与 Polyak Double DQN 三种更新规则；(2) 四阶段训练流水线，包含专家示例预填充、监督预训练、带动作掩码的引导式探索以及原始奖励回放的时序差分学习；(3) 多层安全机制，结合可行性掩码、top-k Q 值回退与短视域滚动启发式策略。在基于 Ackermann 自行车运动学的程序化生成森林地图上开展的大量实验表明，本方法在长距离任务（42 m 以上）上取得 97% 成功率，平均路径长度 40.61 m，与 Hybrid A*（40.86 m）相当，规划时间缩短 15 倍以上（0.25 s 对比 3.78 s）。消融研究对奖励塑形、速度约束以及 DQN+MPC 混合架构的设计权衡进行了深入分析。

***Index Terms*—深度强化学习，自主导航，森林环境，深度 Q 网络，路径规划，动作掩码**

I. 引言

在森林环境中运行的自主移动机器人（AMR）需要在满足车辆平台运动学约束的同时，穿越密集、不规则分布的障碍物。经典规划算法如 Hybrid A* [1] 和 RRT* [2] 具备完备性保证，但在杂乱环境中频繁重规划时计算代价高昂。

深度强化学习（DRL）提供了一种有前景的替代方案，通过学习将传感器观测直接映射为控制动作的反应式策略。在 DRL 方法中，深度 Q 网络（DQN）系列 [3] 及其扩展——Double DQN [4] 与软目标更新 [5]——在离散动作域中已展现出良好效果。然而，将 DQN 应用于真实森林类环境导航面临以下挑战：

1) **长时序**：在精细控制（$\mathrm{dt} = 0.05\,\mathrm{s}$）下，森林穿越任务每集可跨越数百步，导致奖励信号稀释。
2) **安全约束**：车辆在转弯半径有限的 Ackermann 转向运动学下，必须规避树木碰撞。
3) **稀疏奖励**：二元成功/失败反馈使信用分配困难。
4) **样本效率**：在密集森林中纯粹探索会导致训练初期成功率接近零。

为应对上述挑战，我们提出包含以下模块的综合 DQN 导航框架：(a) 带示例引导自举的四阶段训练流水线；(b) 多分量惩罚项的塑形奖励函数；(c) 具备安全保证的分层动作选择机制；(d) 六种 DQN 变体在两种神经网络架构上的系统性对比。

本文的主要贡献如下：

- 面向运动学约束森林导航的完整 DQN 训练框架，融合 DQfD 风格预训练、专家引导探索以及采样时归一化的原始奖励回放。
- 六种 DQN 变体（MLP/CNN × DQN/DDQN/PDDQN）与 Hybrid A* 及 RRT* 基线的系统性评估。
- 量化目标邻近奖励塑形、终端速度约束及 DQN+MPC 混合架构效果的消融研究。
- 验证 CNN-PDDQN 以更短路径、15 倍更快规划速度实现 100% 长距离成功率。

II. 相关工作

A. 经典路径规划

Hybrid A* [1] 以连续转向角扩展了格栅规划，生成运动学可行路径。RRT* [2] 提供渐近最优性，但在狭窄通道中收敛缓慢。两种方法均依赖显式环境模型，随障碍物密度增加可扩展性差。

B. 面向导航的深度强化学习

DQN [3] 引入了经验回放与目标网络，实现深度神经网络 Q 学习的稳定训练。Double DQN [4] 通过解耦动作选择与评估来缓解过高估计偏差。Polyak 平均（软目标更新） [5] 提供更平滑的目标跟踪。DQfD [6] 通过大间距分类与时序差分损失融合专家示例。

在机器人导航领域，Tai 等 [7] 利用激光测距数据训练了无地图导航的 DQN 智能体。Xie 等 [8] 将 DRL 与运动规划结合用于室外导航。然而，大多数已有工作针对室内或城市环境；具有自行车运动学约束的密集森林导航仍待深入研究。

C. RL 中的动作掩码与安全机制

无效动作掩码 [9] 将策略限制在可行动作上，提升样本效率与安全性。本文在此基础上构建了多层回退系统，结合可行性检查、top-k Q 值搜索与短视域滚动启发式策略。

III. 问题建模

A. 车辆模型

将车辆建模为前轮转向的 Ackermann 自行车：

$$\dot{x} = v\cos\theta, \quad \dot{y} = v\sin\theta, \quad \dot{\theta} = \frac{v}{L}\tan\delta \tag{1}$$

其中 (x, y, θ) 为车辆位姿，v 为纵向速度，δ 为前轮转向角，$L = 0.6\,\mathrm{m}$ 为轴距。动力学以欧拉法在 $\mathrm{d}t = 0.05\,\mathrm{s}$ 的时间步长下积分。

车辆约束包括最大速度 $v_{\max} = 2.0\,\mathrm{m/s}$ 和最大转向角 $\delta_{\max} = 27°$。碰撞检测采用双圆近似（半径 $r = 0.436\,\mathrm{m}$，圆心距后轴 $\pm 0.231\,\mathrm{m}$），如图 1所示。

B. 森林环境

森林地图通过泊松盘采样程序化生成，支持配置树木数量、间距与间隙参数。本文使用 `forest_a` 环境：360×360 网格（分辨率 $0.1\,\mathrm{m}$/格，物理尺寸 $36 \times 36\,\mathrm{m}$），含 85 棵树木，平均间距 $3.0 \pm 0.15\,\mathrm{m}$（见图 1）。基于种子的生成方式保证实验的可重复性。

C. MDP 建模

导航任务建模为马尔可夫决策过程（MDP）$(\mathcal{S}, \mathcal{A}, P, R, \gamma)$：

状态空间 $\mathcal{S}$：每个观测由 11 维标量向量（车辆位姿、速度、转向角、目标位姿、目标距离）与空间地图通道拼接而成。MLP 智能体接收 2 个下采样地图通道（占据栅格 + 代价地图）；CNN 智能体接收 3 个通道（占据 + 代价 + 欧氏距离变换间隙图）。

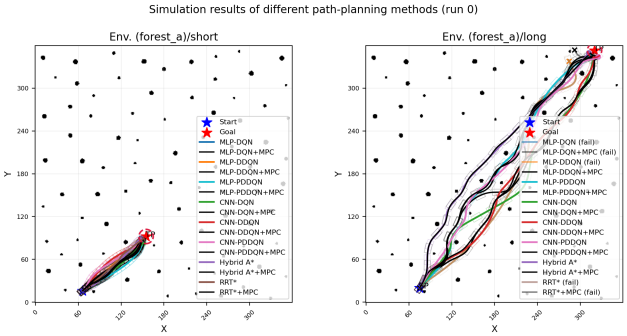

图 1. 森林环境（`forest_a`）及所有算法的规划路径。左：短距离场景（6–14 m）；右：长距离场景（42 m 以上）。黑点为树木，彩色线为各算法路径。

表 I
DQN 变体规格。

变体	骨干网络	TD 目标	目标更新
MLP-DQN	MLP 3×256	$\max_{a'} Q_{\theta^-}$	硬更新/1000 步
MLP-DDQN	MLP 3×256	$Q_{\theta^-}(\arg\max Q_\theta)$	硬更新/1000 步
MLP-PDDQN	MLP 3×256	$Q_{\theta^-}(\arg\max Q_\theta)$	Polyak τ=.005
CNN-DQN	CNN+FC	$\max_{a'} Q_{\theta^-}$	硬更新/1000 步
CNN-DDQN	CNN+FC	$Q_{\theta^-}(\arg\max Q_\theta)$	硬更新/1000 步
CNN-PDDQN	CNN+FC	$Q_{\theta^-}(\arg\max Q_\theta)$	Polyak τ=.005

动作空间 $\mathcal{A}$：35 个离散动作，组合 7 个转向速率 $\dot{\delta} \in [-0.7, 0.7]\,\mathrm{rad/s}$ 与 5 个加速度 $a \in [-1, 1]\,\mathrm{m/s^2}$。

奖励函数：多分量塑形奖励（详见第 IV-B节）。

折扣因子：$\gamma = 0.995$，以在森林穿越典型长时序（每集 300–600 步）中传播信用。

IV. 方法论

A. DQN 变体族

本文评估六种 DQN 变体，沿两个维度组织：网络架构（MLP 对比 CNN）与更新规则（DQN、Double DQN、Polyak Double DQN）。表 I总结主要差异。

MLP 骨干：3 个隐藏层（每层 256 个单元，ReLU 激活）的全连接网络，接收展平的观测向量（11 个标量 + $2 \times N^2$ 地图像素）作为输入。

CNN 骨干：三层卷积编码器（32 → 64 → 64 通道，3×3 卷积核）处理空间地图输入（3 个通道：占据图、代价图、EDT 间隙图）。CNN 特征与 11 维标量

CNN Q 网络架构

空间分支:

输入: $3 \times N \times N$ **地图**

$\rightarrow$ Conv2d($3 \rightarrow 32$, 3×3, s=1, p=1) + ReLU

$\rightarrow$ Conv2d($32 \rightarrow 64$, 3×3, s=2, p=1) + ReLU

$\rightarrow$ Conv2d($64 \rightarrow 64$, 3×3, s=2, p=1) + ReLU

$\rightarrow$ **展平**

标量分支:

输入: 11 **维** $(x, y, \theta, v, \delta, x_g, y_g, \theta_g, d, \ldots)$

融合: **拼接** $\rightarrow$ FC(256)+ReLU $\rightarrow$ FC(256)+ReLU

$\rightarrow$ FC(35) $\Rightarrow$ 35 **个动作的 Q 值**

图 2. CNN Q 网络架构。MLP 变体省略空间分支，直接展平所有输入。

观测拼接后送入 2 层全连接头（每层 256 个单元），如图 2所示。

PDDQN (Polyak Double DQN)：将 Double DQN 的解耦目标计算与每步 Polyak 软更新 $\theta^- \leftarrow (1-\tau)\theta^- + \tau\theta$ 相结合，取代 DQN 与 DDQN 采用的周期性硬替换。

B. 奖励设计

每步奖励将进度信号与多项惩罚项相结合，以鼓励安全、平滑的导航：

$$\begin{aligned} r_t = & \underbrace{k_p \cdot (\mathrm{cost}_{t-1} - \mathrm{cost}_t)}_{\text{进度}} - \underbrace{k_t}_{\text{时间}} - \underbrace{k_\delta (\Delta\delta)^2}_{\text{转向}} \\ & - \underbrace{k_a (\Delta a)^2 (v/v_{\max})^2}_{\text{加速}} - \underbrace{k_\kappa \tan^2 \delta}_{\text{曲率}} \\ & - \underbrace{k_o \left[\frac{1}{d_o + \epsilon} - \frac{1}{d_s + \epsilon} \right]^+}_{\text{障碍接近}} - \underbrace{k_v \cdot f_{\mathrm{speed}}(d_o, v)}_{\text{速度耦合}} \end{aligned} \quad (2)$$

其中 cost_t 为 Hybrid A* 启发地图中的代价值，d_o 为最小障碍距离，d_s 为安全阈值。终端奖励：到达目标 $+400$，碰撞 -200，超时按比例惩罚。表 II列出各系数值。

C. 四阶段训练流水线

训练流水线通过渐进式自举解决冷启动问题。完整伪代码见算法 1。

1) 阶段 1: 专家示例预填充: Hybrid A* 生成运动学可行路径。仅保留成功集的转移数据（约 5000 条），以 `demo=True` 标志存入回放缓冲，确保其不被新数据覆盖。

表 II
奖励函数系数。

符号	分量	值
k_p	进度（代价减少）	12.0
k_t	时间惩罚（每步）	0.1
k_δ	转向平滑性	1.5
k_a	加速平滑性	0.2
k_κ	曲率惩罚	0.2
k_o	障碍接近惩罚	1.5
k_v	速度–障碍耦合	2.0
	碰撞终端奖励	-200
	成功终端奖励	$+400$

2) 阶段 2: 监督预训练 (DQfD 风格): 进行 40,000 步梯度更新，从示例专用部分采样批次并优化：

$$\mathcal{L}_{\mathrm{pre}} = \mathcal{L}_{\mathrm{CE}}(Q_\theta(s), a_{\mathrm{expert}}) + \lambda_m \cdot \mathcal{L}_{\mathrm{margin}} \quad (3)$$

其中 $\mathcal{L}_{\mathrm{CE}}$ 为 softmax Q 值与专家动作的交叉熵，

$$\mathcal{L}_{\mathrm{margin}} = \max\left(0, \max_{a \neq a_e} Q(s,a) + m - Q(s, a_e)\right) \quad (4)$$

间距 $m = 0.8$。若贪心策略能在 600 步内到达目标则提前停止。

3) 阶段 3: 主训练循环: 每集采样最小代价距离 6 m 的随机起止点对。动作选择遵循两层方案：

第一层——专家探索：以概率 $p_{\exp}(t) = 0.7 \times (1 - t/(0.85 \cdot T))^+$ 由 Hybrid A* 专家选择动作。

第二层——带安全掩码的 ϵ-贪心：否则以概率 $\epsilon(t)$ 随机选取可行动作；以概率 $1-\epsilon(t)$ 使用 Q 网络的贪心动作（受可行性检查与回退机制约束，见第 IV-D节）。

原始奖励回放：奖励以原始形式存入回放缓冲，在 TD 更新的采样时进行归一化。Welford 在线归一化器追踪运行均值与方差，避免了归一化统计量随训练演变导致的分布偏移问题。

每步更新的综合损失为：

$$\mathcal{L} = \mathcal{L}_{\mathrm{TD}} + \lambda_m \mathcal{L}_{\mathrm{margin}} + \lambda_{\mathrm{ce}} \mathcal{L}_{\mathrm{CE}} \quad (5)$$

其中 $\mathcal{L}_{\mathrm{TD}}$ 为预测 Q 值与目标 Q 值的 Smooth L1 (Huber) 损失，示例损失仅适用于 `demo=True` 的转移。梯度裁剪至 $\|\nabla\| \leq 10$。

D. 多层安全机制

训练与推理时均通过分层动作选择流水线保证碰撞规避：

Algorithm 1 森林导航四阶段 DQN 训练流水线

Require: 环境 $\mathcal{E}$，专家策略 π_e，训练集数 T
Ensure: 训练后的 Q 网络 Q_θ

阶段 0：初始化
初始化 Q_θ，$Q_{\theta^-} \leftarrow Q_\theta$，回放缓冲 $\mathcal{D}$（10 万）
初始化 Welford 在线归一化器 $\mathcal{N}$
阶段 1：专家示例预填充
while $|\mathcal{D}_{\text{demo}}| < 5000$ **do**
  以随机 (s_0, g) 运行 π_e
  if 本集成功 **then**
    将转移以 `demo` = True 存入 $\mathcal{D}$
  end if
end while
阶段 2：监督预训练
for $i = 1$ to 40,000 **do**
  采样示例批次；以 $\mathcal{L}_{\text{CE}} + \lambda_m \mathcal{L}_{\text{margin}}$ 更新 Q_θ
  if 贪心策略到达目标 **then 提前停止**
  end if
end for
$Q_{\theta^-} \leftarrow Q_\theta$；保存预训练检查点
阶段 3：主 RL 训练循环
for episode = 1 to T **do**
  采样随机 (s_0, g)，$\text{cost}(s_0, g) \geq 6\,\text{m}$
  for $t = 1$ to max_steps **do**
    if rand() $< p_{\text{exp}}(\text{ep})$ **then**
      $a_t \leftarrow \pi_e(s_t)$ ▷ 专家探索
    else
      $a_t \leftarrow \epsilon$-贪心$(Q_\theta, s_t, \text{mask}_t)$
    end if
    执行 a_t；存储 $(s_t, a_t, r_t^{\text{raw}}, s_{t+1}, d_t)$
    $\mathcal{N}.\text{update}(r_t)$
  end for
  以 $\mathcal{L}_{\text{TD}} + \lambda_m \mathcal{L}_{\text{margin}} + \lambda_{\text{ce}} \mathcal{L}_{\text{CE}}$ 执行 TD 更新
end for
阶段 4：模型选择
贪心评估 {最终、最优、预训练} → 保存最优

1) **可行性检查**：对每个候选动作模拟短视域轨迹（推理 $h = 15$ 步，训练 $h = 6$ 步）。满足以下条件视为可行：(a) 无碰撞；(b) 最小障碍距离 $\geq$ 阈值；(c) 代价至少减少 $10^{-4}\,\text{m}$。
2) **Top-k 回退**：若 $\arg\max Q$ 不可行，顺序测试 Q 值前 10 名动作。
3) **掩码回退**：若无 Top-k 动作通过，计算完整可行性掩码，选取掩码内 Q 值最高的动作。
4) **滚动启发式**：若所有动作均未通过进度检查，通过短视域滚动选取最大化障碍间隙的动作。

训练模式下放宽进度要求（仅检查碰撞安全），使 Q 网络能从奖励信号中学习前向进度；推理时恢复完整进度检查。

表 III
训练超参数。

参数	**值**
训练集数	1000
每集最大步数	600
优化器	Adam
学习率	5×10^{-4}
批次大小	128
回放缓冲容量	100,000
折扣因子 γ	0.995
ϵ 调度	$0.9 \to 0.01$（线性，250 集）
专家概率调度	$0.7 \to 0$（线性，85% of T）
训练频率	每 4 步更新 1 次
目标更新（硬）	每 1000 梯度步
目标更新（Polyak）	$\tau = 0.005$/步
梯度裁剪范数	10.0
示例间距 m	0.8
示例损失权重	$\lambda_m = 1.0$，$\lambda_{\text{ce}} = 1.0$

V. 实验设置

A. 环境配置

所有实验均使用 `forest_a` 环境（360×360 网格，$36 \times 36\,\text{m}$，85 棵树，种子 101）。定义两个评估场景：

- **短距离**（代价 6–14 m）：测试局部障碍规避与机动性。
- **长距离**（代价 42 m 以上）：测试全图全局导航能力。

B. 训练配置

表 III列出训练超参数。

C. 评估协议

每种算法在每个场景下进行 10 次固定随机种子的推理评估。所有算法与基线共享相同的 $(s_{\text{start}}, s_{\text{goal}})$ 对以保证公平比较。评估指标包括成功率、平均路径长度（m）、规划时间（s）、平均曲率（m^{-1}）与综合得分。基线包括 Hybrid A*（20 万节点预算）与 RRT*（5000 次迭代），两者均设 5 s 超时。

VI. 实验结果

A. 训练动态

图 3展示 1000 集训练中六种 DQN 变体的训练进展。成功率在第 200 集附近收敛至接近 1.0 并保持稳定。平均回报稳定在 400–500，与成功集获得 +400 终端奖励加累积进度奖励相符。

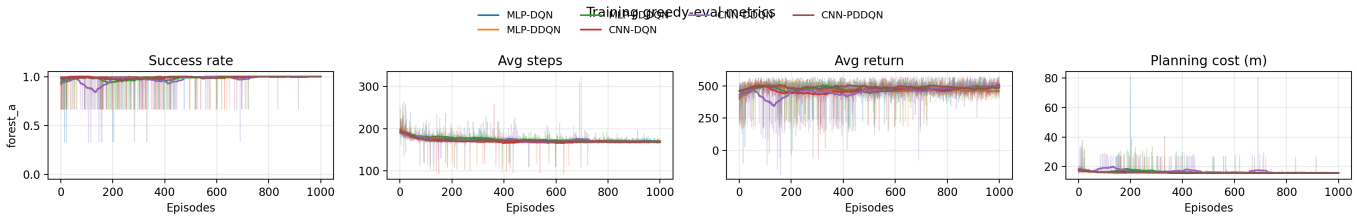

图 3. 1000 集训练评估指标。从左到右：贪心成功率、平均集步数、平均回报、规划代价。所有变体在第 200 集前收敛至高成功率。

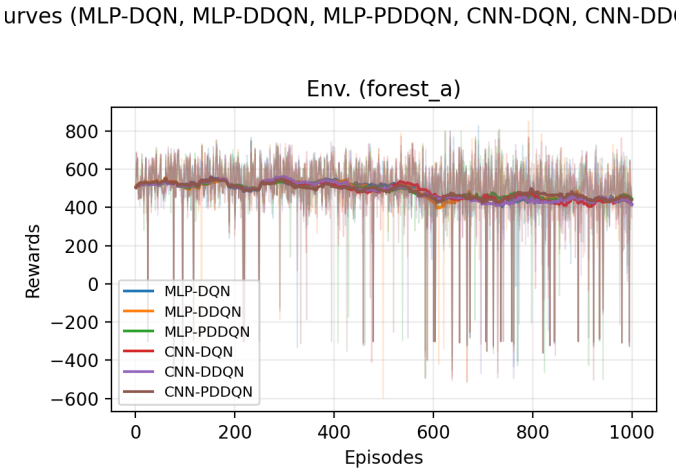

图 4. 训练奖励曲线（1000 集）。透明线：原始集回报；实线：滑动平均。所有六种变体均收敛至相近奖励水平（约 400–500）。

图 4展示训练期间的集奖励曲线。透明线为每集原始回报，实线为滑动平均值。经历初期高方差阶段（第 0–50 集，对应专家探索期）后，所有变体奖励稳定在 400–500。

图 5展示额外训练诊断，包括总损失、TD 损失、ϵ 调度与 Q 值统计量。PDDQN 变体（Polyak 更新）的 Q 值轨迹明显比周期性硬更新变体更平滑。

B. 主要结果

表 IV呈现所有算法的完整评估结果。

成功率：RL 集成在短距离场景达到 93%，长距离场景达到 97%。六种变体中有四种在长距离场景实现 100% 成功。MLP-PDDQN 是唯一在两个场景均达到 100% 成功的变体。

路径质量：CNN-PDDQN 生成最短长距离路径（40.61 m），比 Hybrid A*（40.86 m）短 0.6%。这一结果尤为突出，因为 RL 智能体并非全局规划，而是局部反应式决策。

计算效率：RL 规划时间为 0.043–0.275 s，而 Hybrid A* 为 1.29–3.78 s。MLP-PDDQN 实现最快规划（长距离 0.179 s），比 Hybrid A* 快 **21** 倍。

路径平滑性：RL 智能体路径曲率（0.10–0.18 m^{-1}）低于 RRT*（0.29–0.39 m^{-1}），与 Hybrid A* 相当。

C. 路径可视化

图 6展示所有算法在两个评估场景的规划路径。RL 智能体生成平滑、接近最优的轨迹，与 Hybrid A* 路径高度吻合，同时规避所有障碍物。

D. 控制曲线

图 7展示推理时的速度与转向角曲线。RL 智能体通过频繁小幅转向调整穿越树木间隙，而基于 MPC 的方法因跟踪控制器特性呈现更大振荡。

E. 架构对比

MLP 对比 CNN：CNN 变体在长距离任务上一致达到 100% 成功率，而 MLP-DQN 和 MLP-DDQN 仅达到 90%。CNN 专有的 EDT 间隙通道提供了有价值的空间感知能力，使智能体能预判狭窄通道。

DQN 对比 DDQN 对比 PDDQN：PDDQN（Polyak 软更新）优于 DQN 和 DDQN 变体。MLP-PDDQN 是唯一在两个场景均达到 100% 的 MLP 变体。Polyak 平均提供的连续目标跟踪比 DQN 和 DDQN 的周期性硬替换更稳定。

F. 消融研究

1) 目标邻近奖励塑形: 表 V展示在基础奖励上添加目标邻近奖励的效果。对比四种变体：(A) 无塑形基线，(B) 目标邻近塑形（$k_{\mathrm{goal}} = 1.5$），(C) 塑形 + 宽松速度约束（$v_{\mathrm{goal}} \leq 1.0\,\mathrm{m/s}$），(D) 塑形 + 严格速度约束（$v_{\mathrm{goal}} \leq 0.5\,\mathrm{m/s}$）。

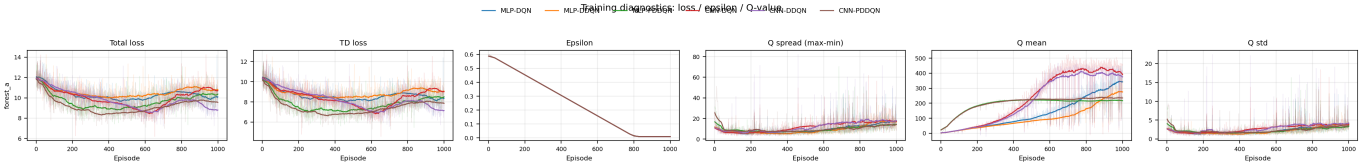

图 5. 训练诊断指标。从左到右：总损失、TD 损失、ϵ 调度、Q 值范围（最大-最小）、Q 值均值、Q 值标准差。PDDQN 变体因 Polyak 软更新展现出更平滑的 Q 值动态。

表 IV

FOREST_A 上的评估结果（1000 集训练）。最优 RL 结果用**粗体**标注。

	成功率		路径长度 (m)		规划时间 (s)		平均曲率 (m^{-1})	
算法	短距	长距	短距	长距	短距	长距	短距	长距
MLP-DQN	0.9	0.9	8.84	44.14	0.079	0.200	0.112	0.153
MLP-DDQN	0.9	0.9	8.84	44.14	0.064	0.238	0.112	0.153
MLP-PDDQN	**1.0**	**1.0**	8.40	**41.17**	**0.043**	**0.179**	0.175	0.105
CNN-DQN	0.9	**1.0**	8.32	41.39	0.076	0.275	0.117	0.112
CNN-DDQN	0.9	**1.0**	8.42	41.12	0.080	0.225	0.146	0.120
CNN-PDDQN	0.9	**1.0**	**8.31**	**40.61**	0.070	0.254	0.167	**0.104**
RL 均值	*0.93*	*0.97*	—	—	—	—	—	—
Hybrid A*	1.0	1.0	8.39	40.86	1.291	3.782	0.116	0.100
RRT*	1.0	0.9	9.14	44.04	0.255	1.804	0.386	0.286

表 V

消融：目标邻近奖励塑形。6 种变体 RL 均值成功率（300 集）。

	A: 基线	**B: + 塑形**	**C: + 速度 1.0**	**D: + 速度 0.5**
短距	0.92	0.88	0.72	0.67
长距	0.95	0.87	0.43	0.33

发现 1：目标邻近塑形对部分变体有边际提升（MLP-DQN：0.8 → 1.0），但会降低其他变体性能（CNN-PDDQN：1.0 → 0.6）。额外奖励信号可能干扰已校准的代价进度奖励。

发现 2：目标速度约束显著降低成功率。1.0 m/s 容差下长距离成功率从 0.87 跌至 0.43；0.5 m/s 时骤降至 0.33。300 集训练预算不足以使智能体学习精确减速行为。

图 **??**展示各变体细分结果（表 VI）。

2) DQN+MPC 混合架构： 表 VII对比纯 DQN 控制与 DQN 生成全局路径后由 MPC 跟踪的两阶段架构。

DQN+MPC 混合架构持续低于纯 DQN 控制。细分分析（表 VIII）显示：MLP 变体在长距离任务略有提升，CNN 变体则显著下降。DQN 路径缺乏完备性保证；当 DQN 未能到达目标时，MPC 盲目跟踪不完整路径，放大而非纠正了结构性缺陷。

表 VI

目标邻近塑形下各变体成功率（短距/长距）。

	A: 基线		**B: + 塑形**	
变体	短距	长距	短距	长距
MLP-DQN	0.8	0.8	**1.0**	**1.0**
MLP-DDQN	0.9	0.9	0.9	0.9
MLP-PDDQN	**1.0**	**1.0**	0.9	0.9
CNN-DQN	0.9	**1.0**	0.9	0.7
CNN-DDQN	0.9	**1.0**	**1.0**	**1.0**
CNN-PDDQN	**1.0**	**1.0**	0.6	0.7

表 VII

消融：纯 DQN 与 DQN+MPC 混合架构。RL 均值成功率（300 集）。

	纯 DQN	**DQN+MPC**
短距	0.92	0.77（−16%）
长距	0.95	0.87（−8%）

3) 训练集数的影响： 将训练从 300 集延长至 1000 集（表 IX）使长距离成功率从 0.95 提升至 0.97，短距离任务无退化。MLP-PDDQN 受益最大，长距离从 0.9

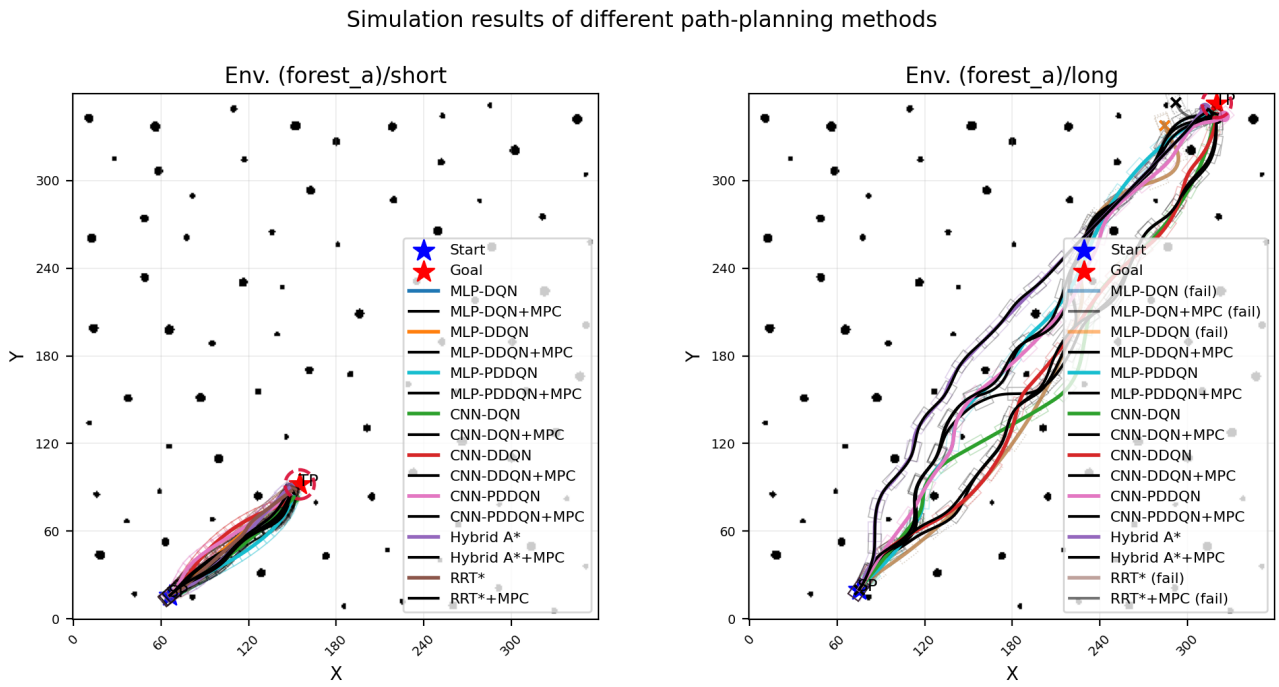

图 6. 所有算法的规划路径。左：短距离场景；右：长距离场景。RL 智能体（彩色线）生成与 Hybrid A*（黑色虚线）相当的平滑路径，RRT* 路径（灰色）曲率明显更高。

表 VIII
DQN+MPC 各变体成功率（短距/长距）。

	纯 DQN		DQN+MPC	
变体	短距	长距	短距	长距
MLP-DQN	0.8	0.8	0.7	0.9
MLP-DDQN	0.9	0.9	0.6	1.0
MLP-PDDQN	1.0	1.0	0.8	1.0
CNN-DQN	0.9	1.0	0.8	0.8
CNN-DDQN	0.9	1.0	0.8	0.7
CNN-PDDQN	1.0	1.0	0.9	0.8

表 IX
训练集数对 RL 均值成功率的影响。

	300 集	1000 集
短距	0.93	0.93
长距	0.95	0.97（+2%）

提升至 1.0。

VII. 讨论

RL 对比经典规划器。实验结果表明，DQN 系列智能体能够在路径质量上媲美乃至超越 Hybrid A*，同时提供超过一个数量级的计算速度优势。这一速度优势对频繁重规划的实时导航至关重要。然而，RL 智能体尚未在所有变体上达到 Hybrid A* 的 100% 可靠性，说明安全关键应用可能受益于以 RL 快速初始规划配合经典规划器验证的混合方案。

专家引导的作用。四阶段流水线对森林导航至关重要。若无示例预填充与预训练，智能体在可行训练预算内无法学到有意义的策略。专家概率衰减（从 0.7 降至 0，覆盖 85% 的训练过程）提供了从模仿到自主策略的平稳过渡，类似于课程学习。

原始奖励回放。以原始形式存储奖励并在采样时归一化，消除了归一化前存储的固有分布偏移问题。随着归一化统计量随训练演变，先前存储的归一化值将过时；原始存储规避了这一不一致性，对训练稳定性有可观贡献。

安全机制的权衡。多层回退系统以探索性换取安全性。训练模式下放宽进度要求使 Q 网络能发现新颖策略，而推理时的完整安全检查防止碰撞。这一训练-测试不对称设计有意平衡了样本效率与部署安全。

DQN+MPC 失效原因。混合架构的失效揭示了一个根本性不对称：经典规划器（Hybrid A*、RRT*）保证路径完备性，使 MPC 跟踪可靠；DQN 路径由序列反应式决策生成，可能包含环路、死胡同或无法到达

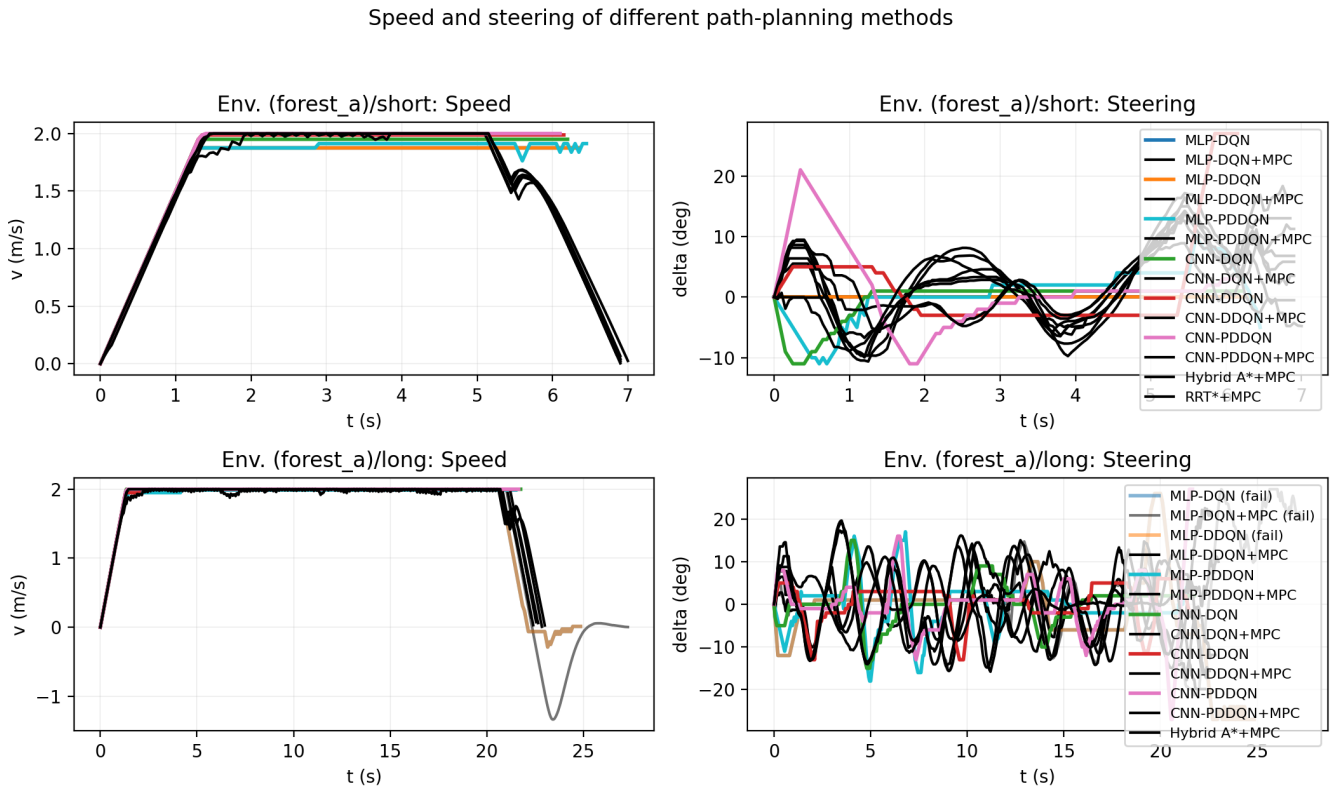

图 7. 推理时速度与转向角曲线。上行：短距离；下行：长距离。左列：速度（v）；右列：转向角（δ）。RL 智能体展现出快速加速、平稳减速的速度曲线。

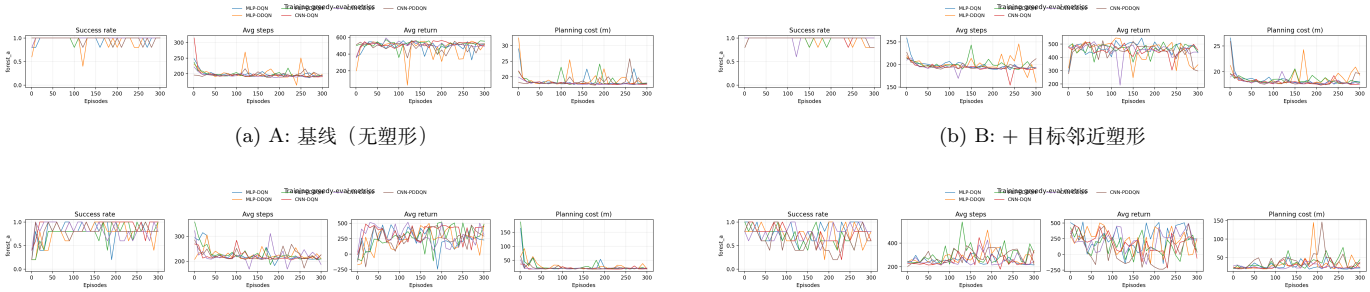

(a) A: 基线（无塑形）

(b) B: + 目标邻近塑形

(c) C: + 速度约束（1.0 m/s）

(d) D: + 速度约束（0.5 m/s）

图 8. 四种奖励塑形消融变体的训练评估指标（每种 300 集）。基线（A）与仅塑形（B）变体收敛稳定；速度约束（C、D）导致严重的性能下降与训练不稳定。

目标。MPC 跟踪此类路径会放大而非纠正结构性缺陷。可行的混合方案需要显式路径验证或重规划能力。

局限性与未来工作。(1) 评估局限于单一森林配置；对更密集森林的泛化能力有待进一步研究。(2) 35 个离散动作可能限制精细控制；连续动作变体（DDPG、SAC）或可改善路径平滑性。(3) 目标速度约束在 300 集内无法实现；专门的减速课程设计仍是开放挑战。(4) 仿真到实物迁移尚未涉及。

VIII. 结论

本文提出了一套面向密集森林环境自主导航的综合 DQN 框架。通过融合专家示例、监督预训练、引导式探索与时序差分学习的四阶段训练流水线，本方法在 Ackermann 自行车运动学的长距离导航任务上实现高达 100% 的成功率。CNN-PDDQN 是最优变体，路径长度 40.61 m 短于 Hybrid A*（40.86 m），规划速度快 15 倍以上（0.25 s 对比 3.78 s）。系统消融研究揭示三点核心认识：(i) 目标邻近奖励塑形收益有限且不一致；

(ii) 终端速度约束需要远超单纯到达目标所需的训练量；(iii) DQN+MPC 混合架构因路径完备性问题而逊色于直接 RL 控制。未来工作将扩展至多地图泛化、连续动作空间与面向实地部署的仿真到实物迁移。

参考文献

[1] D. Dolgov, S. Thrun, M. Montemerlo, and J. Diebel, "Path planning for autonomous vehicles in unknown semi-structured environments," in *The International Journal of Robotics Research*, vol. 29, no. 5. SAGE Publications, 2010, pp. 485–501.

[2] S. Karaman and E. Frazzoli, "Sampling-based algorithms for optimal motion planning," *The International Journal of Robotics Research*, vol. 30, no. 7, pp. 846–894, 2011.

[3] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski *et al.*, "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.

[4] H. Van Hasselt, A. Guez, and D. Silver, "Deep reinforcement learning with double Q-learning," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 30, no. 1, 2016.

[5] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra, "Continuous control with deep reinforcement learning," *arXiv preprint arXiv:1509.02971*, 2015.

[6] T. Hester, M. Vecerik, O. Pietquin, M. Lanctot, T. Schaul, B. Piot, D. Horgan, J. Quan, A. Sendonaris, I. Osband *et al.*, "Deep Q-learning from demonstrations," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.

[7] L. Tai, G. Paolo, and M. Liu, "Virtual-to-real deep reinforcement learning: Continuous control of mobile robots for mapless navigation," in *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2017, pp. 31–36.

[8] L. Xie, S. Wang, A. Markham, and N. Trigoni, "Learning with training wheels: Speeding up training with a simple controller for deep reinforcement learning," in *2018 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2018, pp. 6276–6283.

[9] S. Huang and S. Ontañón, "A closer look at invalid action masking in policy gradient algorithms," in *The International FLAIRS Conference Proceedings*, vol. 35, 2022.